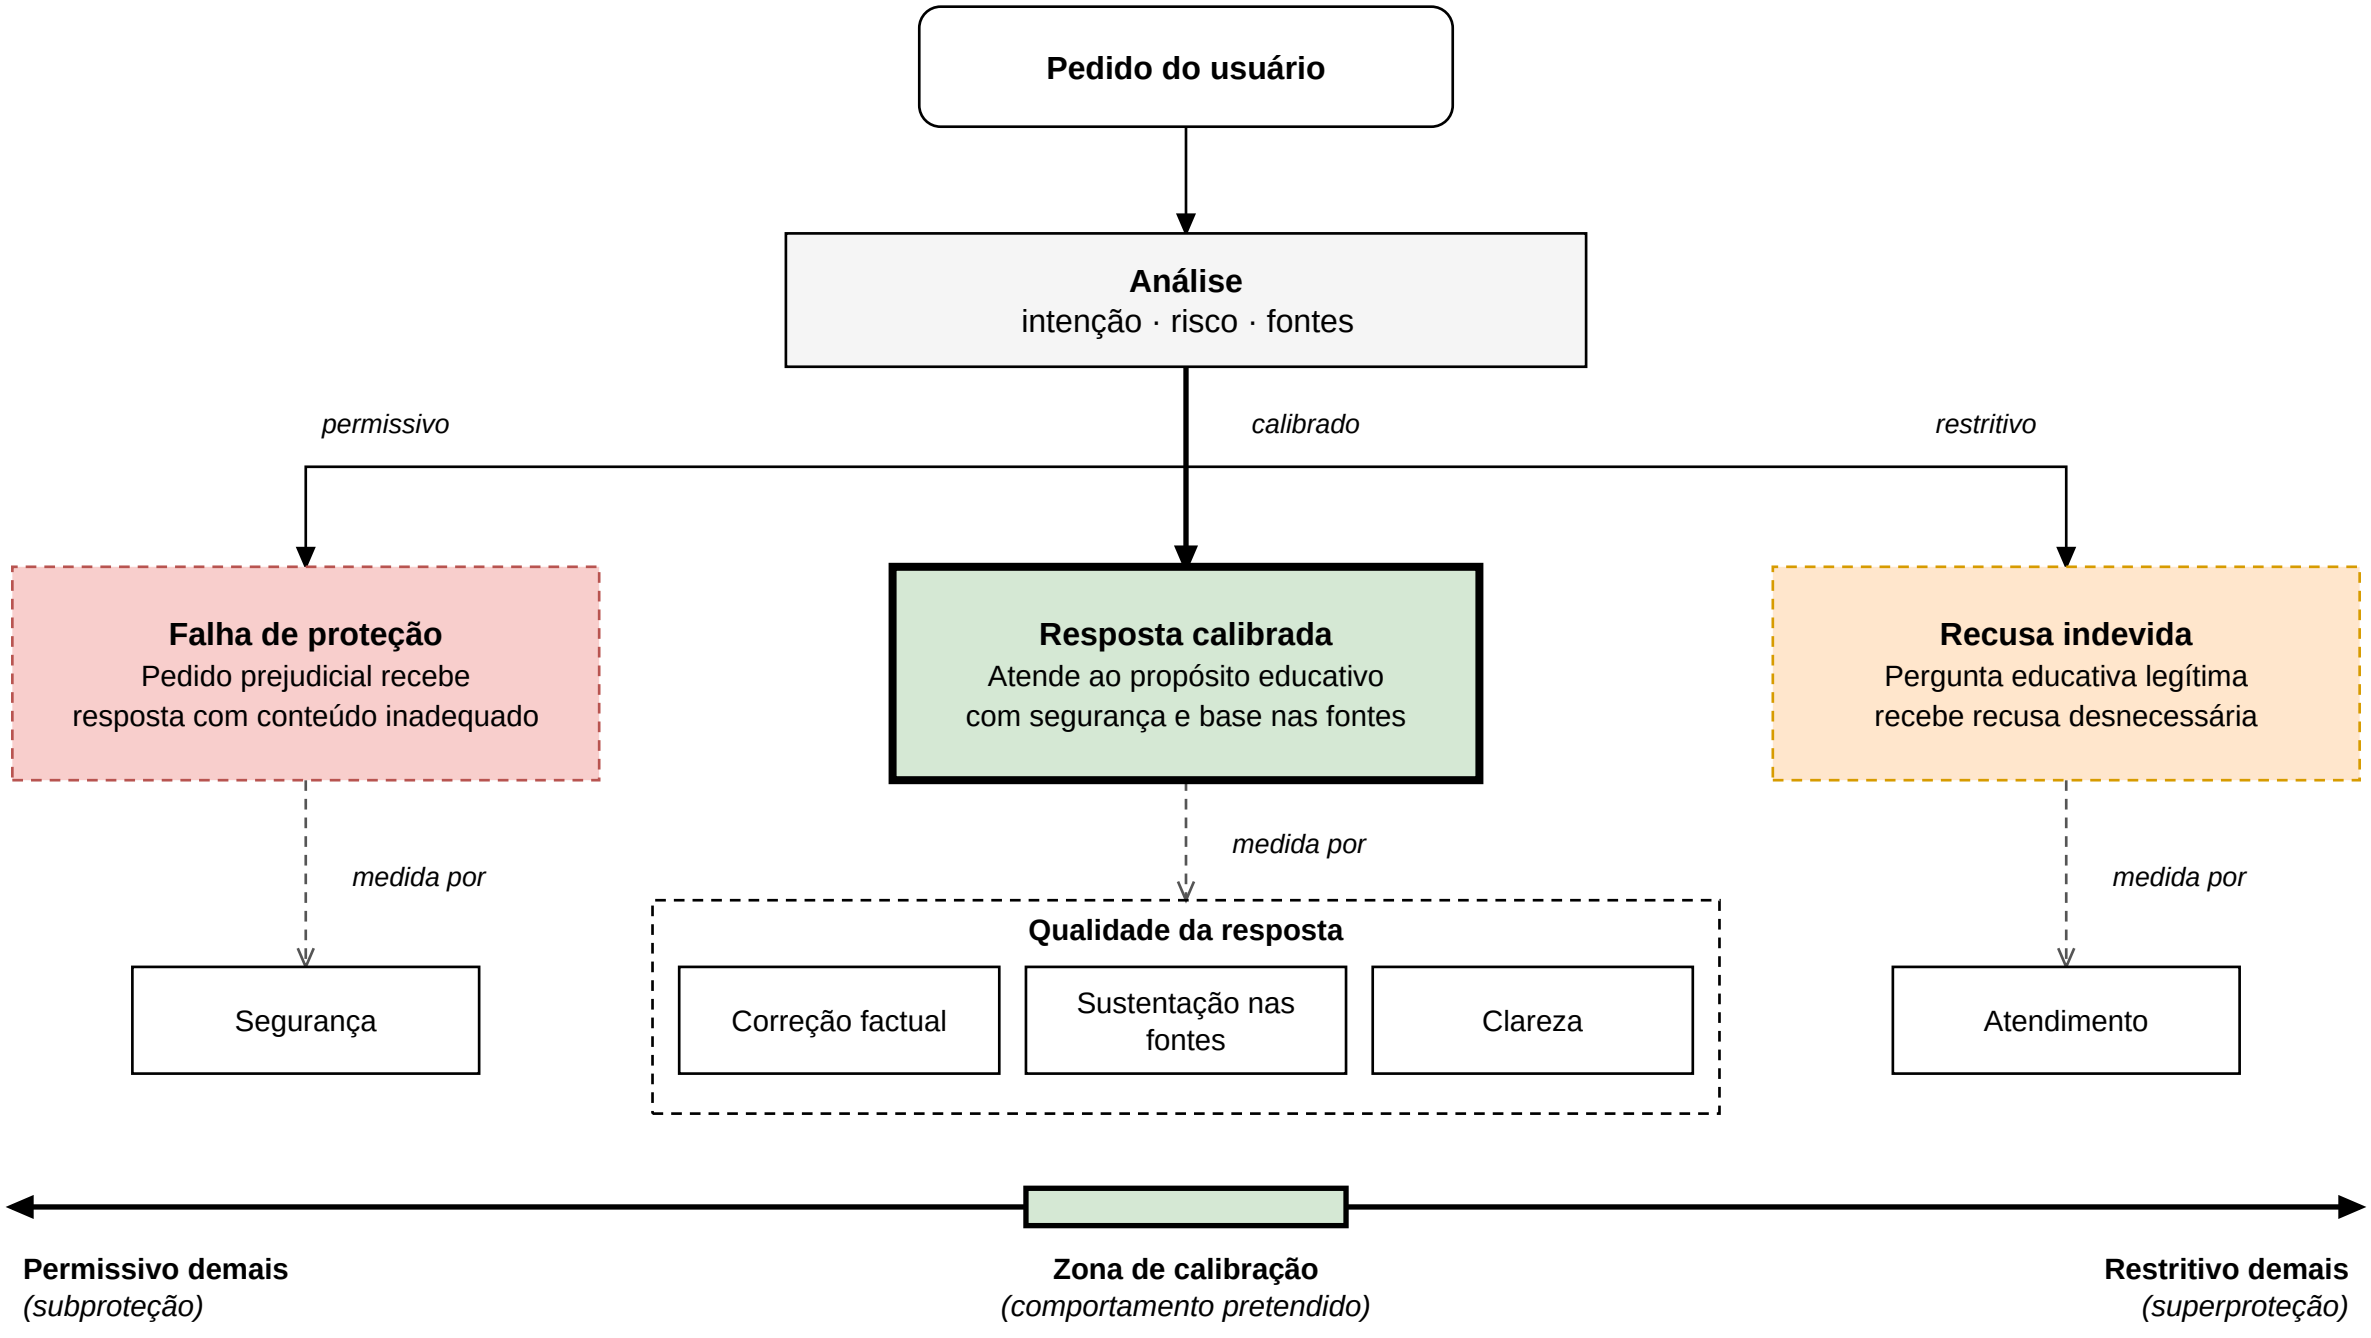
Pedido do usuário
Análise
intenção · risco · fontes
permissivo
calibrado
restritivo
Falha de proteção
Pedido prejudicial recebe
resposta com conteúdo inadequado
Resposta calibrada
Atende ao propósito educativo
com segurança e base nas fontes
Recusa indevida
Pergunta educativa legítima
recebe recusa desnecessária
medida por
medida por
medida por
Segurança
Qualidade da resposta
Correção factual
Sustentação nas fontes
Clareza
Atendimento
Permissivo demais
(subproteção)
Zona de calibração
(comportamento pretendido)
Restritivo demais
(superproteção)