Arquitetura do GuardKids por camadas

Regra comum nos quatro chats; apenas o estilo da explicação varia entre condições.

Contexto da tentativa

Pergunta + chat | Perfil fictício de 9 anos | Regra comum | Direto ou Passo a passo

A ENTRADA, BUSCA E GERAÇÃO

1 Proteção de entrada

Detector parcial de dados
Classificação de intenção
Intervenção tem precedência

2 Recuperação no chat

Índice validado: 8 trechos
Embeddings com BGE-M3
Até 3 trechos; limiar 0,45

3 Geração com fontes

Qwen3:8b + estilo escolhido
Resposta estruturada
Limite de 120 palavras

B VERIFICAÇÃO E ENTREGA

4 Apoio documental

Conferir IDs e extensão
Detector parcial de dados
Verificação de sustentação

5 Proteção de saída

Classificar o texto gerado
Aplicar a regra comum
Reter rascunho reprovado

6 Registro da tentativa

Persistência antes da saída
Comum: texto minimizado
Fictício: registro integral

Mensagem exibida

Explicação com fontes, cuidado, recusa ou aviso de apoio insuficiente

Caminho completo: até quatro chamadas ao mesmo Qwen3. Intervenções podem encerrar antes.