3 Metodologia

Este capítulo apresenta os procedimentos para avaliar a influência da configuração de guardrails na ocorrência de respostas inadequadas e no bloqueio indevido de perguntas em um chatbot educativo infantil, em português brasileiro. Neste trabalho, guardrails são mecanismos que verificam mensagens e aplicam políticas de proteção ao conteúdo das interações. Serão produzidos um quadro de políticas, uma prova de conceito documentada e uma avaliação de seu comportamento diante de ajustes de configuração.

3.1 Caracterização e delimitação da pesquisa

A pesquisa será de desenvolvimento, de natureza aplicada, voltada à construção e à avaliação de guardrails configuráveis. O chatbot será o ambiente de aplicação das proteções. A análise será descritiva, reunindo contagens e proporções de respostas inadequadas e bloqueios indevidos, acompanhadas da apreciação da qualidade das respostas e das falhas observadas.

Crianças de 7 a 11 anos constituirão o público destinatário do projeto. Para delimitar a prova de conceito, os testes utilizarão um único perfil fictício de estudante de 9 anos, matriculado no 4º ano do Ensino Fundamental. Esse perfil definirá a idade, a escolaridade e orientações para o uso de frases curtas, vocabulário acessível e explicação de termos científicos. Permanecerá fixo durante a avaliação, sem representar todas as crianças ou idades do público destinatário e sem pressupor um nível de leitura comum a elas.

Ciências será utilizada como cenário da prova de conceito, com conteúdo delimitado ao tema seres vivos, pela possibilidade de selecionar textos explicativos e conferir as respostas com suas fontes. O conteúdo educativo será fornecido por apostilas selecionadas, mediante Geração Aumentada por Recuperação, ou RAG. A recuperação apoiará o chatbot, enquanto a investigação permanecerá centrada nos guardrails. O escopo compreenderá um modelo de linguagem, uma matéria e um perfil fictício, com perguntas e respostas em texto. Entrada e saída de áudio, geração de imagens, cadastro, chat geral e acompanhamento pelos responsáveis serão considerados possibilidades de evolução futura, sem integrar a implementação ou a avaliação desta etapa.

3.2 Definição das políticas de proteção

As políticas serão fundamentadas nas referências selecionadas. Wang et al. (2022) apoiarão os princípios de proteção e de adequação à infância. Rath et al. (2025) e Khoo,

Chua e Shong (2025) apoiarão a seleção das categorias de risco e dos critérios para avaliar conteúdo inadequado em interações com modelos de linguagem.

Como referência brasileira, será utilizado o *Guia Prático de Audiovisual, Aplicativos e RPG*, quinta edição, do Ministério da Justiça e Segurança Pública (Brasil, 2025). Seus descritores e critérios etários serão relacionados às categorias dos artigos, com adaptação ao contexto conversacional. Essa adaptação será documentada como uma decisão metodológica do estudo, sem atribuição de classificação oficial ao chatbot. A adequação do conteúdo será considerada em relação à idade do perfil fictício, pois 7 a 11 anos não constitui uma faixa única do guia.

A entrega será um quadro de políticas que associe categoria de risco, referência, critério de conteúdo inadequado e tratamento esperado. O tratamento poderá ser uma resposta educativa, uma orientação segura ou o bloqueio de conteúdo. A presença de um tema sensível, isoladamente, não exigirá recusa: serão considerados o contexto e a possibilidade de oferecer uma explicação apropriada. Por exemplo, uma pergunta sobre a alimentação de animais poderá receber uma explicação educativa, enquanto uma solicitação de instruções para ferir animais exigirá proteção. As decisões esperadas para cada caso serão justificadas no quadro de políticas.

Os critérios de referência para avaliar conteúdo e decisões serão fixados antes dos testes. Os ajustes modificarão a forma como o protótipo aplica as políticas, por exemplo, por meio de uma regra ou limiar de decisão, enquanto os critérios de referência permanecerão constantes. Assim, o aumento ou a redução de restrição será avaliado contra o mesmo padrão de adequação, sem redefinir o julgamento esperado para favorecer uma configuração.

3.3 Desenvolvimento da prova de conceito

3.3.1 Base educativa e recuperação de conteúdo

Serão selecionados trechos de apostilas com autoria e revisão de conteúdo identificadas, compatíveis com o 4º ano e com o tema seres vivos. O material *Trilhas de Aprendizagens: Ensino Fundamental, 4º ano, volume 2*, segunda edição, da Secretaria Municipal de Educação de São Paulo, será considerado como fonte candidata. Suas páginas impressas 153 e 154 apresentam atividades sobre alimentação dos seres vivos e cadeias alimentares (São Paulo, 2021). A adoção dos trechos dependerá da conferência de conteúdo, legibilidade e condições de reutilização, incluindo os créditos de materiais de terceiros. Serão registrados edição, páginas, autoria, revisão e condições de uso. A disponibilidade gratuita não será tomada, isoladamente, como autorização de reutilização ou garantia de adequação pedagógica.

A base de recuperação conterá exclusivamente os trechos educativos selecionados. Eles serão associados à fonte e à página de origem, convertidos em representações vetoriais e armazenados para consulta por similaridade. O conteúdo recuperado será fornecido ao modelo como contexto de apoio à resposta, conforme o princípio de recuperação associado à geração (Lewis et al., 2020). Esse procedimento não corresponderá ao treinamento do modelo com as apostilas.

A seleção priorizará textos que possam ser compreendidos sem imagens ou vídeos. Serão documentados o procedimento de extração, a divisão em trechos, o modelo de representação vetorial, o armazenamento e a quantidade de trechos recuperados por consulta. A escolha desses componentes considerará simplicidade e disponibilidade de recursos, sem comparação entre métodos de RAG.

O modelo será orientado a fundamentar as explicações educativas no material recuperado e a informar quando esse material for insuficiente. Essa orientação não elimina o conhecimento prévio do modelo nem garante fidelidade às apostilas. Por isso, será conferido se as respostas disponibilizadas são corretas e sustentadas pelo conteúdo selecionado. Mensagens de bloqueio ou orientação de proteção poderão ser previamente definidas nas políticas, independentemente do acervo educativo.

3.3.2 Guardrails e registro das interações

Será utilizado um modelo de linguagem previamente treinado, com pesos disponíveis para execução local e licença compatível com o projeto, selecionado conforme suporte ao português brasileiro e recursos computacionais. Será priorizada a execução local com componentes gratuitos, considerando o computador disponível, com 16 GB de memória RAM e placa de vídeo NVIDIA GeForce RTX 4060 com 8 GB de memória. Uma verificação preliminar de funcionamento orientará a escolha de um modelo que permita executar o fluxo completo nesses recursos. Não haverá treinamento ou ajuste dos pesos do modelo, nem comparação entre diferentes modelos na avaliação principal.

A identificação do modelo, sua versão, eventual quantização, parâmetros de geração e instruções serão registrados. O perfil fictício será inserido na configuração, sem dados pessoais reais. A infraestrutura e os mecanismos de verificação escolhidos serão documentados antes dos testes, permitindo identificar quais componentes participam de cada decisão. Depois da calibração, esses componentes permanecerão fixos durante a avaliação.

A prova de conceito terá verificações da entrada e da saída. O fluxo consistirá em verificar a pergunta, recuperar conteúdo quando a interação for permitida, gerar a resposta e verificá-la antes da disponibilização. Solicitações bloqueadas na entrada receberão uma mensagem previamente definida. Conteúdo rejeitado na saída será substituído por uma mensagem de proteção ou orientação prevista na política.

As regras ou parâmetros de proteção serão mantidos em arquivo de configuração, separado da lógica principal do chatbot. Esse arquivo registrará as categorias verificadas e os critérios usados para permitir ou bloquear conteúdo. O ajuste do nível de restrição será demonstrado por uma alteração pontual, como a inclusão de uma condição que diferencie explicações educativas de instruções para causar dano, ou a mudança de um limiar quando o mecanismo selecionado produzir escores de risco. O ajuste utilizado será escolhido e documentado na calibração. Sua aplicação deverá ocorrer sem reescrever a lógica principal. O conteúdo recuperado será tratado como fonte educativa, sem autoridade para modificar as instruções e políticas do sistema.

Cada execução registrará pergunta, perfil, versão da configuração, trechos recuperados, decisão de cada verificação e resposta final. Respostas intermediárias rejeitadas serão identificadas separadamente, para distinguir conteúdo gerado de conteúdo efetivamente disponibilizado.

3.4 Seleção das perguntas e execução dos testes

As perguntas serão selecionadas de bases existentes e adaptadas quando necessário ao português brasileiro e ao cenário avaliado. A seleção considerará licença, categorias de risco, pertinência educativa e compatibilidade com o perfil. O MinorBench será considerado como fonte de solicitações de risco (Khoo, Chua e Shong, 2025). Perguntas educativas legítimas serão selecionadas de materiais ou bases compatíveis com as apostilas, sobre o tema seres vivos. As solicitações de risco poderão extrapolar esse tema, para verificar a aplicação das políticas diante de tentativas de desvio do uso educativo. A amostra será intencional e delimitada pelas categorias e conteúdos escolhidos; não representará a frequência real de perguntas feitas por crianças.

Cada caso terá identificador, origem, enunciado utilizado, categoria e tratamento esperado. Traduções e adaptações serão registradas, preservando a intenção da pergunta e o risco avaliado. O conjunto incluirá solicitações de risco e perguntas legítimas com resposta verificável nas apostilas, com indicação das páginas pertinentes. Casos ambíguos e perguntas educativas sem apoio no acervo serão identificados antes da execução e analisados separadamente. Na calibração, será estimado o tempo necessário para executar, classificar e justificar a análise de cada caso. Essa estimativa e a cobertura das categorias orientarão o tamanho da amostra. A quantidade final, a distribuição por categoria e os critérios de inclusão e exclusão serão registrados antes da avaliação.

O pesquisador classificará os casos segundo os critérios de referência antes de examinar as respostas do chatbot. Perguntas usadas no desenvolvimento e na calibração serão identificadas e separadas da amostra de avaliação. As configurações que serão comparadas ficarão definidas antes de executar essa amostra. Ajustes posteriores motivados

pelas falhas encontradas serão registrados como desenvolvimento adicional, preservando os resultados da avaliação realizada.

Para limitar o esforço de execução, a avaliação principal utilizará o mesmo protótipo em uma configuração de referência e após um único ajuste pontual de regra ou parâmetro. A alteração terá finalidade registrada e será avaliada com o mesmo conjunto de perguntas, mantendo as demais condições. A comparação apresentará os casos em que a decisão mudou e os efeitos sobre respostas inadequadas, bloqueios indevidos e qualidade das respostas. Outros ajustes, caso realizados durante o desenvolvimento, serão documentados separadamente.

Perfil, modelo, apostilas, procedimento de recuperação, instruções educativas e parâmetros de geração permanecerão constantes entre os ajustes dos guardrails. Cada teste compreenderá uma pergunta e a resposta final, em sessão independente. Quando disponíveis, serão utilizados controles de aleatoriedade, com seus valores registrados. Eventuais repetições terão quantidade e condições fixadas antes da avaliação; seus resultados serão agrupados por pergunta, sem tratá-las como novos casos independentes. Diferenças de geração ou de conteúdo recuperado serão consideradas na interpretação das mudanças observadas.

3.5 Critérios e indicadores de avaliação

A análise distinguirá a decisão de permitir ou bloquear da adequação da resposta final. Uma recusa poderá conter informação inadequada; uma orientação segura poderá atender ao tratamento esperado sem recusa integral. A identificação desses casos seguirá o quadro de políticas, mantendo o foco no conteúdo disponibilizado.

3.5.1 Respostas inadequadas e bloqueios indevidos

Será considerada inadequada a resposta final que contrariar um critério de proteção definido para o cenário. A taxa de respostas inadequadas será calculada por:

$$T_{RI} = \frac{N_{RI}}{N_V} \times 100, \tag{3.1}$$

em que N_{RI} representa o número de respostas inadequadas e N_V o número de execuções válidas cuja resposta final recebeu classificação conclusiva de conteúdo. Os resultados serão apresentados por configuração, por grupo de perguntas e por categoria de risco. Categorias com poucos casos serão identificadas, limitando a interpretação de suas porcentagens.

Um bloqueio será indevido quando os guardrails rejeitarem uma pergunta legítima ou uma resposta educativa permitida pelos critérios de referência, impedindo o atendimento de uma pergunta com apoio no acervo. O bloqueio correto de uma resposta perigosa gerada

para uma pergunta legítima será registrado como proteção da saída, e não como erro do filtro. Nesse caso, será registrada também a ausência de atendimento da pergunta. A taxa de bloqueios indevidos será:

$$T_{BI} = \frac{N_{BI}}{N_L} \times 100, \tag{3.2}$$

em que N_{BI} corresponde às execuções com bloqueio indevido e N_L às execuções válidas de perguntas legítimas com apoio no acervo cuja decisão pôde ser classificada. A origem da decisão será identificada pelos registros dos guardrails, distinguindo-a de recusa produzida pelo modelo e de falha de recuperação. Casos cuja origem não possa ser determinada serão reportados como inconclusivos e contabilizados separadamente, sem serem considerados acertos.

Também será calculada a proporção de solicitações de risco tratadas adequadamente: número de casos que atendam ao tratamento esperado e não disponibilizem conteúdo inadequado, dividido pelo total de execuções válidas de solicitações de risco com classificação conclusiva do tratamento, multiplicado por cem.

Uma execução será válida quando o fluxo terminar com uma resposta final registrável, inclusive uma mensagem de bloqueio ou de insuficiência do acervo. Falhas que interrompam esse fluxo serão reportadas como erros técnicos. Serão informados o total de tentativas, as execuções válidas e as perdas ou classificações inconclusivas de cada configuração. Na comparação, será preservada a correspondência entre perguntas e explicitado quando houver dados ausentes. Cada indicador apresentará numerador, denominador e quantidade de casos excluídos por ausência de classificação, para tornar visível sua cobertura. Taxas sem casos no denominador serão registradas como não aplicáveis.

3.5.2 Qualidade das respostas disponibilizadas

As respostas educativas permitidas serão avaliadas pelo pesquisador quanto à correção, pertinência e clareza. A correção será conferida com as informações de referência das apostilas; a pertinência, pelo atendimento à pergunta; e a clareza, pelo vocabulário, extensão e explicação dos termos em relação às orientações do perfil. Afirmações ausentes das fontes serão assinaladas como não sustentadas, sem serem automaticamente classificadas como falsas. Quando necessário, sua verificação será documentada.

Cada critério receberá uma classificação de atendimento integral, parcial ou ausente, acompanhada de justificativa. Para correção, atendimento parcial indicará uma imprecisão localizada e atendimento ausente um erro que comprometa a explicação; para pertinência, esses níveis indicarão resposta incompleta e falta de atendimento à pergunta; para clareza, indicarão dificuldades localizadas e incompatibilidade predominante com as orientações de linguagem. Atendimento integral corresponderá à ausência desses problemas na análise realizada. Os resultados serão apresentados por critério, junto da quantidade de perguntas

que receberam resposta educativa, para que a qualidade não seja interpretada apenas sobre as poucas respostas que uma configuração muito restritiva permita.

Mensagens de bloqueio ou orientação serão examinadas quanto à coerência com a política, clareza e ausência de conteúdo inadequado. A apreciação da linguagem não comprovará compreensão por crianças, pois não haverá participação infantil nesta etapa.

3.6 Análise das entregas e limites do estudo

A análise relacionará os ajustes efetuados aos indicadores e aos exemplos de respostas. Para cada configuração, serão apresentadas contagens, porcentagens e a diferença observada em relação à configuração de referência. Os casos serão examinados em conjunto para discutir o equilíbrio entre proteção e atendimento das perguntas legítimas. Efeitos da recuperação e da geração serão considerados, sem atribuir automaticamente toda mudança aos guardrails.

As entregas serão apresentadas em correspondência aos três objetivos específicos: quadro de políticas, prova de conceito documentada e avaliação do comportamento dos guardrails. A conclusão responderá à pergunta de pesquisa com base nessas evidências, incluindo resultados desfavoráveis e limites observados.

Os resultados serão restritos ao perfil fictício, à matéria, ao modelo, às fontes e às perguntas selecionados. A seleção intencional, as adaptações das bases, a variabilidade da geração e o julgamento por um único pesquisador limitarão sua generalização. Os registros dos critérios e das justificativas permitirão revisar as decisões. O estudo não envolverá crianças nem coleta de seus dados pessoais; não avaliará conversas com múltiplas interações, compreensão infantil, recursos de áudio ou imagens. As conclusões tratarão do comportamento observado na prova de conceito, sem garantia de segurança absoluta ou de eficácia pedagógica.

Referências

BRASIL. Ministério da Justiça e Segurança Pública. **Guia Prático de Audiovisual, Aplicativos e RPG**. 5. ed. Brasília, 2025. Disponível em: https://www.gov.br/mj/pt-br/assuntos/seus-direitos/classificacao-1/classind-audio-visual-2025-vs-10-nova-faixa.pdf. Acesso em: 6 out. 2026.

KHOO, Shaun; CHUA, Gabriel; SHONG, Rachel. **MinorBench: A Hand-Built Benchmark for Content-Based Risks for Children**. ICLR 2025 Workshop on AI for Children, 2025. arXiv:2503.10242, v. 1. Disponível em: https://arxiv.org/abs/2503.10242. Acesso em: 6 out. 2026.

LEWIS, Patrick et al. **Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks**. NeurIPS, 2020. Disponível em: https://arxiv.org/abs/2005.11401. Acesso em: 6 out. 2026.

RATH, Prasanjit; SHRAWGI, Hari; AGRAWAL, Parag; DANDAPAT, Sandipan. **LLM Safety for Children**. Preprint, 2025. arXiv:2502.12552, v. 1. Disponível em: https://arxiv.org/abs/2502.12552. Acesso em: 6 out. 2026.

SÃO PAULO (Município). Secretaria Municipal de Educação. Coordenadoria Pedagógica. **Trilhas de aprendizagens: Ensino Fundamental: 4º ano: volume 2**. 2. ed. São Paulo: SME/COPED, 2021. Disponível em: https://acervodigital.sme.prefeitura.sp.gov.br/wp-content/uploads/2021/10/4ano_TA2_2ed_web.pdf. Acesso em: 7 out. 2026.

WANG, Ge; ZHAO, Jun; VAN KLEEK, Max; SHADBOLT, Nigel. Informing Age-Appropriate AI: Examining Principles and Practices of AI for Children. In: **CHI Conference on Human Factors in Computing Systems**. New York: ACM, 2022. DOI: 10.1145/3491102.3502057.