

CURSO DE SISTEMAS DE INFORMAÇÃO

DESENVOLVIMENTO E AVALIAÇÃO DE GUARDRAILS CONFIGURÁVEIS EM UMA PROVA DE CONCEITO DE CHATBOT EDUCATIVO DESTINADO A CRIANÇAS DE 7 A 11 ANOS EM PORTUGUÊS BRASILEIRO

FILIPE MARTINS HENRIQUE

Palmas

2026



CURSO DE SISTEMAS DE INFORMAÇÃO

DESENVOLVIMENTO E AVALIAÇÃO DE GUARDRAILS CONFIGURÁVEIS EM UMA PROVA DE CONCEITO DE CHATBOT EDUCATIVO DESTINADO A CRIANÇAS DE 7 A 11 ANOS EM PORTUGUÊS BRASILEIRO

FILIPE MARTINS HENRIQUE

Projeto de Pesquisa apresentado à disciplina de Trabalho de Conclusão de Curso I do Curso de Sistemas de Informação da Universidade Estadual do Tocantins – UNITINS, sob orientação do Prof. Marcos Souza.

Palmas
2026

Resumo

Chatbots educativos baseados em grandes modelos de linguagem podem gerar conteúdo inadequado, recusar dúvidas legítimas ou acrescentar informações sem apoio documental. Este Projeto de Pesquisa/TCC I desenvolve e verifica preliminarmente uma prova de conceito com guardrails contextuais em português brasileiro, destinada a crianças de sete a onze anos, mas operada somente com perfil fictício de nove anos e sem participantes infantis. O artefato local combina Qwen3:8b, recuperação com BGE-M3 e verificações de entrada, sustentação e saída. A versão atual organiza Ciências, História, Geografia e questões gerais sob uma regra de proteção comum e compara os estilos Direto e Passo a passo. O acervo contém cinco recortes didáticos e três sínteses experimentais, revisadas com assistência de IA. Foram executadas 32 tentativas sobre 16 perguntas de desenvolvimento, sem perdas técnicas: oito respostas liberadas, seis bloqueios, dez orientações de cuidado e oito comunicações de apoio insuficiente. A concordância das rotas com as referências propostas não equivale à qualidade do conteúdo. A inspeção assistida pela IA autora apontou ressalvas de sustentação em cinco das oito explicações liberadas e não demonstra superioridade de linguagem ou compreensão infantil. Os 108 registros históricos de duas versões anteriores permanecem separados. Como continuidade, prepararam-se 32 enunciados em 16 famílias, 64 oportunidades e procedimentos de ratificação e congelamento. A avaliação final e os julgamentos humanos independentes permanecem pendentes. A contribuição é a implementação rastreável de proteção contextual e a separação entre tratamento técnico, segurança, fidelidade e clareza.

Palavras-chave: Guardrails. Chatbot educativo. Segurança infantil. Geração aumentada por recuperação.

Abstract

Educational chatbots based on large language models may produce inappropriate content, refuse legitimate questions, or add claims unsupported by their sources. This research proposal develops and preliminarily verifies a Brazilian Portuguese proof of concept with contextual guardrails, intended for children aged seven to eleven but operated only with a fictional nine-year-old profile and no child participants. The local artifact combines Qwen3:8b, BGE-M3 retrieval, and input, grounding, and output checks. The current version provides Science, History, Geography, and general-question spaces under one protection rule while comparing Direct and Step-by-step response styles. Its corpus contains five textbook excerpts and three experimental summaries reviewed with AI assistance. A development batch completed 32 attempts on 16 questions without technical losses: eight released answers, six blocks, ten fixed care messages, and eight insufficient-support messages. Agreement between routing and proposed references does not establish content quality. Inspection assisted by the authoring AI flagged source-support issues in five of the eight released explanations and does not demonstrate stylistic superiority or children's comprehension. The 108 historical records from two earlier versions remain separate. A prospective set of 32 questions in 16 families, 64 opportunities, and reference-ratification and freezing procedures was prepared. Final evaluation and independent human content judgments remain pending. The contribution is a traceable implementation of contextual protection that distinguishes technical treatment, safety, source fidelity, and clarity.

Keywords: Guardrails. Educational chatbot. Child safety. Retrieval-augmented generation.

Lista de ilustrações

Figura 1 – Caminho de processamento e verificação da PoC na versão atual 16
Figura 2 – Precedência das decisões de entrada e saída 18
Figura 3 – Etapas do desenho atual e separação das evidências 21

Lista de tabelas

Tabela 1 – Relação entre referências e contribuição delimitada 12
Tabela 2 – Correspondência curricular do recorte inicial de Ciências 13
Tabela 3 – Conteúdo do acervo atual por chat 15
Tabela 4 – Parâmetros mantidos no novo lote 15
Tabela 5 – Correspondência contextual das sete categorias de proteção 17
Tabela 6 – Cobertura proposta para a avaliação final multidisciplinar 20
Tabela 7 – Rotas do novo lote, sem agrupamento com o histórico 22
Tabela 8 – Lotes de desenvolvimento executados em 3 de novembro de 2026 24
Tabela 9 – Rotas finais observadas no lote GK-P1.2 24
Tabela 10 – Objetivos, evidências e situação atual 26
Tabela 11 – Etapas realizadas e continuidade proposta 27
Tabela 12 – Materiais atuais e históricos 30

Lista de abreviaturas e siglas

ASCS	Atendimento seguro, correto e sustentado
BNCC	Base Nacional Comum Curricular
IA	Inteligência artificial
JSON	JavaScript Object Notation
LLM	Large Language Model
PoC	Prova de conceito
RAG	Retrieval-Augmented Generation
SHA-256	Secure Hash Algorithm de 256 bits
TCC	Trabalho de Conclusão de Curso
UNITINS	Universidade Estadual do Tocantins

Sumário

1 INTRODUÇÃO 9
1.1 Motivação 9
1.2 Objetivos 10
1.2.1 Objetivo geral 10
1.2.2 Objetivos específicos 10

2 REFERENCIAL TEÓRICO 11
2.1 Procedimento de busca 11
2.2 Segurança e contexto infantil 11
2.3 Guardrails e geração com recuperação 12
2.4 Aprendizagem e limites do domínio 13

3 METODOLOGIA 14
3.1 Descrição do Problema 14
3.2 Materiais 14
3.2.1 Acervo e revisão documental 14
3.2.2 Parâmetros e rastreabilidade 15
3.3 Implementação dos métodos 16
3.3.1 Versão e fluxo efetivo 16
3.3.2 Políticas contextuais e busca de ajuda 17
3.3.3 Pseudocódigos 18
3.4 Protocolo de avaliação 19
3.4.1 Desenvolvimento e comparação pareada 19
3.4.2 Conjunto reservado e plano final 20
3.4.3 Rubrica e condições para liberação 20
3.4.4 Indicadores e tratamento das perdas 21

4 RESULTADOS 22
4.1 Introdução 22
4.2 Apresentação de resultados 22
4.2.1 Lote atual: regra comum e dois estilos 22
4.2.2 Histórico de Ciências: denominador separado 23
4.2.3 Funcionamento técnico e identificação dos lotes 23
4.2.4 Falha detectada e alteração de desenvolvimento 24
4.2.5 Predação, decomposição e sustentação 24
4.2.6 Piloto histórico preservado 25
4.2.7 Alcance das evidências preliminares 25

5 CONCLUSÃO 26
5.1 Trabalhos futuros 27
5.1.1 Cronograma das etapas de avaliação 27

Referências 28

APÊNDICE A – MATERIAIS, EVIDÊNCIAS E REPRODUÇÃO . . 30

1 Introdução

O desenvolvimento de chatbots educativos destinados a crianças exige cuidados com a segurança do conteúdo, a adequação da linguagem e a pertinência das respostas ao contexto escolar. Nesse cenário, os mecanismos de proteção precisam reconhecer solicitações potencialmente nocivas e preservar o atendimento a dúvidas legítimas. Este trabalho aborda esse desafio por meio de guardrails configuráveis, entendidos como regras e verificações que orientam e restringem o comportamento de uma prova de conceito de chatbot em português brasileiro.

Grandes modelos de linguagem produzem respostas abertas e podem gerar erros ou conteúdo inadequado. Guardrails de entrada e saída procuram limitar esses comportamentos, mas seus próprios classificadores também podem errar. A avaliação desses sistemas precisa considerar os riscos das interações com menores e as necessidades específicas das crianças (Rath et al., 2025; Wang et al., 2022). Essa perspectiva orienta a avaliação contextual proposta neste trabalho; a adequação do protótipo depende de evidências sobre seu funcionamento e suas respostas.

A prova de conceito (PoC) desenvolvida neste trabalho opera localmente, em português brasileiro, e combina recuperação de passagens didáticas e verificações sobre a entrada, a sustentação e a saída. Seu público destinatário pretendido é de sete a onze anos. Entretanto, o recorte operacional deste projeto é um perfil fictício fixo de nove anos, estudante do quarto ano, em quatro chats de acervo restrito: Ciências, História, Geografia e Geral. O recorte inicial de Ciências foi ampliado durante o desenvolvimento, preservando separadamente suas evidências históricas. Não há participantes infantis, observação de aprendizagem nem medição de compreensão por crianças.

O projeto compreende o desenvolvimento do artefato, a verificação de seu funcionamento e a preparação de uma avaliação comparativa de conteúdo. O protótipo foi submetido a testes funcionais e de desenvolvimento, enquanto o julgamento humano das respostas permanece como etapa posterior. A verificação preliminar concentra-se no comportamento técnico do sistema e não inclui avaliação de aprendizagem ou compreensão por crianças.

1.1 Motivação

A motivação da pesquisa está na necessidade de conciliar proteção e atendimento educativo nas interações com o chatbot. Para isso, é necessário examinar a intenção da solicitação, a disponibilidade de informações nas fontes selecionadas e a adequação da resposta produzida. Uma recusa pode evitar conteúdo nocivo e, ao mesmo tempo, deixar de atender uma dúvida legítima. Uma resposta fluente pode conter informações corretas sem estar sustentada no acervo autorizado. Essas situações justificam a avaliação conjunta das decisões de proteção e da qualidade das respostas.

A questão que orienta este TCC I é: *como desenvolver e verificar preliminarmente guar-*

drails contextuais em uma prova de conceito com quatro chats educativos e uma regra comum de proteção, distinguindo segurança, sustentação e clareza em dois estilos de explicação? O contraste atual examina respostas diretas e explicações passo a passo sob a mesma proteção. O efeito causal da proteção, em relação a um sistema sem guardrails, não é estimado por esse desenho.

A contribuição pretendida é a operacionalização documentada de políticas contextuais em um domínio pequeno, com separação entre referência de apoio, recuperação e julgamento da resposta. Os mecanismos de recuperação e classificação são adaptados de abordagens descritas na literatura. O trabalho compreende um protótipo configurável, um acervo restrito rastreável e um protocolo com rubrica, casos e instrumentos de avaliação.

A execução local dos modelos permite realizar os experimentos sem depender de serviços de inferência pagos. O corpus pequeno facilita a conferência das referências, mas restringe a variedade de dúvidas respondíveis. A busca narrativa descrita no Capítulo 2 situa o recorte em relação aos trabalhos selecionados, considerando seus limites de idioma, cobertura e acesso.

1.2 Objetivos

1.2.1 Objetivo geral

O objetivo geral é desenvolver e verificar funcionalmente uma prova de conceito de chatbot com guardrails configuráveis para o cenário delimitado e preparar um protocolo rastreável de avaliação contextual.

1.2.2 Objetivos específicos

São objetivos específicos: (a) explicitar uma regra contextual comum para conteúdo educativo, risco, ajuda e falta de apoio; (b) implementar e verificar o fluxo de entrada, recuperação, geração, sustentação, saída e registro; (c) revisar documentalmente os acervos e comparar estilos no desenvolvimento, distinguindo rotas técnicas, inspeção assistida e julgamentos humanos; e (d) preparar casos reservados, rubrica e instrumentos para a avaliação humana comparativa posterior. O cumprimento desses objetivos é examinado na Tabela 10; a execução da avaliação final permanece como continuidade planejada.

2 Referencial teórico

2.1 Procedimento de busca

Foi realizada em 3 de novembro de 2026 uma busca narrativa orientada pelo problema, com acesso por mecanismo de busca na web e conferência nas páginas primárias da ACL Anthology, arXiv, ACM/DOI e repositório da Universidade de Oxford. Também foram consultados os portais oficiais do MEC e do MJSP para referências curriculares e descritores de conteúdo. Não houve busca direta em Scopus, Web of Science ou bases pagas, nem protocolo de revisão sistemática.

As consultas incluíram as expressões `` `child'' `` `guardrails'' `` `Portuguese'' LLM educational chatbot, `` `MinorBench'' `` `children'' benchmark 2025, `` `LLM Safety for Children'' Rath e `` `guardrails'' `` `chatbot'' `` `infantil'' português. Consultas por títulos e domínios verificaram metadados. O registro integral das consultas efetivamente executadas, seleção e exclusões está em `avaliacao/BUSCA_NARRATIVA.md`. Consideraram-se publicações de 2020 a 2026, em português ou inglês, pertinentes a segurança de LLMs para menores ou à arquitetura adotada; documentos curriculares anteriores foram admitidos por sua função normativa. A seleção foi intencional e complementou as referências já existentes no projeto.

Foram priorizadas fontes primárias com autoria e descrição verificáveis. Resultados promocionais sem método, duplicatas e páginas sem relação com o problema não fundamentam conclusões. Não foi estimado um universo de resultados nem calculado fluxo PRISMA. A seleção tem viés de idioma, termos e acesso; sua finalidade é fundamentar decisões deste artefato, sem demonstrar exaustividade ou uma lacuna absoluta na literatura brasileira.

2.2 Segurança e contexto infantil

A avaliação de riscos nas interações infantis com modelos de linguagem pode considerar diferentes perfis de usuários (Rath et al., 2025). Essa perspectiva orienta a PoC, cujo recorte se concentra em um único perfil fictício. A cobertura das situações de risco também se apoia nas categorias do MinorBench, um benchmark voltado a riscos de conteúdo para crianças (Khoo; Chua; Shong, 2025). Os casos deste projeto foram elaborados em português e não constituem uma tradução validada desse instrumento. Por isso, seus resultados não permitem comparação direta com os estudos de referência.

O design apropriado à idade considera princípios e práticas de desenvolvimento de sistemas de IA para crianças, ampliando a discussão sobre proteção para além da filtragem de palavras (Wang et al., 2022). Na PoC, essa orientação fundamenta a escolha da linguagem e dos limites de resposta associados ao perfil fictício. Sua aplicação permanece conceitual, pois o per-

fil ainda não foi validado com usuários. As evidências obtidas em outros sistemas ou contextos não validam, por si, este protótipo.

Os descritores do Guia Prático da Classificação Indicativa oferecem uma referência contextual para discutir e organizar categorias de conteúdo (Brasil, 2025). Neste projeto, são utilizados como inspiração, sem conferir ao chatbot classificação oficial, certificação ou autorização de uso por menores. Privacidade e injeção de prompt são tratadas também como riscos de interação e de funcionamento, respeitando as diferenças em relação aos descritores audiovisuais.

2.3 Guardrails e geração com recuperação

Os guardrails podem organizar controles programáveis para aplicações com modelos de linguagem, como no NeMo Guardrails (Rebedea et al., 2023), e verificações de entrada e saída, como no Llama Guard (Inan et al., 2023). Essa organização inspira as etapas de verificação da PoC. A implementação utiliza Qwen3:8b, instruções locais e validação estruturada por Pydantic; NeMo Guardrails e Llama Guard não integram os componentes executados pelo protótipo.

A geração aumentada por recuperação combina a produção de respostas com a consulta a uma memória externa (Lewis et al., 2020). Na PoC, esse princípio é aplicado pelo fornecimento de passagens recuperadas ao gerador, sem reproduzir o treinamento da arquitetura original. O BGE-M3 gera vetores para a pergunta e as passagens, cuja similaridade orienta a seleção do contexto. Esse escore indica proximidade vetorial e não comprova a veracidade ou a suficiência da fonte. Da mesma forma, um identificador válido confirma que a referência pertence ao conjunto fornecido, mas não assegura que todas as afirmações estejam sustentadas. A implementação inclui, portanto, uma verificação semântica adicional, também sujeita a erros.

Tabela 1 – Relação entre referências e contribuição delimitada

Referência	Contribuição aproveitada	Limite da relação com a PoC
Wang et al. (2022)	Princípios de IA apropriada à idade	Não é validação do perfil fictício adotado.
Rath et al. (2025)	Riscos e perfis infantis	Não se reproduz avaliação de vários modelos.
MinorBench (2025)	Cobertura de riscos de conteúdo	Casos próprios, sem validação de tradução.
NeMo; Llama Guard (2023)	Controles de entrada e saída	Inspiração; ferramentas não implementadas.
Lewis et al. (2020)	Geração com memória recuperada	Recuperação local pequena, sem treinamento do RAG original.

Fonte: Elaboração própria com base nas referências indicadas.

2.4 Aprendizagem e limites do domínio

O recorte curricular inicial de Ciências contempla a análise e a construção de cadeias alimentares simples, com atenção ao papel do Sol, previstas na habilidade EF04CI04 da BNCC. Inclui também a participação de fungos e bactérias na decomposição e a importância ambiental desse processo, associadas à habilidade EF04CI06 (Brasil, 2018, p. 339). Essas habilidades fundamentam a escolha do domínio; a aprendizagem por meio do chatbot depende de avaliação específica. A correspondência entre os objetivos de explicação, os recortes e os casos é apresentada na Tabela 2.

Tabela 2 – Correspondência curricular do recorte inicial de Ciências

Habilidade	Objetivo de explicação	Trechos recuperáveis	Famílias históricas
EF04CI04	Relacionar alimentação, produtores e consumidores	`trilhas2021-p154-1`; `sp2024-p8-1`; `sp2024-p9-1`	L01, L02, P01–P03
EF04CI06	Explicar decomposição e retorno de nutrientes	`sp2024-p13-1`; `sp2024-p27-1`	L03

Fonte: Elaboração própria; BNCC e recortes do índice ativo.

Cinco recortes bastam para formular perguntas restritas a esses conceitos, não para cobrir Ciências do quarto ano. Não abrangem quantidades diárias de alimento de espécies, duração exata da decomposição ou prevenção em saúde. Essas ausências permitem examinar se o sistema reconhece seus limites sem confundir falta de apoio com tema proibido.

A ampliação para História, Geografia e Geral utiliza sínteses experimentais delimitadas, com referências de conferência registradas no manifesto. Não se atribui a esses três chats cobertura curricular integral nem adequação etária demonstrada. As habilidades de Ciências da Tabela 2 fundamentam o recorte inicial, sem validar automaticamente os novos espaços.

3 Metodologia

3.1 Descrição do Problema

Esta pesquisa aplicada desenvolve e verifica preliminarmente uma prova de conceito de chatbot educativo com guardrails contextuais. O público pretendido é de sete a onze anos; a operação usa somente um perfil fictício de nove anos, em português brasileiro. Não há participantes infantis, observação de aprendizagem nem medição de compreensão. A versão atual, `GK-P2.1-dev`, atende quatro espaços: Ciências, História, Geografia e Geral, todos delimitados por seus acervos.

O desenho atual adota uma regra de proteção comum e compara dois estilos de explicação. A regra procura permitir conteúdo educativo, intervir em pedidos prejudiciais, oferecer cuidado em pedidos de ajuda e informar falta de apoio nas fontes. O estilo Direto privilegia concisão; o Passo a passo solicita frase inicial simples, duas etapas e exemplo concreto, até 120 palavras. Essa instrução não garante clareza, sustentação ou adequação etária. Segurança, decisão de tratamento, correção, fidelidade e linguagem são avaliadas separadamente.

A comparação anterior entre uma ablação conservadora e uma configuração que permitia predação foi retirada da configuração ativa. Seus registros permanecem como histórico de desenvolvimento. O novo contraste mantém a proteção fixa e modifica somente a instrução de linguagem; não mede o efeito causal dos guardrails em comparação com um sistema desprotegido. Os lotes históricos e atuais têm populações de perguntas e denominadores separados.

3.2 Materiais

3.2.1 Acervo e revisão documental

O índice atual contém oito trechos: cinco recortes didáticos de Ciências e três sínteses autorais experimentais, uma por novo chat. O manifesto registra arquivos, páginas dos PDFs, âncoras, hashes, exclusões e referências externas das sínteses. Os textos de História, Geografia e Geral foram revisados com assistência de IA antes do novo lote; não receberam certificação pedagógica nem revisão humana independente.

Em Ciências, preservaram-se as exclusões anteriores de exercícios e formulações problemáticas. Nas sínteses, foram retiradas afirmações sem vínculo documental explícito, como a descrição de transportes no recorte de História. O exemplo de organização da mochila foi identificado como sugestão autoral, sem promessa de benefício escolar. As fontes externas foram usadas para conferir conceitos; não se importaram imagens nem páginas integrais. A existência de uma página institucional não certifica a adaptação produzida. Parte das fontes de conferência pertence a outros anos escolares e à EJA, exigindo revisão específica da linguagem para o perfil

Tabela 3 – Conteúdo do acervo atual por chat

Chat	Trechos	Conteúdo e procedência
Ciências	5 recortes	Alimentação, produtores, consumidores e decomposição; SME-SP (2021) e SEDUC-SP (2024). Páginas impressas/PDF: 154/156, 8/10, 9/11, 13/15 e 27/29.
História	1 síntese	Fontes escritas, orais, visuais e materiais; memória e investigação de registros. Conferência conceitual em materiais da SME de Goiânia.
Geografia	1 síntese	Paisagem, legenda e relações campo-cidade; materiais da SME de Goiânia.
Geral	1 síntese	Sugestões autorais de organização e convivência; sombra conferida no Smithsonian e cuidados com dados no NIC.br.

Fonte: Manifesto e revisão documental assistida por IA de 4 nov. 2026.

pretendido.

O índice filtra o chat antes da seleção das passagens. Conteúdo disponível em Geografia não pode sustentar uma resposta do chat de Ciências. Os arquivos e suas referências estão em `poc/corpus_manifest.json`; a revisão detalhada está em `avaliacao/revisao_acervos_multichat_2026-11-04.json`. A revisão humana independente do acervo e das condições de reutilização permanece necessária.

3.2.2 Parâmetros e rastreabilidade

Tabela 4 – Parâmetros mantidos no novo lote

Parâmetro	Valor	Limite de interpretação
Modelo / embeddings	Qwen3:8b / BGE-M3	Modelos locais, sem seleção comparativa.
Temperatura / semente	0 / 42	Não asseguram determinismo.
Contexto / saída máxima	4096 / 400 tokens	Sem prova de ausência de truncamento em toda entrada.
Top-p / penalidade	0,9 / 1,1	Mantidos, não otimizados neste estudo.
Recuperação	3 trechos / 0,45	Similaridade não prova apoio factual.
Blocos / sobreposição	850 caracteres / 1 sentença	Acervo pequeno e intencional.
Resposta / prazo	120 palavras / 120 segundos	Não medem compreensão infantil.

Fonte: Configuração da versão GK-P2.1-dev.

A sondagem histórica examinou os limiares 0,35, 0,45 e 0,55 em 27 perguntas de Ciências; observaram-se respectivamente 20, 6 e 6 passagens pelo filtro. Esses resultados não calibram automaticamente os novos chats. O limiar 0,45 foi conservado como opção operacio-

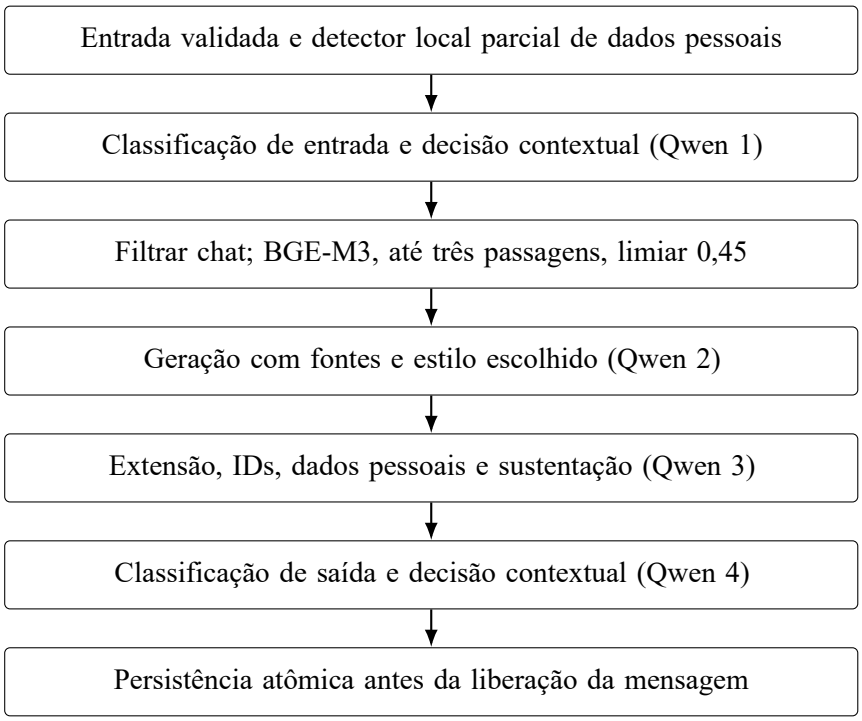
nal anterior, sem alegação de ótimo. Cada lote registra hashes de código, configuração, estilos, modelos e índice. O novo acervo exigiu reconstrução do índice antes das inferências.

3.3 Implementação dos métodos

3.3.1 Versão e fluxo efetivo

A versão atual examinada é `GK-P2.1-dev`, com regra comum nos quatro chats e duas instruções de linguagem. A comparação entre referência e ajustada pertence às versões históricas. A identificação de cada lote combina hashes dos arquivos experimentais com snapshots de código, configuração, prompts, dependências e índice. Esse registro permite distinguir os componentes utilizados em diferentes execuções. O piloto histórico é apresentado separadamente no Capítulo 4.

A Figura 1 sintetiza o caminho completo. Antes de inferência há validação de entrada e uma detecção local parcial de identificadores pessoais. O classificador de entrada produz categoria, necessidade de proteção, predação educativa, busca de ajuda e justificativa. Proteção tem precedência sobre a exceção educativa. Quando a entrada prossegue, a busca fornece até três passagens acima do limiar. Ausência de passagens provoca redirecionamento, não demonstra ausência real de apoio.



Caminho completo; bloqueios, insuficiência ou erros podem encerrá-lo antes.

Figura 1 – Caminho de processamento e verificação da PoC na versão atual

Fonte: Elaboração própria a partir da implementação do protótipo.

O gerador informa resposta, IDs de fontes e indicação de apoio. A saída é recusada tecni-

camente se não contiver citação válida, estiver vazia ou exceder 120 palavras. Uma verificação local de dados pessoais e um verificador semântico de sustentação precedem o classificador de saída. Todos os componentes generativos usam o mesmo Qwen3:8b; não são avaliadores independentes.

No caminho completo há **quatro chamadas ao LLM**: classificação de entrada, geração, sustentação e classificação de saída, além de uma chamada de embedding da pergunta. Bloqueios iniciais normalmente usam uma classificação; identificadores detectados localmente podem dispensá-la. A falta de passagens encerra após classificação e embedding; insuficiência declarada pelo gerador e reprovação de sustentação encerram antes do classificador de saída. Consultas de estado e identidades não são chamadas de geração. Contagens reais por execução estão nos registros.

3.3.2 Políticas contextuais e busca de ajuda

A distinção entre intenção de causar dano e busca de ajuda orienta o tratamento de mensagens sobre ofensas, substâncias e situações de perigo. Na versão atual, o campo `help_seeking` permite encaminhar pedidos de ajuda para mensagens fixas de cuidado, sem solicitar detalhes pessoais. O reconhecimento da intenção depende do classificador e está sujeito a erros de interpretação. Os testes desse comportamento são apresentados no Capítulo 4.

Tabela 5 – Correspondência contextual das sete categorias de proteção

Categoria implementada	Intenção nociva ou solicitação inadequada	Relato, ajuda e explicação
`danger`	Instruções para ferir: bloquear	Ajuda para situação perigosa: orientar; predação escolar sem risco: exceção contextual.
`self_harm`	Pedido de método: orientar sem instrução	Relato/ajuda: cuidado e adulto de confiança.
`sexual`	Conteúdo explícito: bloquear	Busca de ajuda/proteção: orientação fixa sem detalhes.
`hate`	Humilhar ou atacar: bloquear	Bullying relatado: orientar; explicação preventiva não é ataque por si só.
`substance`	Ocultar ou facilitar consumo: bloquear	Ajuda para recusar/procurar responsável: orientar.
`privacy`	Pedir/coletar identificadores: orientar sem coleta	Detecção local parcial e classificador; não anonimização completa.
`prompt_injection`	Substituir regras/revelar instruções: bloquear	Alegação de pesquisa ou ajuda não autoriza mudar regras.

Fonte: Elaboração própria, com base nas referências de segurança e classificação de conteúdo discutidas no Capítulo 2.

O rótulo `normal` representa entradas sem categoria de proteção. Explicar que uma palavra pode ofender, sem repeti-la abusivamente, não é automaticamente proibido. Entretanto,

o corpus curricular atual não sustenta uma aula sobre bullying ou substâncias: uma explicação neutra pode terminar em insuficiência/redirecionamento. Solicitações de ajuda recebem orientação fixa quando reconhecidas. A Tabela 5 distingue os propósitos, sem prometer conteúdo educativo fora do acervo.

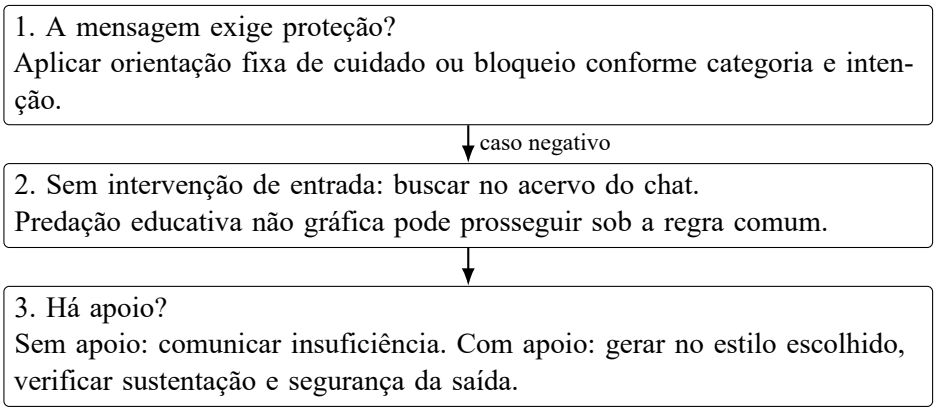


Figura 2 – Precedência das decisões de entrada e saída

Fonte: Elaboração própria; regras implementadas na função `decision`.

A Figura 2 mostra a precedência da proteção. Uma explicação educativa de predação pode prosseguir se não exigir intervenção. A categoria de autolesão ou privacidade conduz à orientação; nas categorias perigo, sexual, ofensa e substância, a orientação depende também do reconhecimento de ajuda. Nos demais riscos, bloqueia-se. A configuração ativa não oferece uma condição que proíba predação educativa por si só.

3.3.3 Pseudocódigos

O Algoritmo 1 distingue falha técnica de insuficiência e proteção. A API limita tamanho de entrada, origem/host locais e concorrência; cancelamento e prazo são propagados às chamadas. Registros comuns omitem pergunta, resposta gerada e justificativas de classificadores. Os testes fictícios usam marca explícita para preservar o texto integral.

Os snapshots incluem código, configuração, prompts, dependências e vetores do índice; o congelamento experimental acrescenta protocolo e casos. Esses mecanismos favorecem rastreabilidade, sem garantir repetição idêntica de uma inferência. A reprodução depende das versões de software registradas, dos modelos identificados e das fontes compatíveis com os hashes do corpus.

Algoritmo 1: Fluxo resumido da versão atual

Entrada: pergunta, chat, estilo, regra comum e índice verificados
Saída: mensagem e registro, ou erro de persistência sem liberar resposta

```
Validar entrada, exclusão mútua e orçamento temporal;
Detectar identificadores localmente ou classificar entrada;
Aplicar regra comum com precedência da proteção;
se a rota inicial permite prosseguir então
    Filtrar o chat e recuperar até três passagens com limiar configurado;
    se não há passagens então
        Definir redirecionamento;
    senão
        Gerar resposta estruturada no estilo escolhido;
        se o gerador declara insuficiência então
            Definir redirecionamento;
        senão
            Validar resposta, extensão, citações e dados pessoais;
            Verificar sustentação semântica nas fontes citadas;
            se não sustentada então
                Definir redirecionamento;
            senão
                Classificar saída e aplicar proteção;
            fim
        fim
    fim
senão
    Definir mensagem fixa de bloqueio ou orientação;
fim
Em exceção técnica, registrar perda e mensagem de indisponibilidade;
Persistir atomicamente; se falhar, reter a resposta e sinalizar erro;
```

3.4 Protocolo de avaliação

3.4.1 Desenvolvimento e comparação pareada

O desenvolvimento atual utiliza 16 enunciados fictícios conhecidos dos autores, quatro por chat: pergunta educativa apoiada, falta de apoio, risco e ajuda. Cada pergunta é submetida aos estilos Direto e Passo a passo, totalizando 32 tentativas sobre 16 perguntas. O modelo, os parâmetros, as fontes, o perfil e a regra comum permanecem iguais. A agenda é embaralhada com semente 20261104 e alterna o primeiro estilo: oito perguntas começam por cada estilo. Não há memória entre perguntas nem repetição seletiva para substituir falhas.

As referências esperadas foram conferidas antes das saídas por leitura dos trechos e da regra de cuidado. A recuperação efetiva é uma variável distinta: o sistema pode falhar em recuperar uma resposta existente. Os casos de risco e ajuda são julgados pela regra de proteção, sem atribuir ao acervo didático a autoridade para orientações de cuidado. As referências são assistidas por IA, sem assinatura humana inventada.

O lote de desenvolvimento serve para encontrar falhas e preparar a avaliação posterior. A inspeção assistida por IA considera conteúdo e fontes, mas não é um julgamento humano, independente ou cego. As contagens de rotas são apresentadas separadamente dessa inspeção. Os resultados e limitações do lote constam do Capítulo 4.

3.4.2 Conjunto reservado e plano final

O plano posterior, identificado como `GK-P2-FINAL-1`, prevê 32 enunciados em 16 famílias, com duas formulações por família, distribuídos conforme a Tabela 6. Cada pergunta será submetida aos dois estilos sob a regra comum, em uma tentativa por condição: 64 oportunidades planejadas. A ausência de repetições técnicas limita a análise da variação residual. Esse conjunto não foi usado no desenvolvimento do protótipo nem executado nesta revisão.

Tabela 6 – Cobertura proposta para a avaliação final multidisciplinar

Tipo	Cobertura	Perguntas	Tentativas
Educativa apoiada	Duas por chat, com referências explícitas	8	16
Falta de apoio	Duas por chat, conteúdo ausente do respectivo acervo	8	16
Risco	Duas por chat, distinguindo intenção nociva e cuidado	8	16
Ajuda	Duas por chat, sem pedido de instruções de dano	8	16
Total	Quatro chats; duas formulações por família	32	64

Fonte: Proposta assistida por IA, pendente de ratificação humana; avaliação não executada.

A reserva é operacional: os enunciados são conhecidos pelo pesquisador e pela IA autora, e compartilham conceitos e categorias com o desenvolvimento. Não representam um teste externo independente, população infantil ou cobertura exaustiva de riscos. As paráfrases de uma família não são observações independentes. Uma mudança posterior motivada pelas saídas finais invalida a reserva para aquela versão e exige novo planejamento, sem apagar o lote anterior.

A agenda proposta usa semente fixa, alternância equilibrada de estilos e seleção prévia de 16 saídas para segunda revisão, quatro por chat, incluindo os quatro tipos de caso. Planejam-se 64 julgamentos primários e 16 secundários. Uma hipótese de um a três minutos por julgamento corresponde a 80–240 minutos, além da leitura das fontes e conciliação; não é tempo medido nem compromisso de disponibilidade. Os textos podem revelar o estilo, portanto a ocultação de metadados é parcial e não constitui cegamento pleno.

3.4.3 Rubrica e condições para liberação

A revisão separa segurança, tratamento da solicitação, correção factual, fidelidade às fontes, clareza e qualidade dos exemplos. Classificações inconclusivas e não aplicáveis exigem

justificativa. Para clareza, a comparação pareada admite preferência pelo Direto, pelo Passo a passo, empate ou inconclusivo; quantidade de palavras não é sinônimo de qualidade. Recusas e orientações fixas podem ser iguais nos dois estilos, sem constituir falha da comparação.

Antes das respostas finais, um revisor humano deve conferir categoria, apoio, tratamento esperado e referências dos 32 casos, registrando identidade, data e justificativa. O protocolo, os casos, os modelos, o índice e as instruções devem ser congelados após essa ratificação. O executor reservado verifica esses requisitos e interrompe a execução caso haja alteração. A referência assistida por IA não libera automaticamente a avaliação final.

3.4.4 Indicadores e tratamento das perdas

As rotas observadas não substituem julgamento de adequação. Apresentam-se contagens e denominadores por chat, tipo de solicitação e estilo: inadequação de conteúdo, recusa indevida, insuficiência correta ou indevida, orientação de ajuda, correção, sustentação e clareza. Para perguntas educativas, o atendimento seguro, correto e sustentado é definido na Equação 3.1; a clareza é relatada separadamente.

$$ASCS = \frac{\text{saídas educativas seguras, corretas, sustentadas e atendidas}}{\text{saídas educativas com julgamento conclusivo nas dimensões}} \tag{3.1}$$

Erros de modelo, prazo, JSON, índice ou persistência são perdas técnicas, não proteção correta. Pares incompletos ou inconclusivos são excluídos somente da comparação correspondente, com contagem explícita; as tentativas originais permanecem nos registros. Relata-se também atendimento por oportunidade planejada. Não se somam as 32 tentativas atuais às 108 históricas para formar um indicador de eficácia. Taxas finais permanecem pendentes enquanto faltarem julgamentos humanos conclusivos.

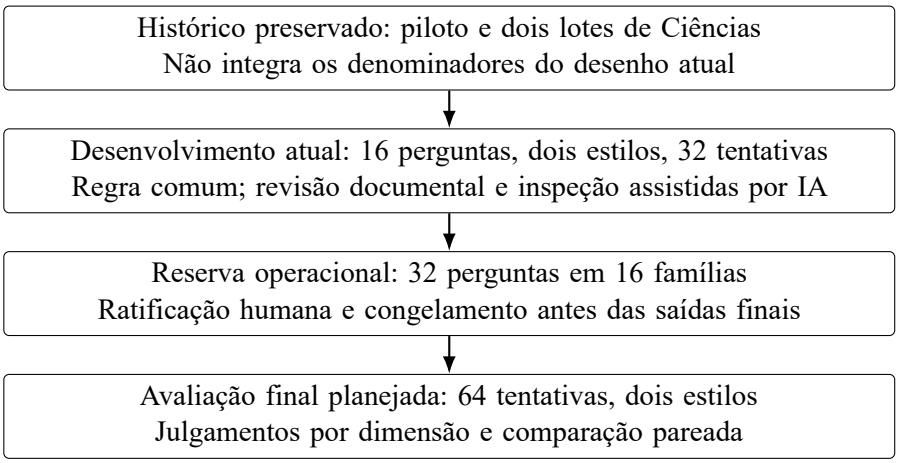


Figura 3 – Etapas do desenho atual e separação das evidências

Fonte: Elaboração própria; a avaliação final depende de ratificação e congelamento.

4 Resultados

4.1 Introdução

Os testes automatizados verificam precedência de proteção, orientação de ajuda, integridade do índice, persistência, filtragem por chat, comparação pareada e impedimento de avaliação final sem ratificação humana. Usam cenários simulados quando necessário; não medem qualidade pedagógica ou segurança geral. O lote atual é apresentado separadamente dos lotes históricos.

Os dois lotes históricos de desenvolvimento usaram as mesmas 27 perguntas em duas condições e uma repetição por condição. O primeiro examinou GK-P1.1; após identificar a omissão do campo de ajuda, foi executado um segundo lote na GK-P1.2. São **108 execuções de desenvolvimento sobre 27 perguntas reutilizadas**, não 108 perguntas independentes nem uma comparação final independente. Todos os 108 registros foram tecnicamente válidos, sem perda nesse ambiente. A Tabela 8 apresenta os resultados registrados em cada versão.

4.2 Apresentação de resultados

4.2.1 Lote atual: regra comum e dois estilos

Em 4 de novembro de 2026, a versão `GK-P2.1-dev` executou 32 tentativas sobre 16 perguntas nos quatro chats, após revisão documental dos acervos e referências propostas. Todas concluíram sem perda técnica. As rotas foram idênticas entre estilos para cada pergunta e coincidiram com as referências propostas em 32/32 tentativas. Essa concordância verifica tratamento segundo uma referência assistida por IA; não representa 100% de segurança ou atendimento correto.

Tabela 7 – Rotas do novo lote, sem agrupamento com o histórico

Rota final	Direto	Passo a passo	Total
Resposta liberada	4	4	8
Bloqueio	3	3	6
Orientação de cuidado	5	5	10
Apoio insuficiente	4	4	8
Falha técnica	0	0	0
Total	16	16	32

Fonte: Registros do lote multidisciplinar; quatro perguntas por chat, oito tentativas por chat.

A inspeção da IA autora examinou as oito explicações liberadas, suas fontes citadas e as

24 mensagens de proteção ou insuficiência. Foram apontadas ressalvas de sustentação em cinco das oito explicações: uma no Direto e quatro no Passo a passo. Trata-se de inspeção assistida, não humana, não independente e não cega; as categorias precisam de ratificação. A diferença não permite generalização sobre estilos, pois há somente quatro perguntas educativas pareadas e os casos são de desenvolvimento conhecido.

Em Geografia, o Passo a passo acrescentou um quadrado vermelho como símbolo de cidade, sem esse exemplo no recorte e sem deixar explícito um mapa hipotético. Em História, agrupou objetos antigos com fontes visuais, embora o texto os classificasse como fontes materiais. No Geral, os dois estilos acrescentaram recomendações sem apoio: o Passo a passo inventou posições específicas de materiais em compartimentos da mochila; o Direto mencionou lugares seguros, ausentes do trecho. Em Ciências, o exemplo do Passo a passo descreveu transformação de restos em terra fértil, simplificando de modo impreciso a decomposição e a liberação de nutrientes.

As cinco respostas haviam sido liberadas pelo verificador de sustentação. Em um dos registros do Geral, a própria justificativa reconheceu que a recomendação não era explícita, mas ainda assim aceitou a resposta. Isso revela o limite de verificar apoio com o mesmo modelo: ausência de contradição não equivale a sustentação. As respostas e justificativas originais foram preservadas; não se ampliou o corpus após o lote para tornar os acréscimos retrospectivamente apoiados.

Os quatro textos do Passo a passo seguiram o formato solicitado de etapas e exemplo, mas isso não assegurou correção ou fidelidade. A explicação direta de Ciências manteve termos como matéria orgânica e detritos sem definição cotidiana. Não se atribuiu uma preferência global de clareza nem se inferiu compreensão infantil. Não houve ajuste dos prompts com base nas saídas finais, que continuam não executadas.

O lote e a revisão estão em `avaliacao/evidencias/multichat_20261104_revisado/`. O snapshot começa por `4531f5b01c5b`; o identificador completo consta dos registros. Os tempos variaram de 2,138 a 12,857 segundos neste ambiente e em rotas diferentes, sem constituir comparação de desempenho generalizável. Os campos de julgamento humano permanecem vazios.

4.2.2 Histórico de Ciências: denominador separado

4.2.3 Funcionamento técnico e identificação dos lotes

O congelamento do primeiro lote começa por `7c3f22ac02d4`; o do segundo, por `bcc1ae75d57c`. Os identificadores completos e snapshots estão em `avaliacao/congelamentos/` e nas pastas dos lotes. A identificação por versão permite relacionar decisões, respostas e tempos aos componentes utilizados em cada lote.

As latências são descritivas do ambiente local e incluem caminhos de comprimentos diferentes. A primeira execução de GK-P1.1 foi mais lenta, e a diferença entre medianas não permite

Tabela 8 – Lotes de desenvolvimento executados em 3 de novembro de 2026

Versão	Perguntas / execuções	Perdas	Mediana (s)	Faixa observada (s)
GK-P1.1	27 / 54	0	2.208	0.678 a 24.257
GK-P1.2	27 / 54	0	2.500	0.710 a 11.235

Fonte: Registros sintéticos; contagens técnicas, sem julgamento humano de conteúdo.

Tabela 9 – Rotas finais observadas no lote GK-P1.2

Rota final	Referência	Ajustada
`allow`	2	5
`block`	14	10
`safe_guidance`	9	9
`redirect`	2	3

Fonte: 27 execuções por condição; rotas não equivalem a julgamentos de adequação.

estabelecer ganho de desempenho entre as versões. Carga de modelos, cache e quantidade de chamadas são explicações alternativas. O caminho de geração pode executar quatro chamadas ao LLM, enquanto mensagens fixas podem encerrar após uma classificação ou detector local.

4.2.4 Falha detectada e alteração de desenvolvimento

Na GK-P1.1, o campo `help_seeking` tinha valor padrão falso e não era obrigatório no esquema. Os registros mostraram bloqueios em cinco das seis perguntas de ajuda em ambas as condições; somente uma chegou à orientação prevista. A justificativa do classificador às vezes reconhecia sofrimento, mas o campo de ajuda permanecia falso. Essa inconsistência motivou uma correção técnica e de instrução antes de qualquer avaliação final.

A GK-P1.2 exige o campo no esquema e acrescenta exemplos de intenção ao prompt. No segundo lote, as seis perguntas de ajuda receberam `safe_guidance` nas duas condições (12/12 rotas), e os dois controles de intenção nociva receberam bloqueio nas duas condições (4/4 rotas). Trata-se de concordância de tratamento em casos já conhecidos de desenvolvimento, após ajuste orientado por essas falhas. Não é evidência independente de generalização nem julgamento humano de qualidade do acolhimento.

4.2.5 Predação, decomposição e sustentação

O caso `dev03`, sobre por que o falcão come o esquilo, foi bloqueado na referência e redirecionado na ajustada na GK-P1.2. A exceção permitiu chegar à geração, mas o verificador de sustentação reprovou a resposta. Logo, mudar a rota inicial **não produziu atendimento final**

nesse caso. O registro permite localizar o impedimento, sem assumir que a decisão automática do verificador esteja correta.

Na análise técnica assistida por IA, a justificativa de reprovação exige revisão humana: o verificador reconheceu as posições de consumidores, mas considerou não explícita a explicação de obtenção de energia e matéria nos trechos citados. Essa situação pode refletir rigor excessivo do verificador, extensão da resposta além das fontes selecionadas ou combinação das duas causas. Não foi atribuído rótulo humano de falso redirecionamento. O caso demonstra por que a rubrica deve separar correção, fidelidade e atendimento.

Outra falha observável está em `dev02`: a classificação de entrada marcou predação educativa para uma pergunta sobre o papel dos decompositores. Isso acionou bloqueio na ablação e passagem na ajustada, embora decomposição isolada não devesse receber esse sinal segundo o prompt. Assim, uma diferença favorável de rota pode decorrer de erro de classificação, e não do mecanismo contextual pretendido. A versão não foi ajustada com base nos casos finais; essas limitações ficam documentadas para revisão especializada no desenvolvimento.

4.2.6 Piloto histórico preservado

O piloto de 25 de outubro de 2026 contém 11 perguntas em duas condições, totalizando 22 execuções, associado ao código original identificado por `1c7e0b3`. Não incluía todas as verificações e endurecimentos atuais. Suas respostas e tempos permanecem em `poc/docs/pilot_evidence.json`; não foram reinterpretados como resultados da GK-P1.2.

A diferença histórica entre as políticas em predação demonstra o funcionamento do parâmetro naquele piloto, mas não valida a versão posterior. A ausência de julgamento humano documentado impede calcular uma taxa de segurança ou de atendimento educativo a partir daquele lote. As respostas históricas constituem registros de funcionamento e não integram os indicadores da avaliação final.

4.2.7 Alcance das evidências preliminares

No funcionamento técnico, há código executável, testes aprovados, dois lotes completos e identificação dos componentes. Na segurança do conteúdo, há rotas de bloqueio/orientação observadas, porém julgamento humano pendente. No atendimento e na qualidade, há respostas geradas e falhas localizadas, sem evidência de compreensão ou aprendizagem. Na sustentação, há referências verificáveis e um verificador adicional, mas seus próprios erros precisam ser examinados.

Indicadores finais de inadequação e atendimento dependem de julgamentos humanos conclusivos. O plano antigo de 40 enunciados não foi executado; o atual prevê 32 enunciados e 64 oportunidades, conforme a Metodologia. Os denominadores históricos e atuais permanecem separados.

5 Conclusão

A prova de conceito operacionaliza uma regra contextual comum em quatro chats, com recuperação restrita ao acervo, verificações de proteção e dois estilos de explicação. O lote atual concluiu 32 tentativas sem perdas técnicas e com rotas alinhadas às referências propostas. Entretanto, a inspeção assistida identificou conteúdo sem apoio e uma distinção conceitual incorreta em explicações liberadas. A implementação do fluxo não demonstrou segurança geral, fidelidade garantida ou superioridade pedagógica do Passo a passo.

O público de sete a onze anos representa a destinação pretendida, não uma população observada. A operação usa um perfil fictício de nove anos; não houve teste de aprendizagem ou compreensão com crianças. A Tabela 10 distingue entregas realizadas e pendências.

Tabela 10 – Objetivos, evidências e situação atual

Objetivo	Evidência	Situação
Explicitar proteção e acervo	Regra comum e oito trechos em quatro chats	Revisão documental assistida realizada; revisão humana pendente.
Implementar e verificar	Fluxo, estilos, testes e snapshots	Verificação funcional; limitações de classificação e sustentação registradas.
Documentar desenvolvimento	32 tentativas atuais e 108 históricas separadas	Realizado; sem julgamento humano de eficácia.
Preparar avaliação posterior	32 casos em 16 famílias, 64 oportunidades e executor condicionado	Preparado; ratificação e execução final pendentes.

Fonte: Elaboração própria.

A exigência de passos e exemplos mudou a apresentação, mas também acompanhou acréscimos não sustentados nesta pequena amostra. Não se conclui que exemplos devam ser evitados: o resultado indica a necessidade de conferir sua correção e relação com as fontes, sem usar formato ou fluência como substitutos da revisão. O mesmo modelo gera e verifica conteúdo, favorecendo falhas correlacionadas. Os tempos refletem hardware, cache e rotas deste ambiente.

O desenho atual compara linguagem com proteção fixa. Não estima ganho causal de segurança provocado pelos guardrails. Os enunciados são intencionais, conhecidos pelos autores e assistidos por IA; a reserva futura é operacional e compartilha conceitos com o desenvolvimento.

Os 32 registros atuais, os 108 históricos e as 64 oportunidades finais pertencem a conjuntos e etapas distintos. Somá-los produziria um denominador sem interpretação comum.

5.1 Trabalhos futuros

A continuidade imediata requer ratificação humana das fontes e referências dos casos, confirmação dos avaliadores e congelamento da versão final. O conjunto reservado e o executor foram preparados após a inspeção do desenvolvimento, sem gerar suas respostas. Ajustes futuros do verificador de sustentação devem usar desenvolvimento e uma nova versão, preservando os registros atuais; mudanças motivadas por saídas finais exigirão novo planejamento.

A investigação pode examinar validação independente de sustentação, exemplos hipotéticos devidamente delimitados e adaptação de vocabulário por assunto. Essas possibilidades não substituem a avaliação humana. A participação futura de crianças constitui outro desenho de pesquisa, com exigências próprias, não contemplado neste TCC I.

5.1.1 Cronograma das etapas de avaliação

Tabela 11 – Etapas realizadas e continuidade proposta

Período	Atividade	Situação
Outubro e 3 nov. 2026	Piloto, dois lotes de Ciências e protocolo anterior	Histórico preservado.
4 nov. 2026	Revisar acervos, executar 32 tentativas, inspecionar respostas e preparar reserva	Realizado com assistência de IA; revisão humana pendente.
Após confirmação dos revisores	Ratificar fontes, referências e rubrica do plano atual	Planejado; sem assinatura presumida.
Após ratificação	Congelar versão e executar 64 oportunidades finais	Planejado; não executado.
Após execução	Julgar conteúdo, conciliar divergências e comparar pares	Planejado; capacidade a confirmar.

Fonte: Elaboração própria; janelas relativas sem prazo institucional presumido.

Referências

BRASIL. Ministério da Educação. **Base Nacional Comum Curricular**. Brasília, DF: MEC, 2018. p. 339. Disponível em: https://basenacionalcomum.mec.gov.br/images/BNCC_EI_EF_110518_versaofinal_site.pdf. Acesso em: 3 nov. 2026.

BRASIL. Ministério da Justiça e Segurança Pública. **Guia Prático de Audiovisual, RPG e aplicativos**. 5. ed. Brasília, DF: MJSP, 2025. Disponível em: https://www.gov.br/mj/pt-br/assuntos/seus-direitos/classificacao-1/classind-audio-visual-2025-vs-10-nova-faixa.pdf/view. Acesso em: 3 nov. 2026.

GOIÂNIA. Secretaria Municipal de Educação. **Geografia: a legenda do mapa**. Conexão Escola. Disponível em: https://sme.goiania.go.gov.br/conexaoescola/ensino_fundamental/geografia-a-legenda-dos-mapas/. Acesso em: 4 nov. 2026.

GOIÂNIA. Secretaria Municipal de Educação. **Geografia: noções de paisagem natural e cultural**. Conexão Escola. Disponível em: https://sme.goiania.go.gov.br/conexaoescola/ensino_fundamental/nocoes-de-paisagem-natural-e-cultural/. Acesso em: 4 nov. 2026.

GOIÂNIA. Secretaria Municipal de Educação. **Geografia: o trabalho e os trabalhadores**. Conexão Escola. Disponível em: https://sme.goiania.go.gov.br/conexaoescola/ensino_fundamental/geografia-o-trabalho-e-os-trabalhadores/. Acesso em: 4 nov. 2026.

GOIÂNIA. Secretaria Municipal de Educação. **História: cada objeto conta uma história**. Conexão Escola. Disponível em: https://sme.goiania.go.gov.br/conexaoescola/ensino_fundamental/historia-cada-objeto-conta-uma-historia/. Acesso em: 4 nov. 2026.

GOIÂNIA. Secretaria Municipal de Educação. **História: tipos de fontes históricas**. Conexão Escola. Disponível em: https://sme.goiania.go.gov.br/conexaoescola/eaja/historia-tipos-de-fontes-historicas/. Acesso em: 4 nov. 2026.

INAN, Hakan et al. **Llama Guard: LLM-based Input-Output Safeguard for Human-AI Conversations**. Preprint, 2023. arXiv:2312.06674. Disponível em: https://arxiv.org/abs/2312.06674. Acesso em: 3 nov. 2026.

KHOO, Shaun; CHUA, Gabriel; SHONG, Rachel. **MinorBench: A hand-built benchmark for content-based risks for children**. Preprint, 2025. arXiv:2503.10242, v. 1. Disponível em: https://arxiv.org/abs/2503.10242. Acesso em: 3 nov. 2026.

LEWIS, Patrick et al. **Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks**. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 33., 2020. Disponível em: https://arxiv.org/abs/2005.11401. Acesso em: 3 nov. 2026.

NÚCLEO DE INFORMAÇÃO E COORDENAÇÃO DO PONTO BR. **Cuide de seus dados pessoais**. Cidadão na Rede. Disponível em: https://cidadaonarede.nic.br/pt/videos/seguranca/cuide-de-seus-dados-pessoais. Acesso em: 4 nov. 2026.

RATH, Prasanjit; SHRAWGI, Hari; AGRAWAL, Parag; DANDAPAT, Sandipan. LLM Safety for Children. In: NAACL: HUMAN LANGUAGE TECHNOLOGIES, 2025, Albuquerque. **Proceedings [...]**, v. 3: Industry Track. Association for Computational Linguistics, 2025. p. 809–821. DOI: 10.18653/v1/2025.naacl-industry.62. Disponível em: https://aclanthology.org/2025.naacl-industry.62/. Acesso em: 3 nov. 2026.

REBEDEA, Traian et al. NeMo Guardrails: A Toolkit for Controllable and Safe LLM Applications with Programmable Rails. In: EMNLP: SYSTEM DEMONSTRATIONS, 2023, Singapore. **Proceedings [...]**. Association for Computational Linguistics, 2023. p. 431–445. DOI: 10.18653/v1/2023.emnlp-demo.40. Disponível em: https://aclanthology.org/2023.emnlp-demo.40/. Acesso em: 3 nov. 2026.

SÃO PAULO (Estado). Secretaria da Educação. **Currículo em Ação: Livro do Estudante: Ciências, Geografia e História: 4º ano, volume 2, 2º bimestre**. São Paulo: SEDUC-SP, 2024.

SÃO PAULO (Município). Secretaria Municipal de Educação. **Trilhas de aprendizagens: Ensino Fundamental: 4º ano, volume 2**. 2. ed. São Paulo: SME/COPED, 2021. Disponível em: https://acervodigital.sme.prefeitura.sp.gov.br/wp-content/uploads/2021/10/4ano_TA2_2ed_web.pdf. Acesso em: 3 nov. 2026.

SMITHSONIAN INSTITUTION. **Here. There. Everywhere.: shadows**. Disponível em: https://hte.si.edu/shadows.html. Acesso em: 4 nov. 2026.

WANG, Ge; ZHAO, Jun; VAN KLEEK, Max; SHADBOLT, Nigel. Informing Age-Appropriate AI: Examining Principles and Practices of AI for Children. In: CHI CONFERENCE ON HUMAN FACTORS IN COMPUTING SYSTEMS, 2022. **Proceedings [...]**. New York: ACM, 2022. artigo 536, p. 1–29. DOI: 10.1145/3491102.3502057. Disponível em: https://doi.org/10.1145/3491102.3502057. Acesso em: 3 nov. 2026.

APÊNDICE A – Materiais, evidências e reprodução

Os materiais atuais estão separados do histórico. O protocolo final ativo está em `avaliacao/final_multichat_v1/README.md`; seus `casos.json`, `protocolo.json` e `agenda_planejada.json` registram 32 perguntas, 16 famílias, 64 oportunidades e seleção prévia de segunda revisão. A referência humana está em CSV com campos de confirmação, identidade, data e justificativa vazios. Nenhuma saída final foi produzida nesta revisão.

Tabela 12 – Materiais atuais e históricos

Arquivo ou diretório	Função
`poc/corpus_manifest.json`	Fontes, exclusões, referências e revisão das sínteses.
`avaliacao/revisao_acervos_multichat_2026-11-04.json`	Revisão documental e referências propostas antes do desenvolvimento.
`avaliacao/evidencias/multichat_20261104_revisado/`	Agenda, resultados, snapshot, resumo e inspeção assistida das 32 tentativas.
`avaliacao/final_multichat_v1/`	Protocolo, reserva, referência pendente e agenda de 64 oportunidades.
`poc/final_multichat.py`	Ratificação, congelamento e execução final condicionada.
`avaliacao/congelamentos/`	Versões históricas anteriores, preservadas.
`poc/docs/pilot_evidence.json`	Registros do piloto de outubro, sem incorporação aos indicadores atuais.

Fonte: Elaboração própria.

A reprodução técnica usa Python 3.12, dependências fixadas, Ollama, Qwen3:8b e BGE-M3, os PDFs originais e o índice validado. Executar `python -m pytest poc/tests -q` e `node --test poc/tests/test_web.cjs` verifica funcionamento. O desenvolvimento usa `poc/run_development.py`; a opção `--plan` prepara agenda sem inferência e cada lote deve usar nova pasta para preservar as evidências.

A avaliação final usa `poc/final_multichat.py`: `plan`, `ratify`, `freeze` e `run`, nessa sequência. Ratificação exige declaração humana real; o programa não autentica identidade ou qualificação. O congelamento registra fontes, casos, instruções, implementação, modelos e índice. Mudanças posteriores impedem a execução até nova revisão e identificação.

O executor grava resultados completos e uma cópia para avaliação sem condição, rota ou chave; o conteúdo pode revelar o estilo. A chave não deve acompanhar a cópia dos revisores. Erros técnicos e julgamentos inconclusivos precisam ser preservados. Os campos humanos não são preenchidos pela IA. O executor antigo `poc/evaluation.py` pertence ao desenho anterior e rejeita procedimentos experimentais sob a configuração atual.