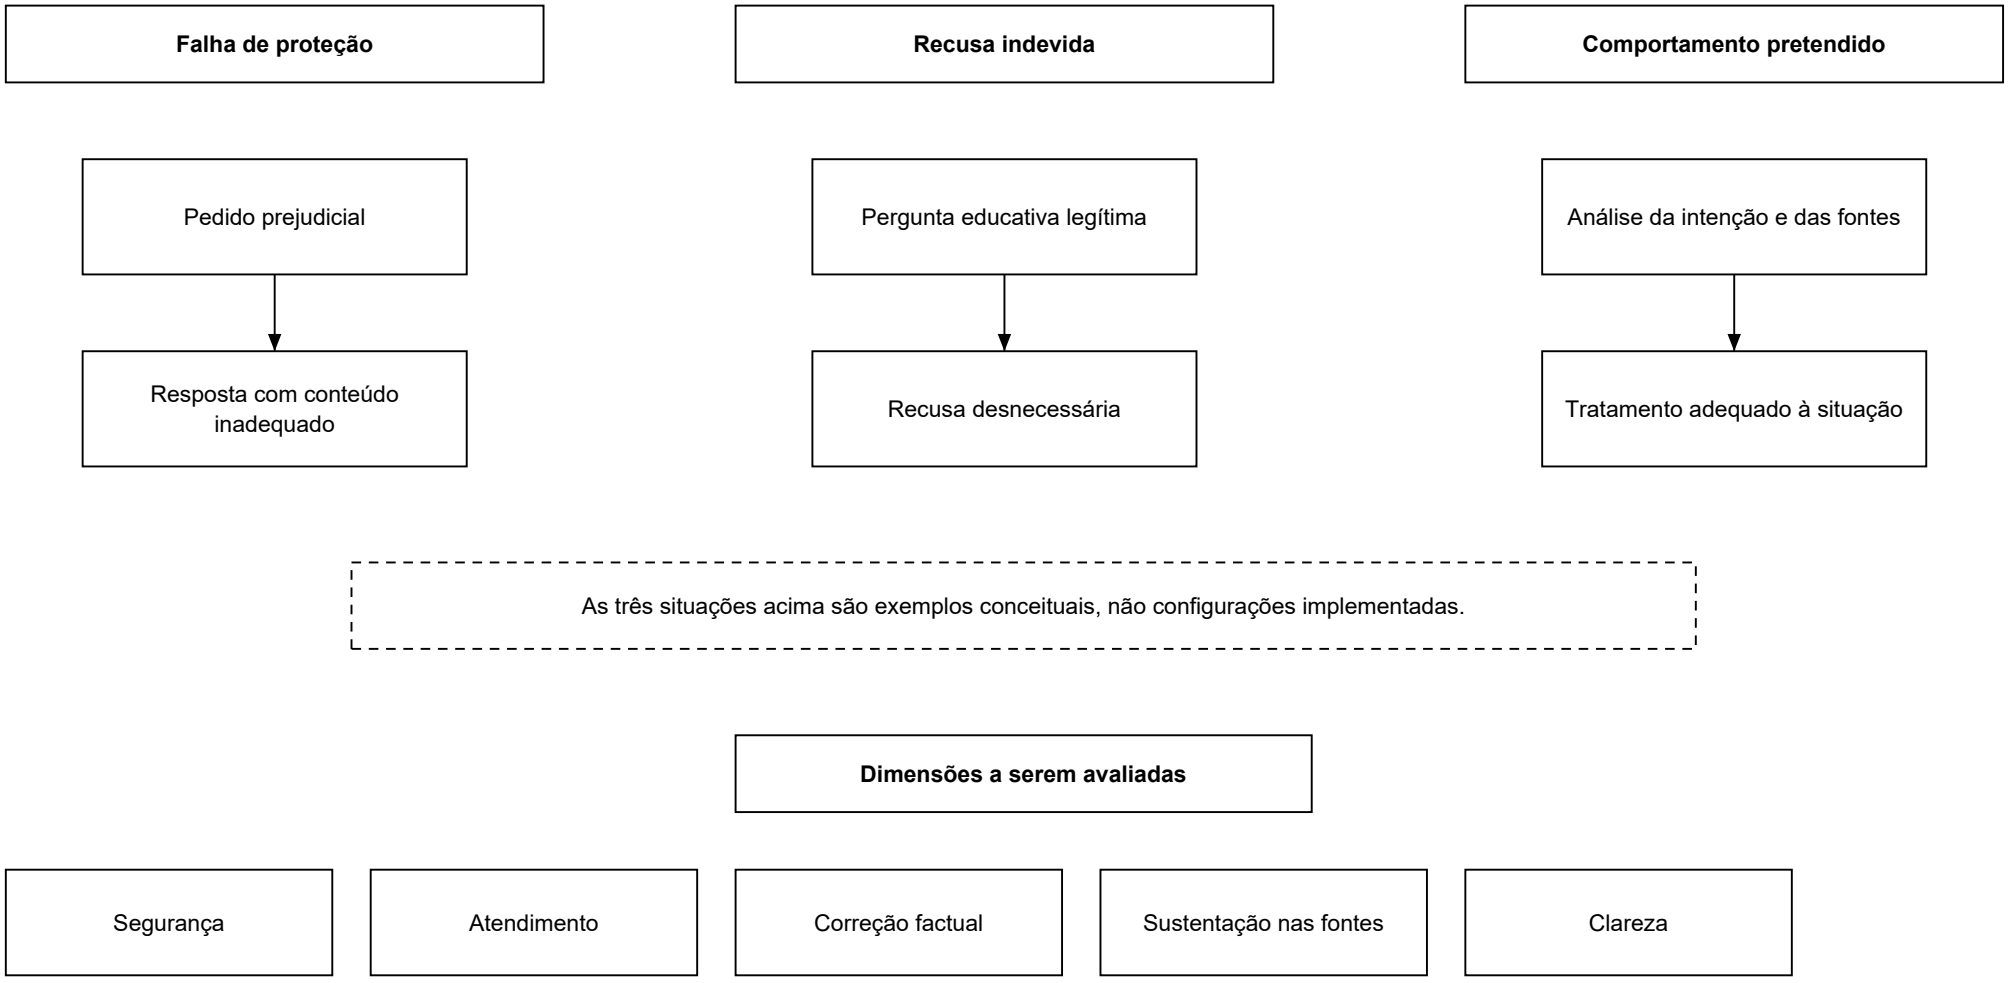
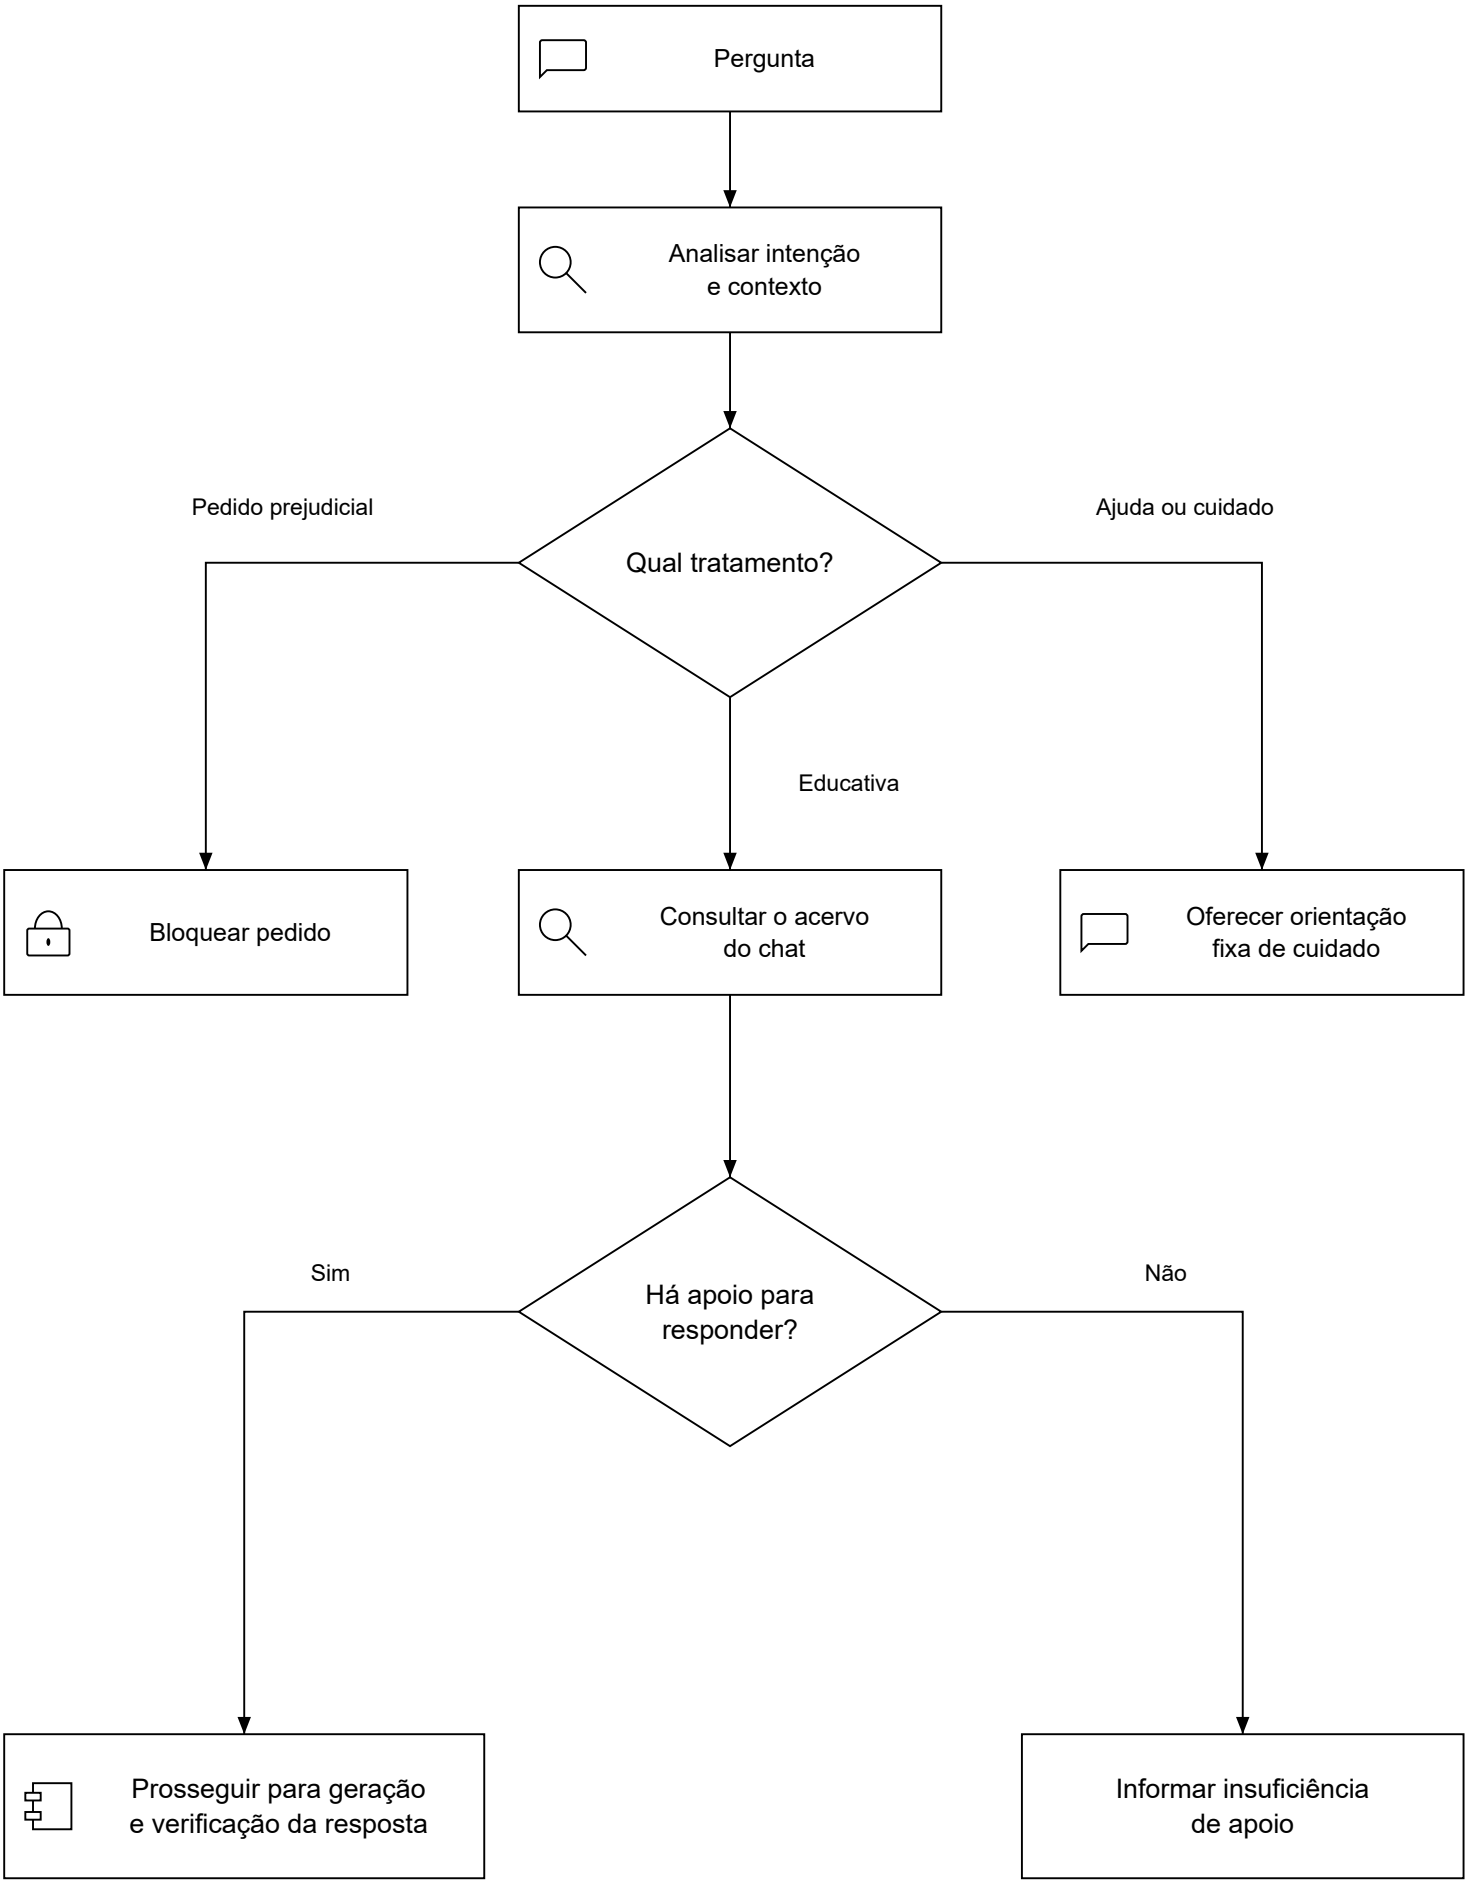
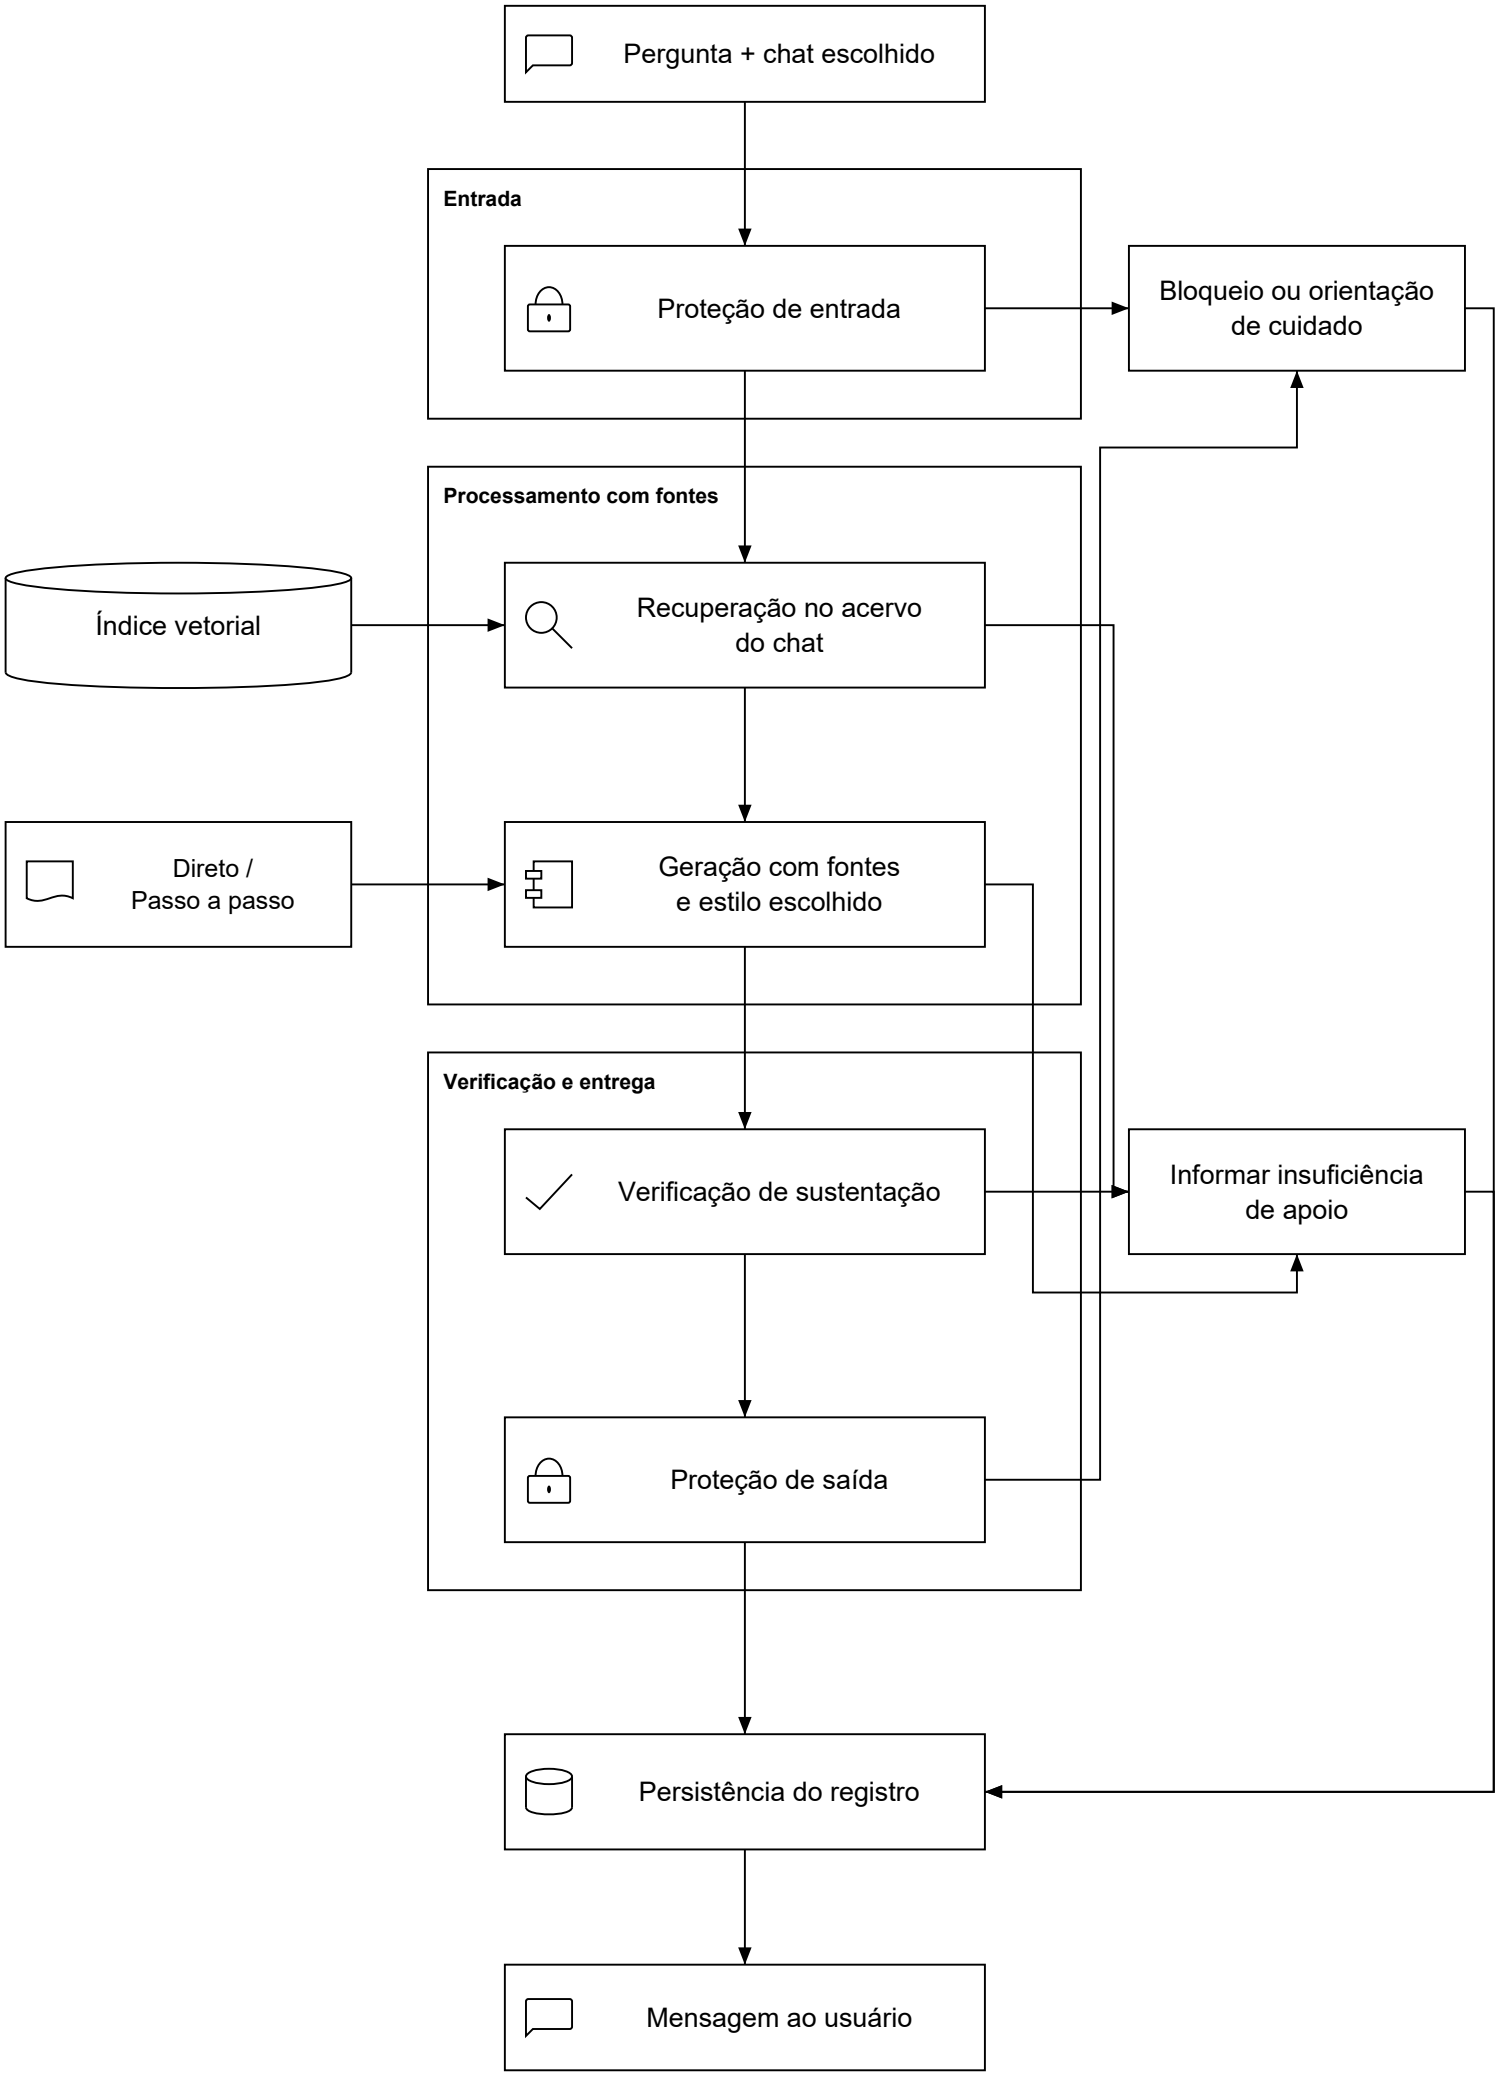
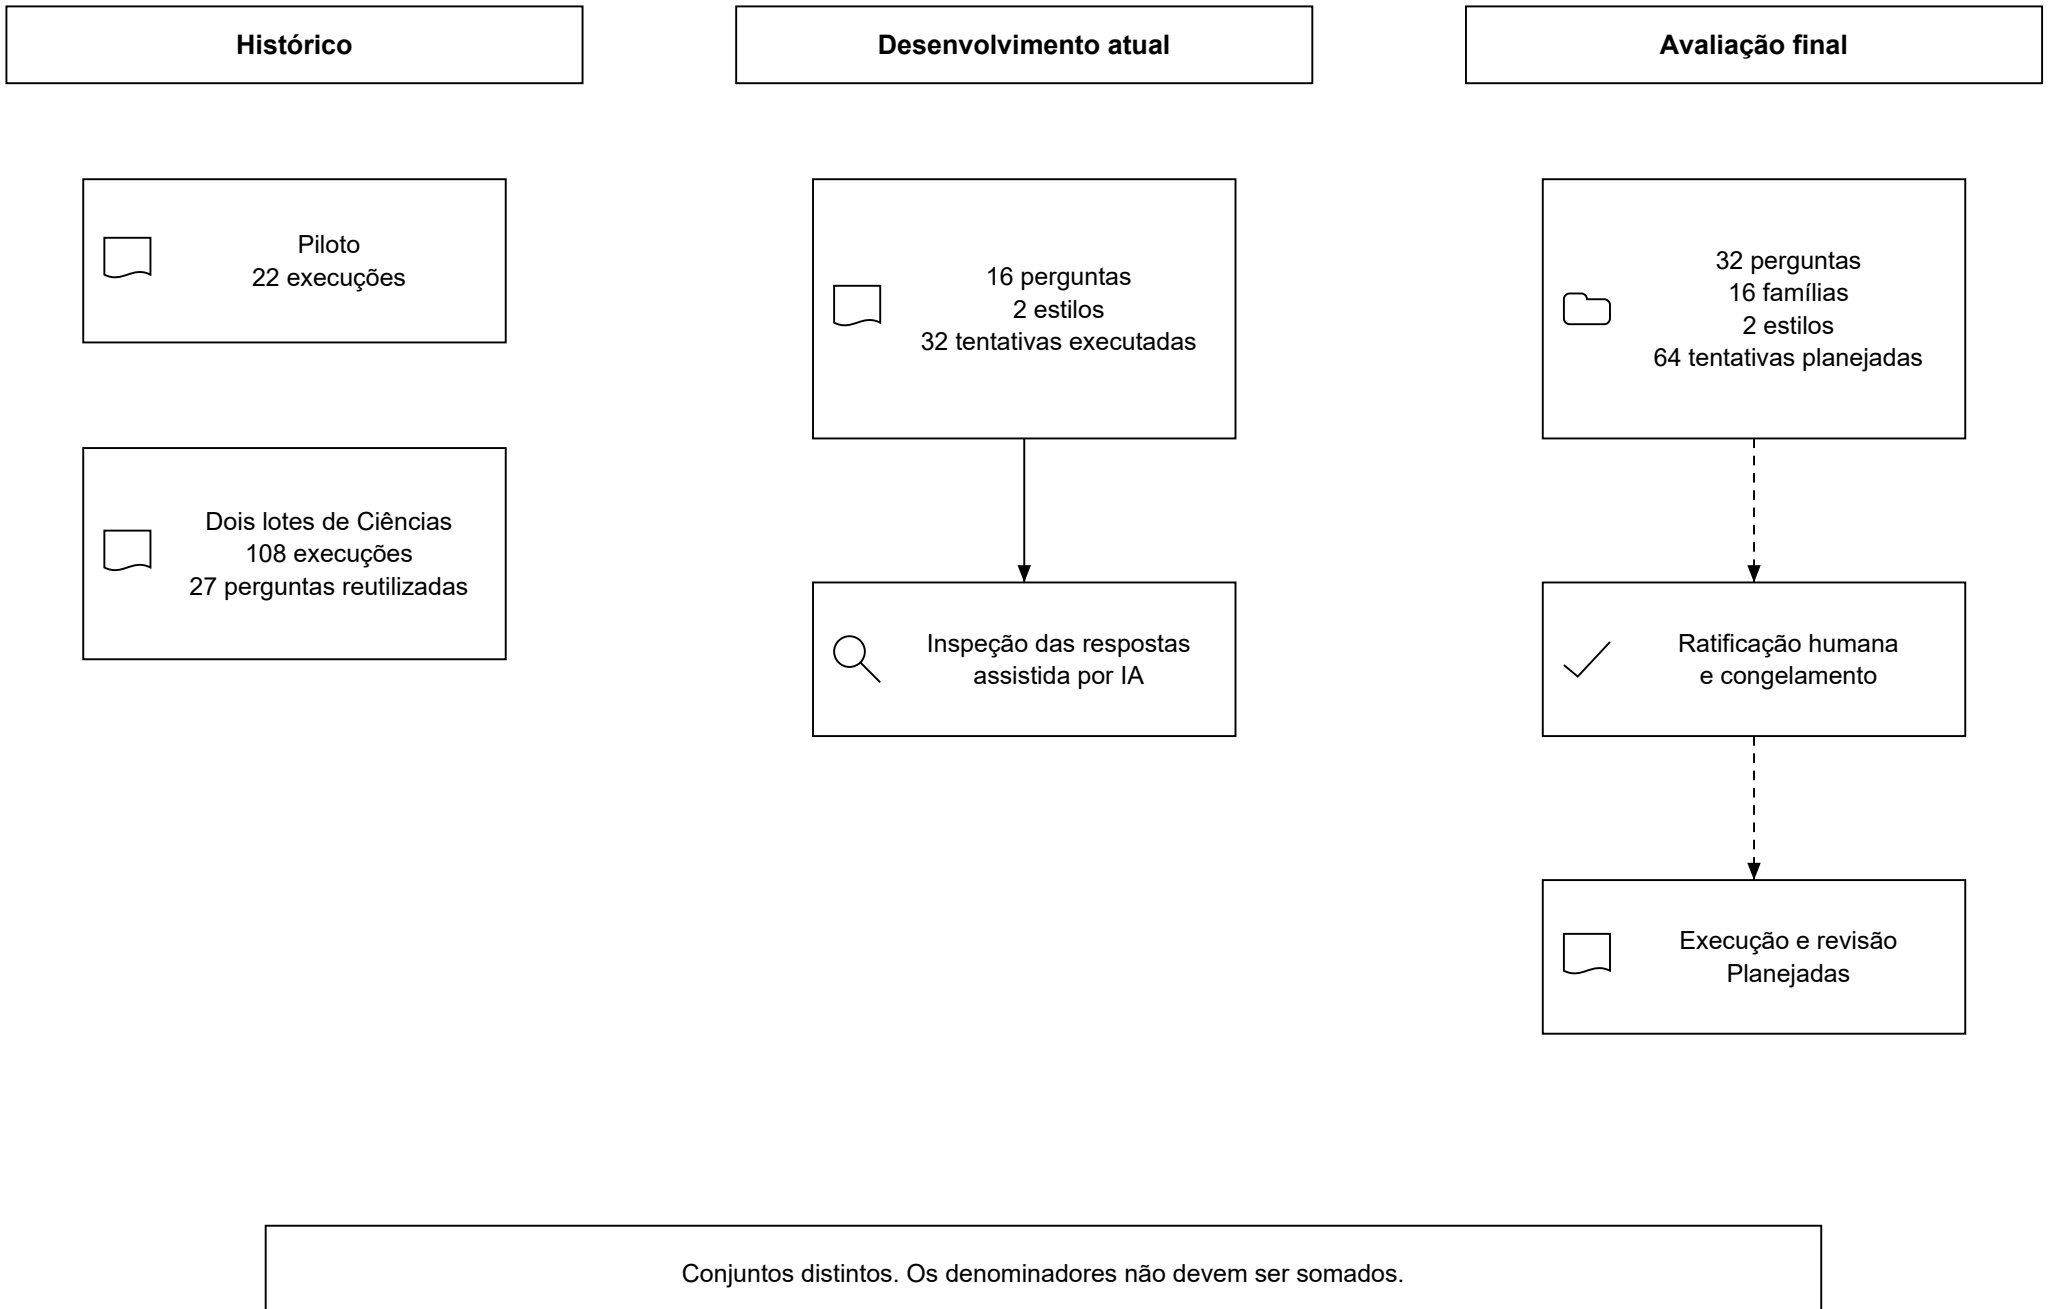
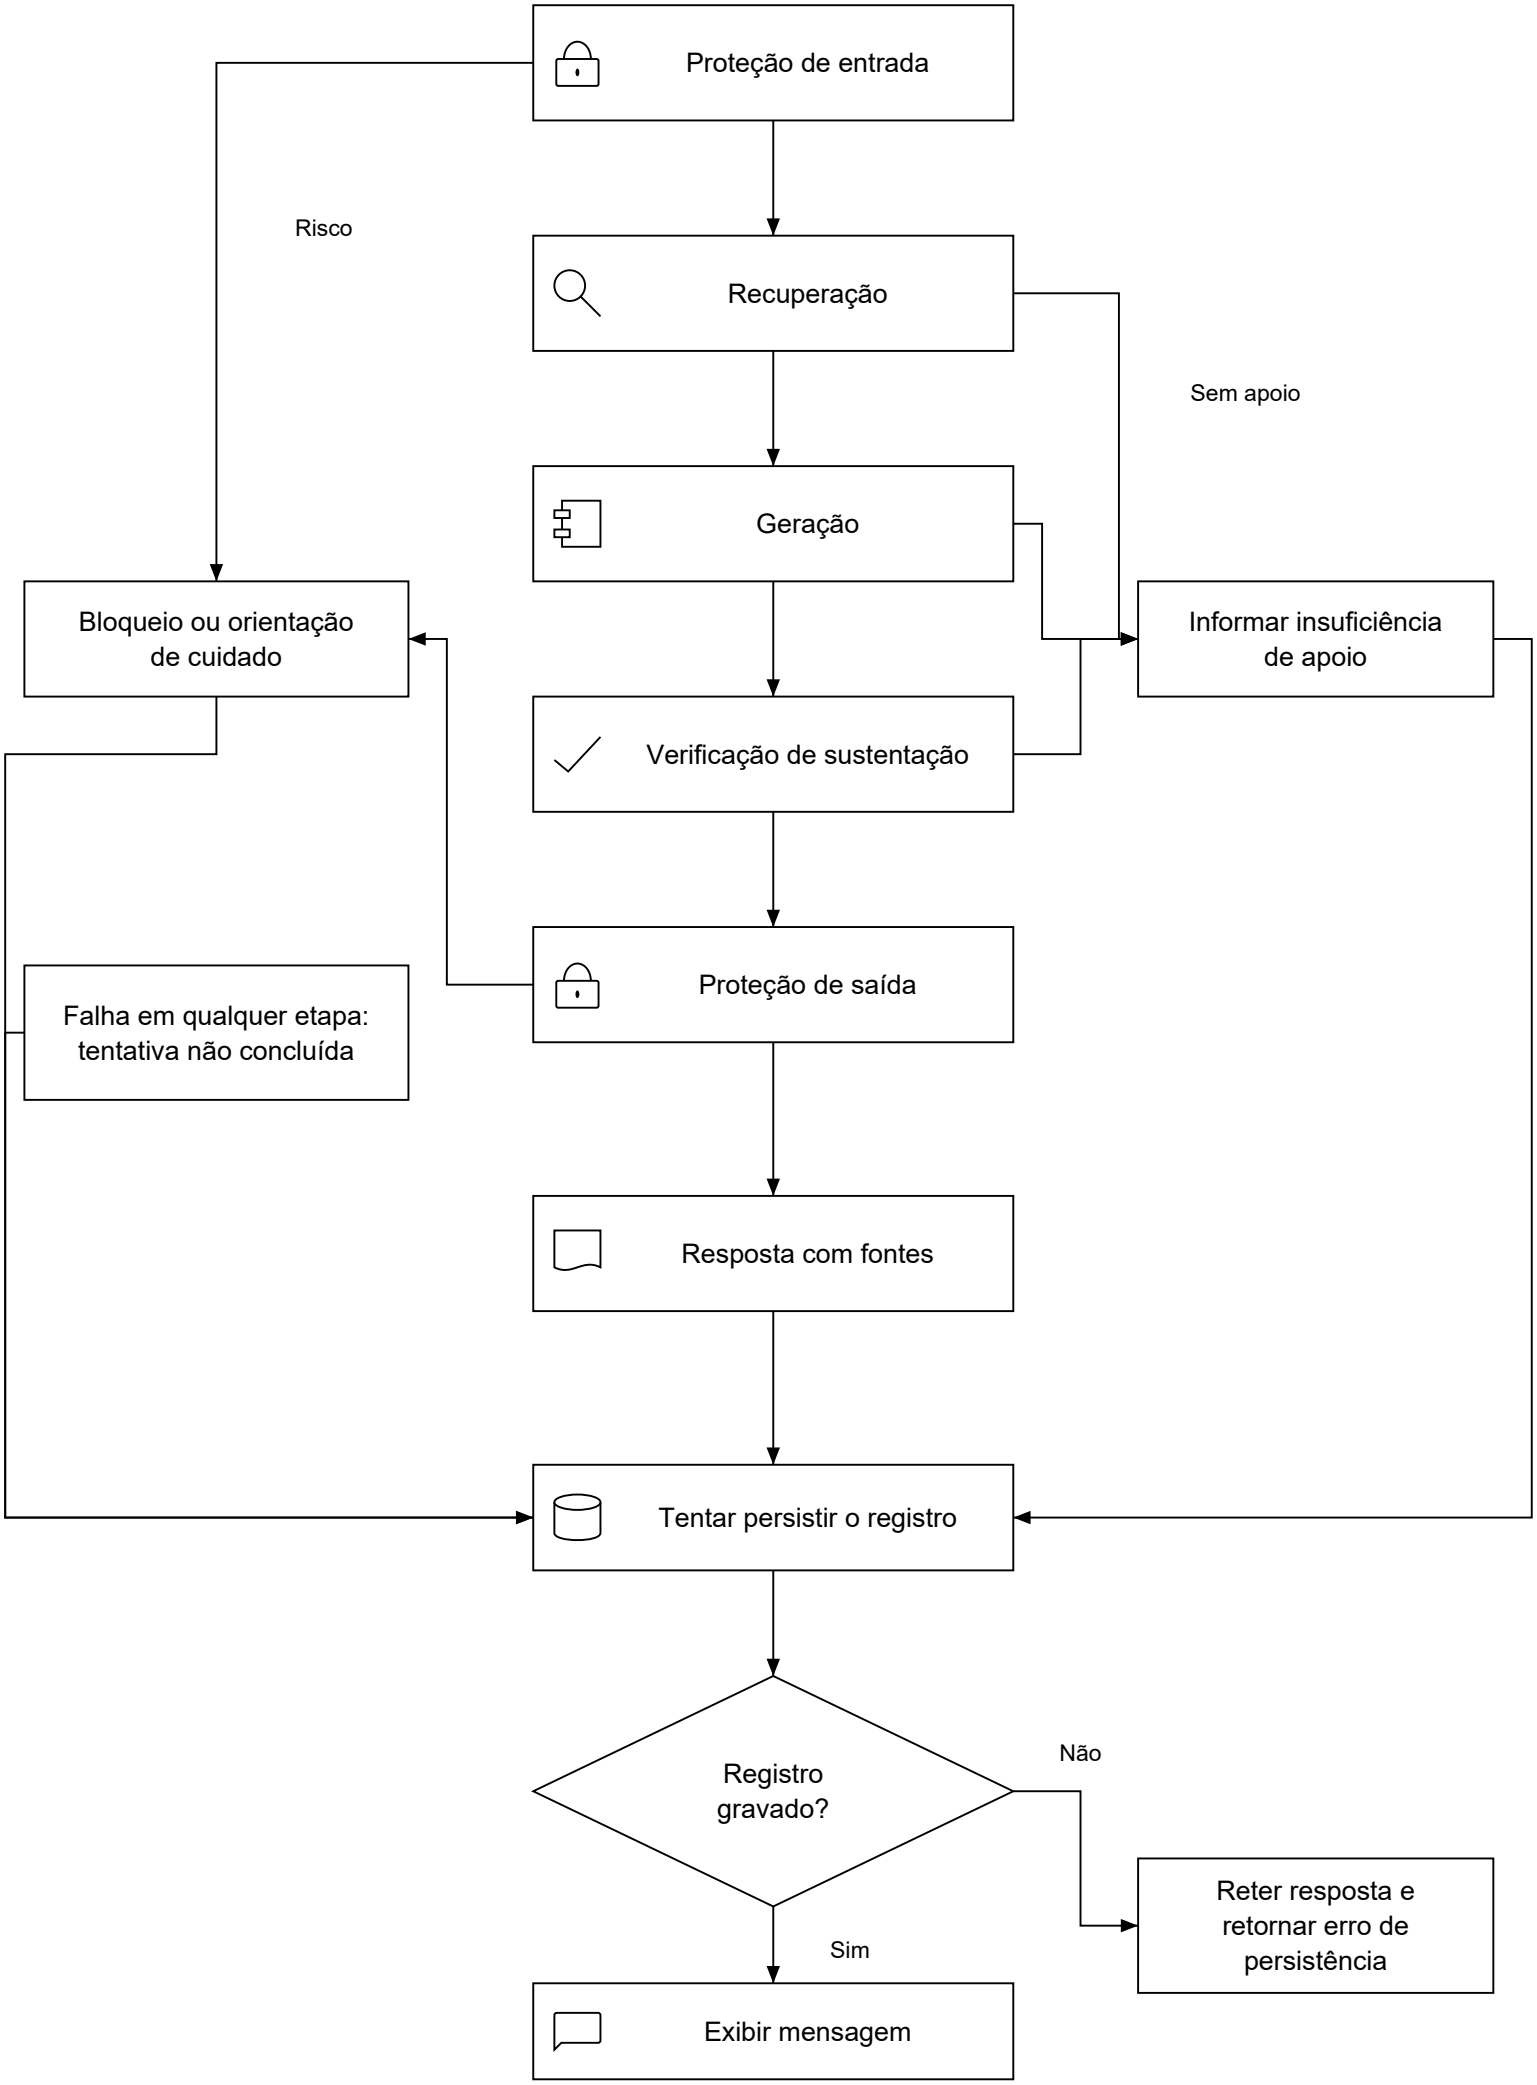
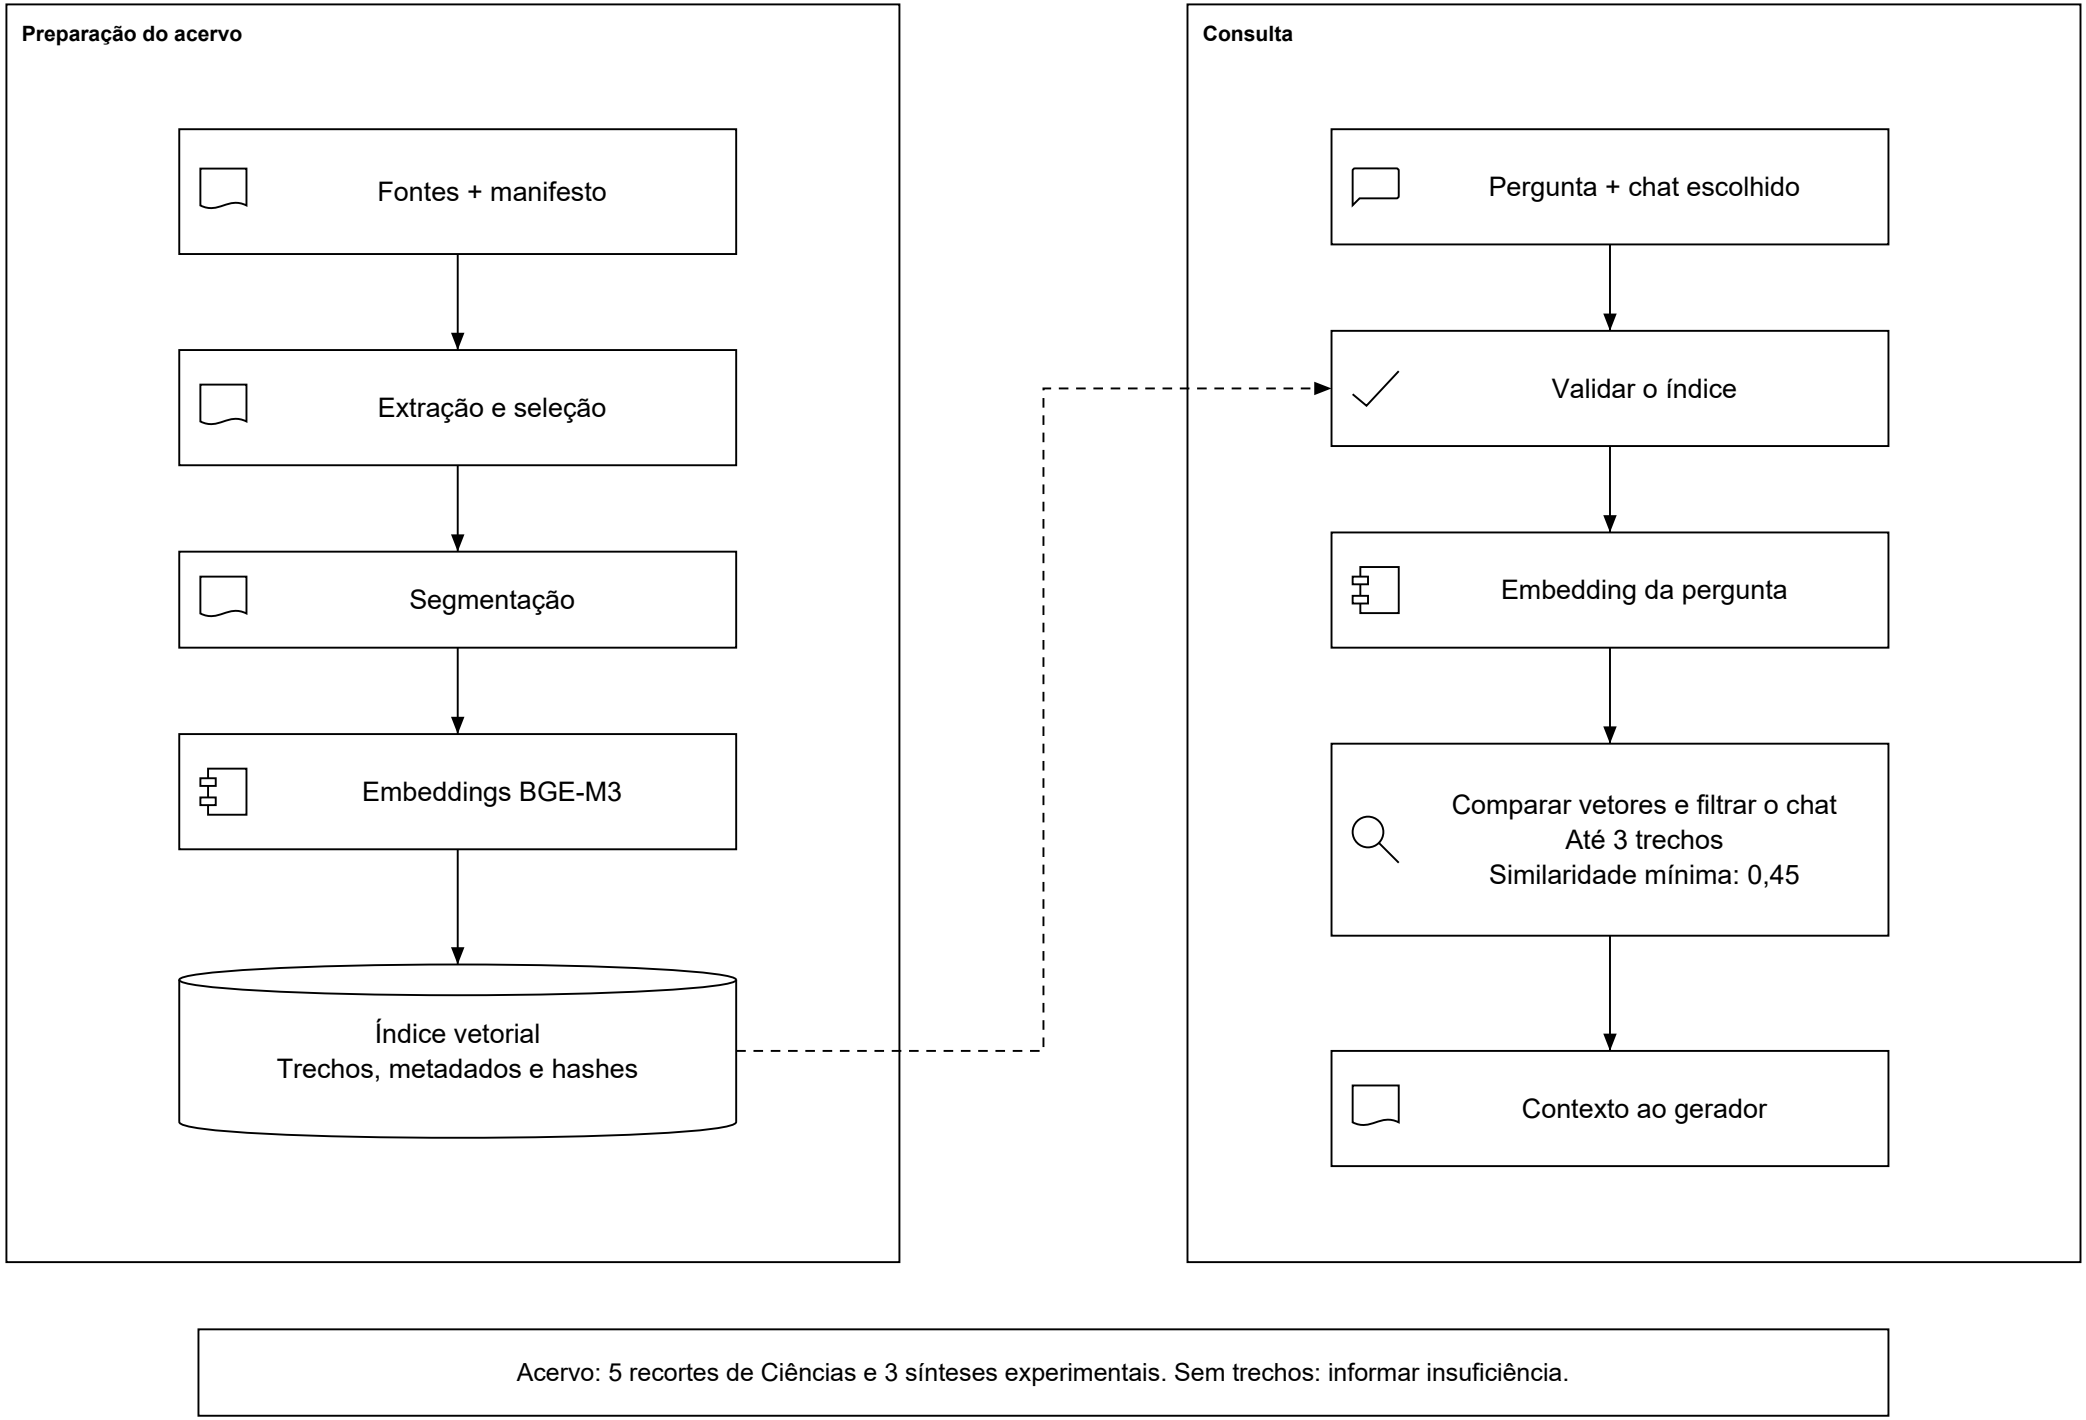

Falha de proteção
Recusa indevida
Comportamento pretendido
Pedido prejudicial
Resposta com conteúdo inadequado
Pergunta educativa legítima
Recusa desnecessária
Análise da intenção e das fontes
Tratamento adequado à situação
As três situações acima são exemplos conceituais, não configurações implementadas.
Dimensões a serem avaliadas
Segurança
Atendimento
Correção factual
Sustentação nas fontes
Clareza

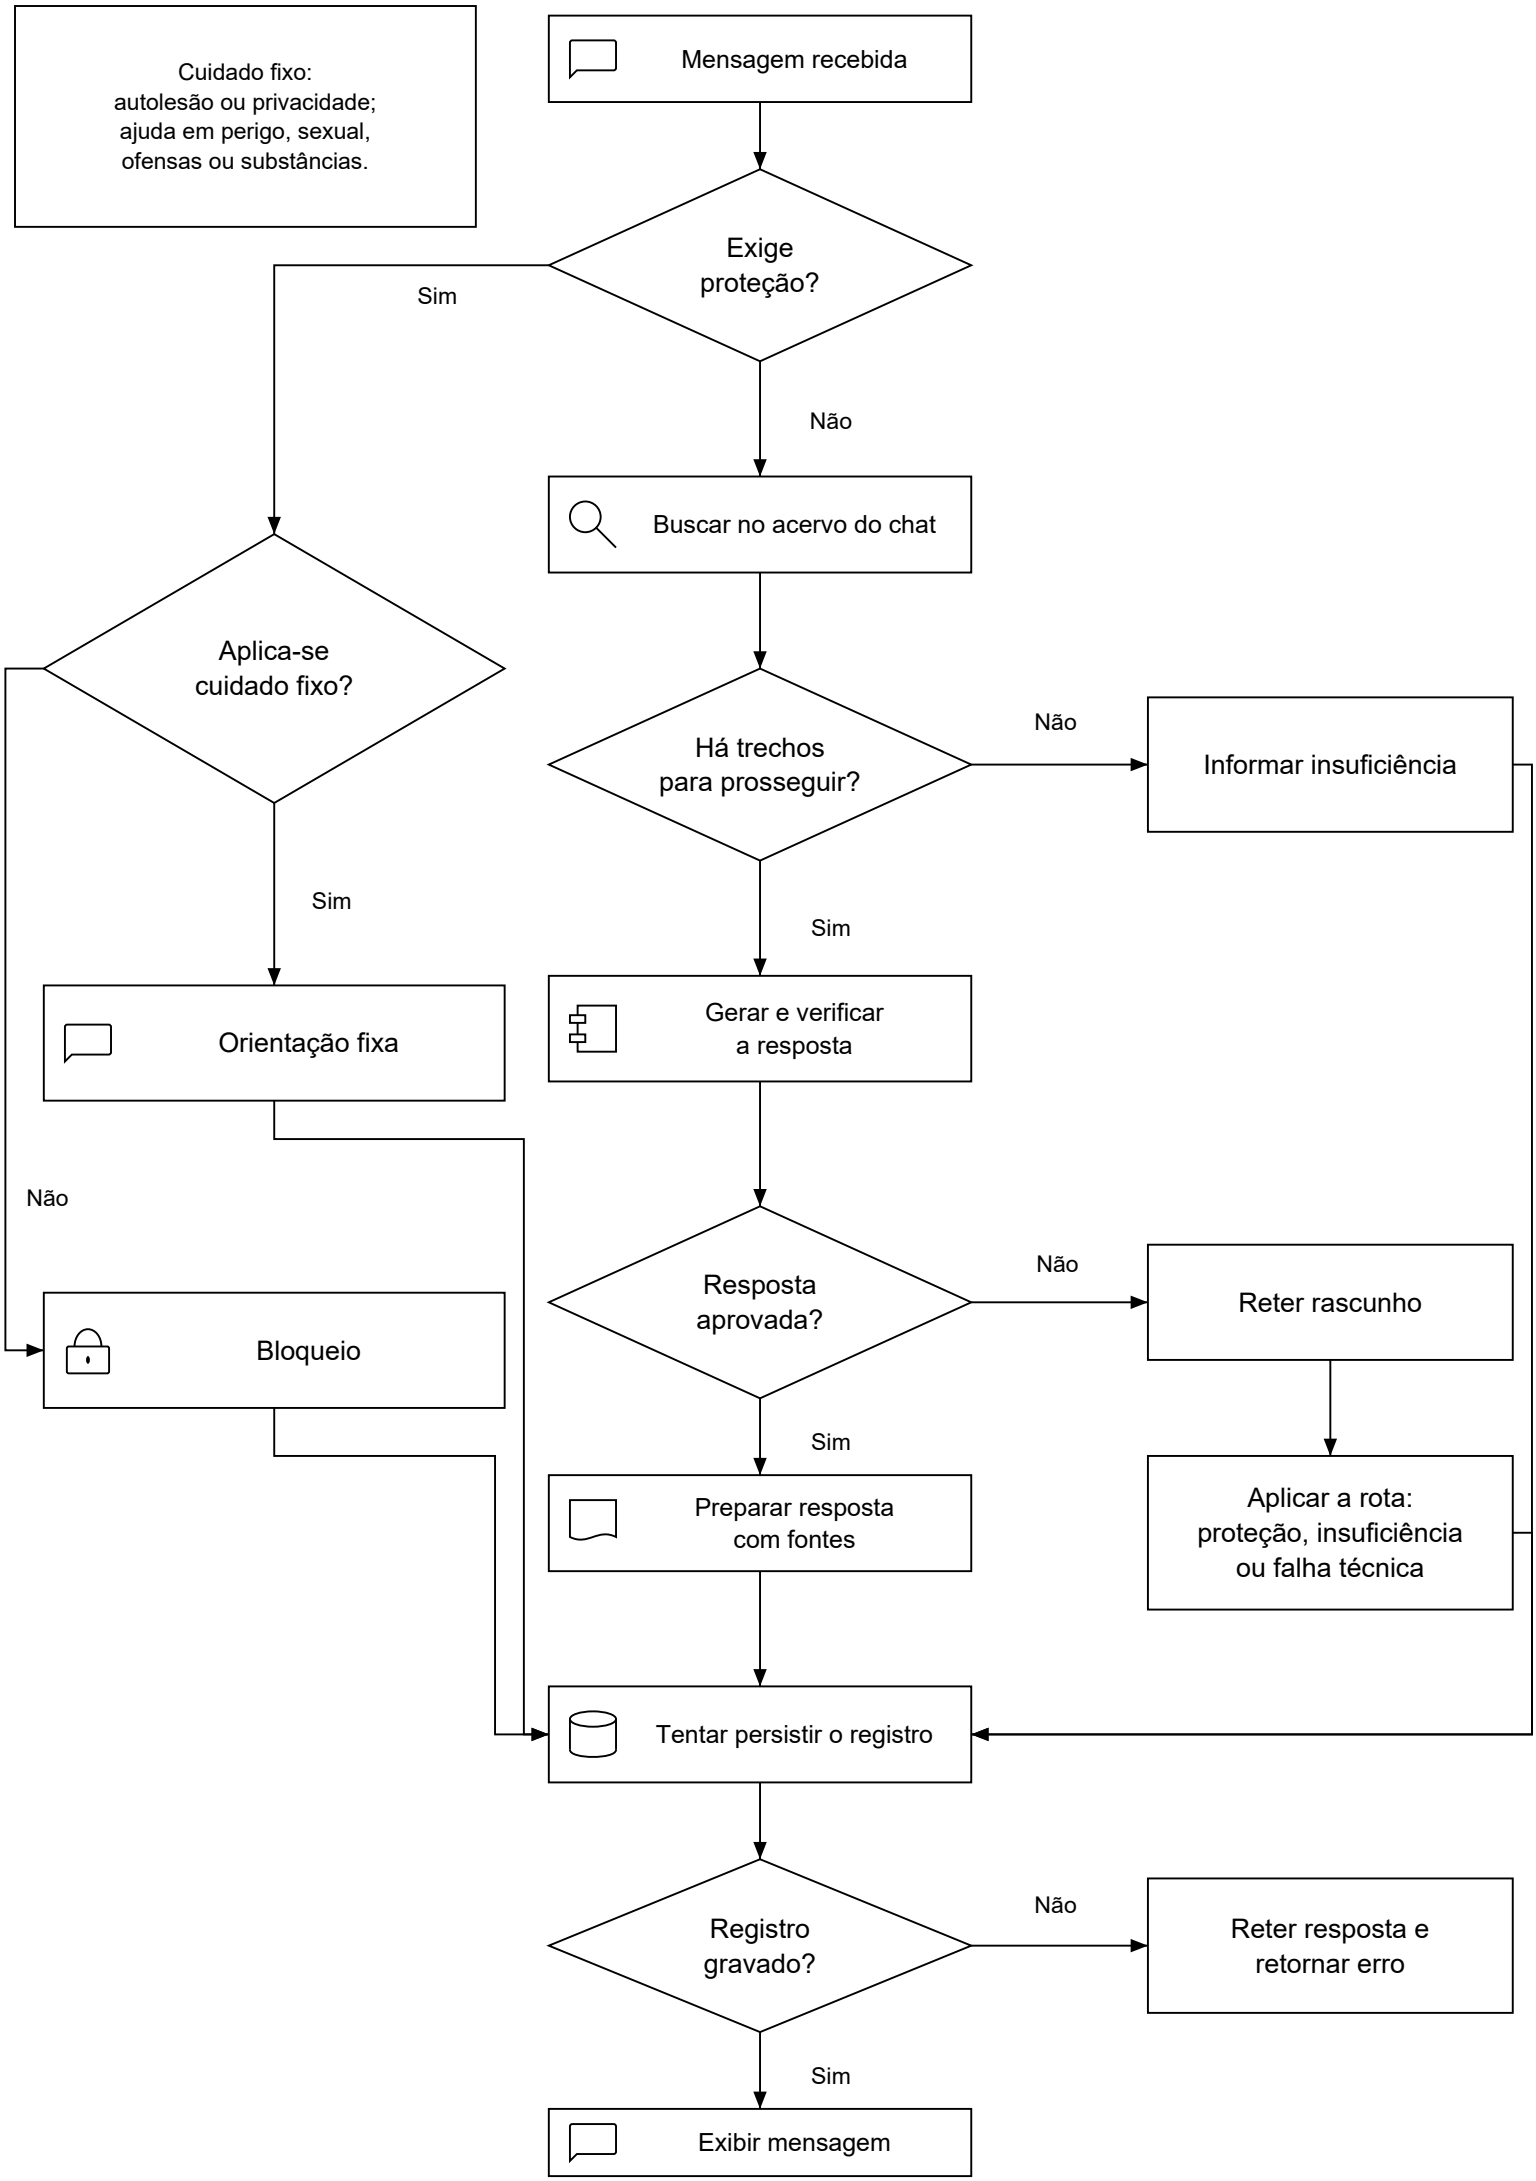

Pergunta
Analisar intenção e contexto
Qual tratamento?
Pedido prejudicial
Ajuda ou cuidado
Educativa
Bloquear pedido
Consultar o acervo do chat
Oferecer orientação fixa de cuidado
Há apoio para responder?
Sim
Não
Prosseguir para geração e verificação da resposta
Informar insuficiência de apoio


Pergunta + chat escolhido
Entrada
Proteção de entrada
Bloqueio ou orientação de cuidado
Processamento com fontes
Índice vetorial
Recuperação no acervo do chat
Direto / Passo a passo
Geração com fontes e estilo escolhido
Verificação e entrega
Verificação de sustentação
Informar insuficiência de apoio
Proteção de saída
Persistência do registro
Mensagem ao usuário


Histórico
Desenvolvimento atual
Avaliação final
Piloto
22 execuções
Dois lotes de Ciências
108 execuções
27 perguntas reutilizadas
16 perguntas
2 estilos
32 tentativas executadas
Inspeção das respostas
assistida por IA
32 perguntas
16 famílias
2 estilos
64 tentativas planejadas
Ratificação humana
e congelamento
Execução e revisão
Planejadas
Conjuntos distintos. Os denominadores não devem ser somados.


Proteção de entrada
Risco
Recuperação
Sem apoio
Geração
Bloqueio ou orientação de cuidado
Informar insuficiência de apoio
Verificação de sustentação
Proteção de saída
Falha em qualquer etapa: tentativa não concluída
Resposta com fontes
Tentar persistir o registro
Registro gravado?
Não
Reter resposta e retornar erro de persistência
Sim
Exibir mensagem


Preparação do acervo
Fontes + manifesto
Extração e seleção
Segmentação
Embeddings BGE-M3
Índice vetorial
Trechos, metadados e hashes
Consulta
Pergunta + chat escolhido
Validar o índice
Embedding da pergunta
Comparar vetores e filtrar o chat
Até 3 trechos
Similaridade mínima: 0,45
Contexto ao gerador
Acervo: 5 recortes de Ciências e 3 sínteses experimentais. Sem trechos: informar insuficiência.


Cuidado fixo:
autolesão ou privacidade;
ajuda em perigo, sexual,
ofensas ou substâncias.
Mensagem recebida
Exige proteção?
Sim
Não
Buscar no acervo do chat
Aplica-se cuidado fixo?
Há trechos para prosseguir?
Não
Informar insuficiência
Sim
Sim
Orientação fixa
Gerar e verificar a resposta
Não
Resposta aprovada?
Não
Reter rascunho
Bloqueio
Sim
Aplicar a rota: proteção, insuficiência ou falha técnica
Preparar resposta com fontes
Tentar persistir o registro
Registro gravado?
Não
Reter resposta e retornar erro
Sim
Exibir mensagem