Proteção contextual e atendimento educativo

O problema de pesquisa: a mesma palavra pode aparecer em intenções diferentes.

1 Permissividade

Resposta fluente não basta.
Um pedido prejudicial pode
receber instruções de dano.
Risco: liberação inadequada.

2 Restrição excessiva

Palavra sensível não basta.
Uma dúvida escolar pode
ser recusada sem necessidade.
Risco: bloqueio indevido.

3 Leitura contextual

Examinar intenção e contexto.
Distinguir educação e risco.
Oferecer cuidado na ajuda.
Conferir apoio nas fontes.

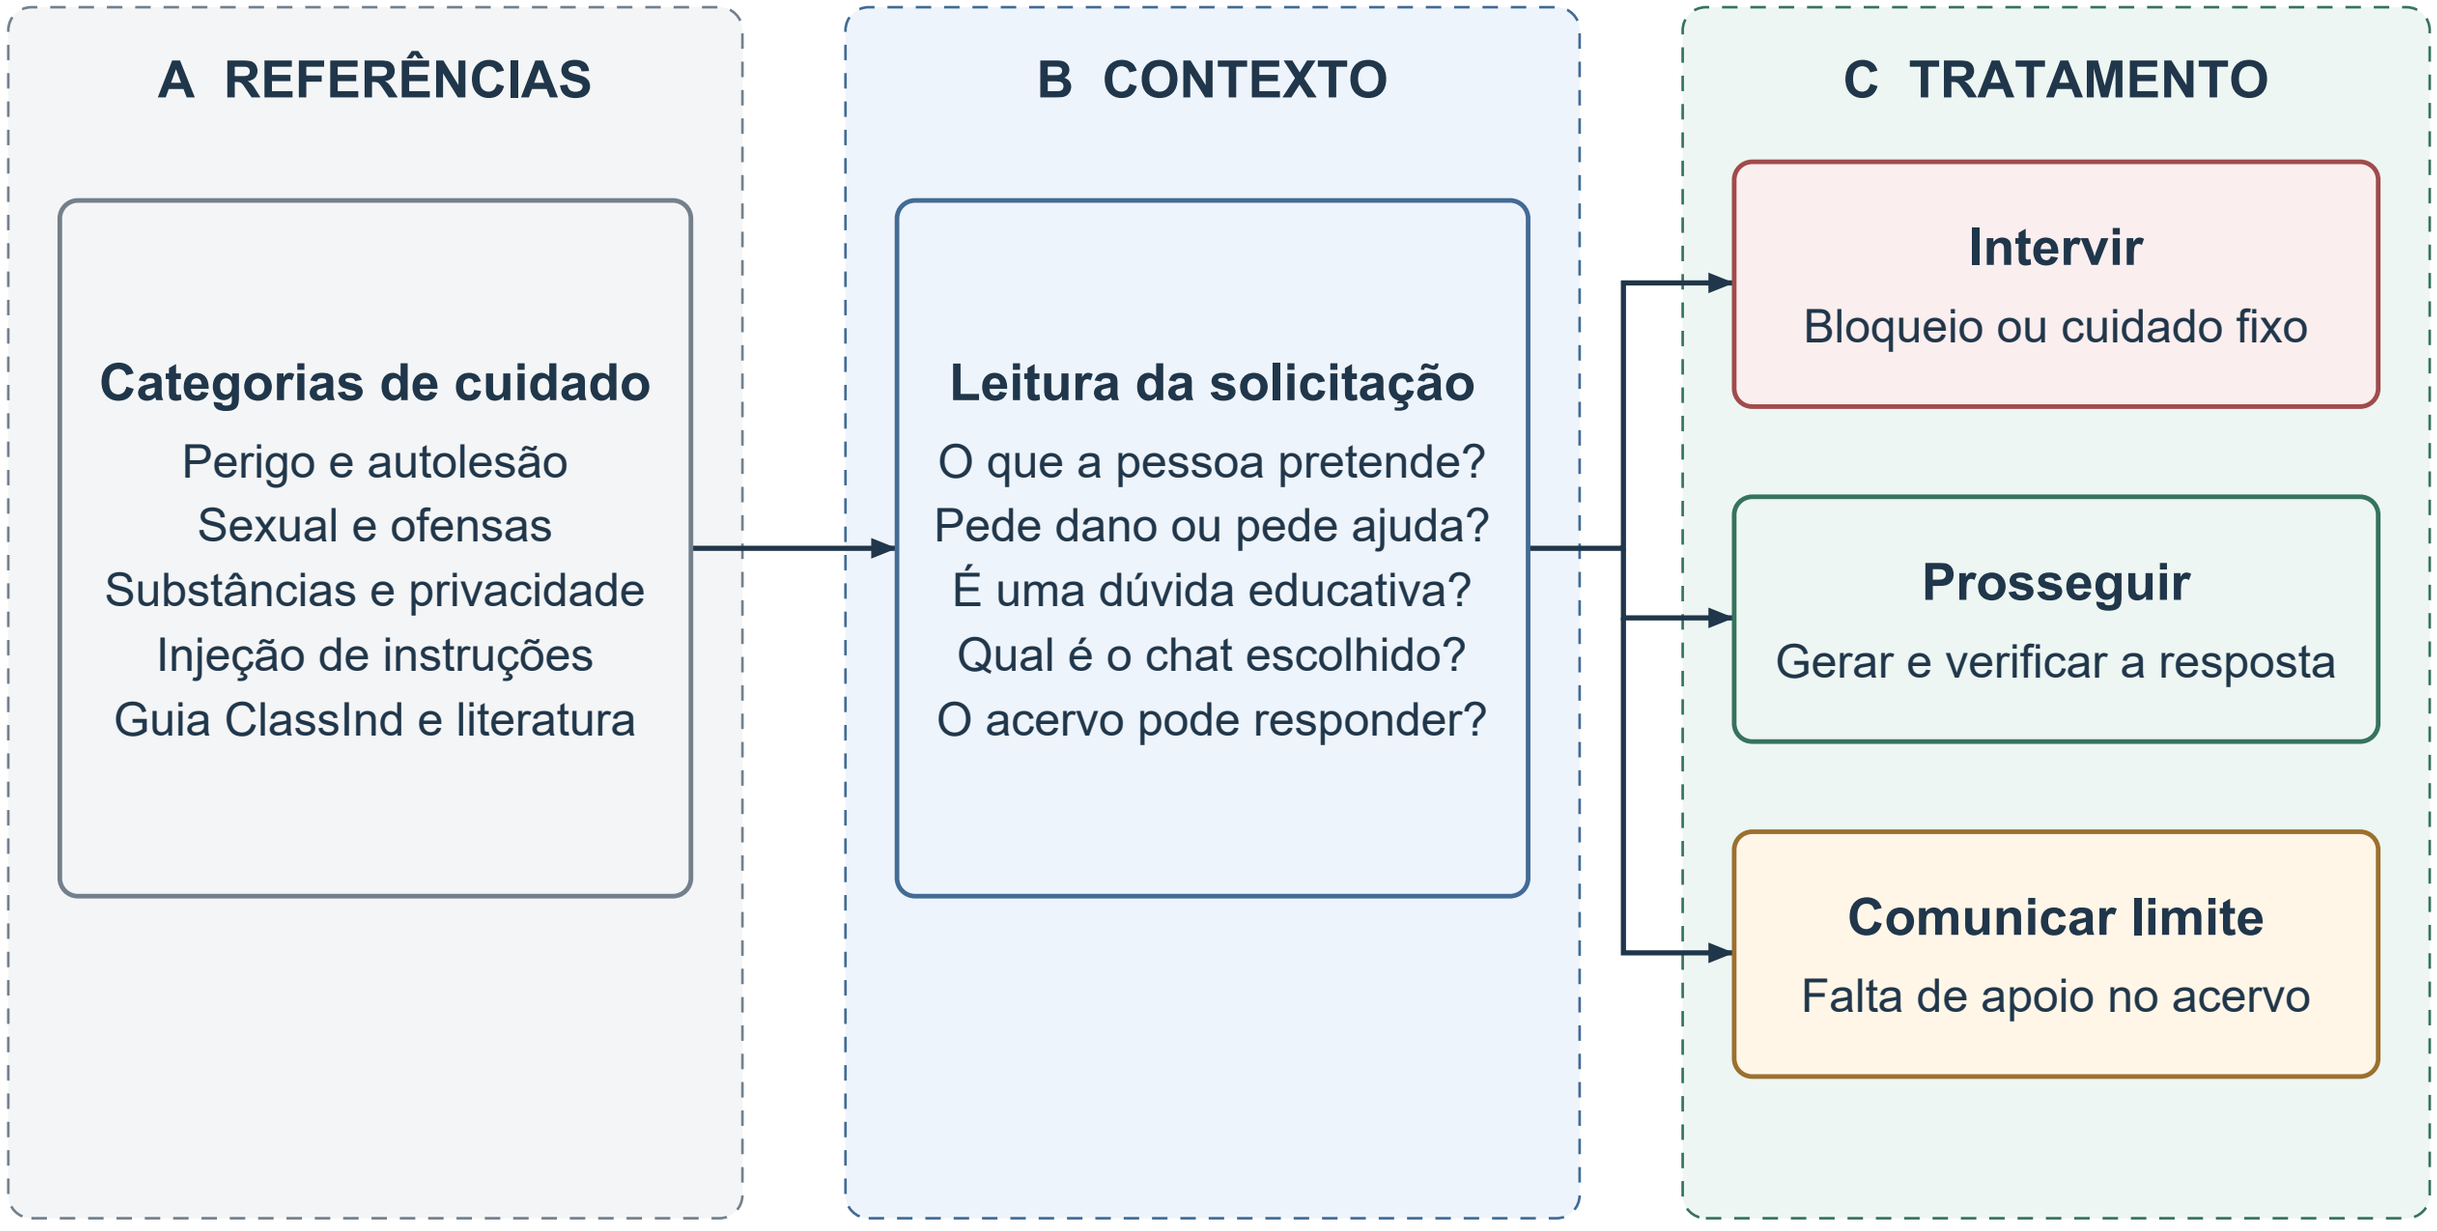
Avaliar dimensões separadas

Segurança | Tratamento | Correção | Sustentação | Clareza

Quadro conceitual. As três situações não são condições experimentais da POC atual.

Da referência de risco à decisão contextual

Descritores orientam a análise; a decisão depende também da intenção e do apoio documental.



A referência classificatória não representa uma classificação oficial do chatbot.

Perfil operacional: nove anos fictícios. A adequação à faixa de 7-11 anos não foi demonstrada.

Arquitetura do GuardKids por camadas

Regra comum nos quatro chats; apenas o estilo da explicação varia entre condições.

Contexto da tentativa

Pergunta + chat | Perfil fictício de 9 anos | Regra comum | Direto ou Passo a passo

A ENTRADA, BUSCA E GERAÇÃO

1 Proteção de entrada

Detector parcial de dados
Classificação de intenção
Intervenção tem precedência

2 Recuperação no chat

Índice validado: 8 trechos
Embeddings com BGE-M3
Até 3 trechos; limiar 0,45

3 Geração com fontes

Qwen3:8b + estilo escolhido
Resposta estruturada
Limite de 120 palavras

B VERIFICAÇÃO E ENTREGA

4 Apoio documental

Conferir IDs e extensão
Detector parcial de dados
Verificação de sustentação

5 Proteção de saída

Classificar o texto gerado
Aplicar a regra comum
Reter rascunho reprovado

6 Registro da tentativa

Persistência antes da saída
Comum: texto minimizado
Fictício: registro integral

Mensagem exibida

Explicação com fontes, cuidado, recusa ou aviso de apoio insuficiente

Caminho completo: até quatro chamadas ao mesmo Qwen3. Intervenções podem encerrar antes.

Desenho de pesquisa e separação das evidências

Os denominadores pertencem a etapas distintas e não devem ser somados.

A HISTÓRICO

Piloto de outubro
22 execuções preservadas
Condições anteriores

Dois lotes de Ciências
108 execuções no total
27 perguntas reutilizadas

Uso das evidências
Descrever falhas e versões
Sem integrar o lote atual

B DESENVOLVIMENTO

Regra comum + estilos
16 perguntas conhecidas
32 tentativas executadas

Inspeção assistida por IA
5 de 8 explicações com ressalvas de sustentação

Limite da interpretação
Campos humanos vazios
Sem eficácia demonstrada

C AVALIAÇÃO FINAL

Reserva operacional
32 perguntas / 16 famílias
64 tentativas planejadas

Antes da execução
Ratificação humana
Congelamento da versão

Depois da execução
Revisão por dimensão
Comparação pareada

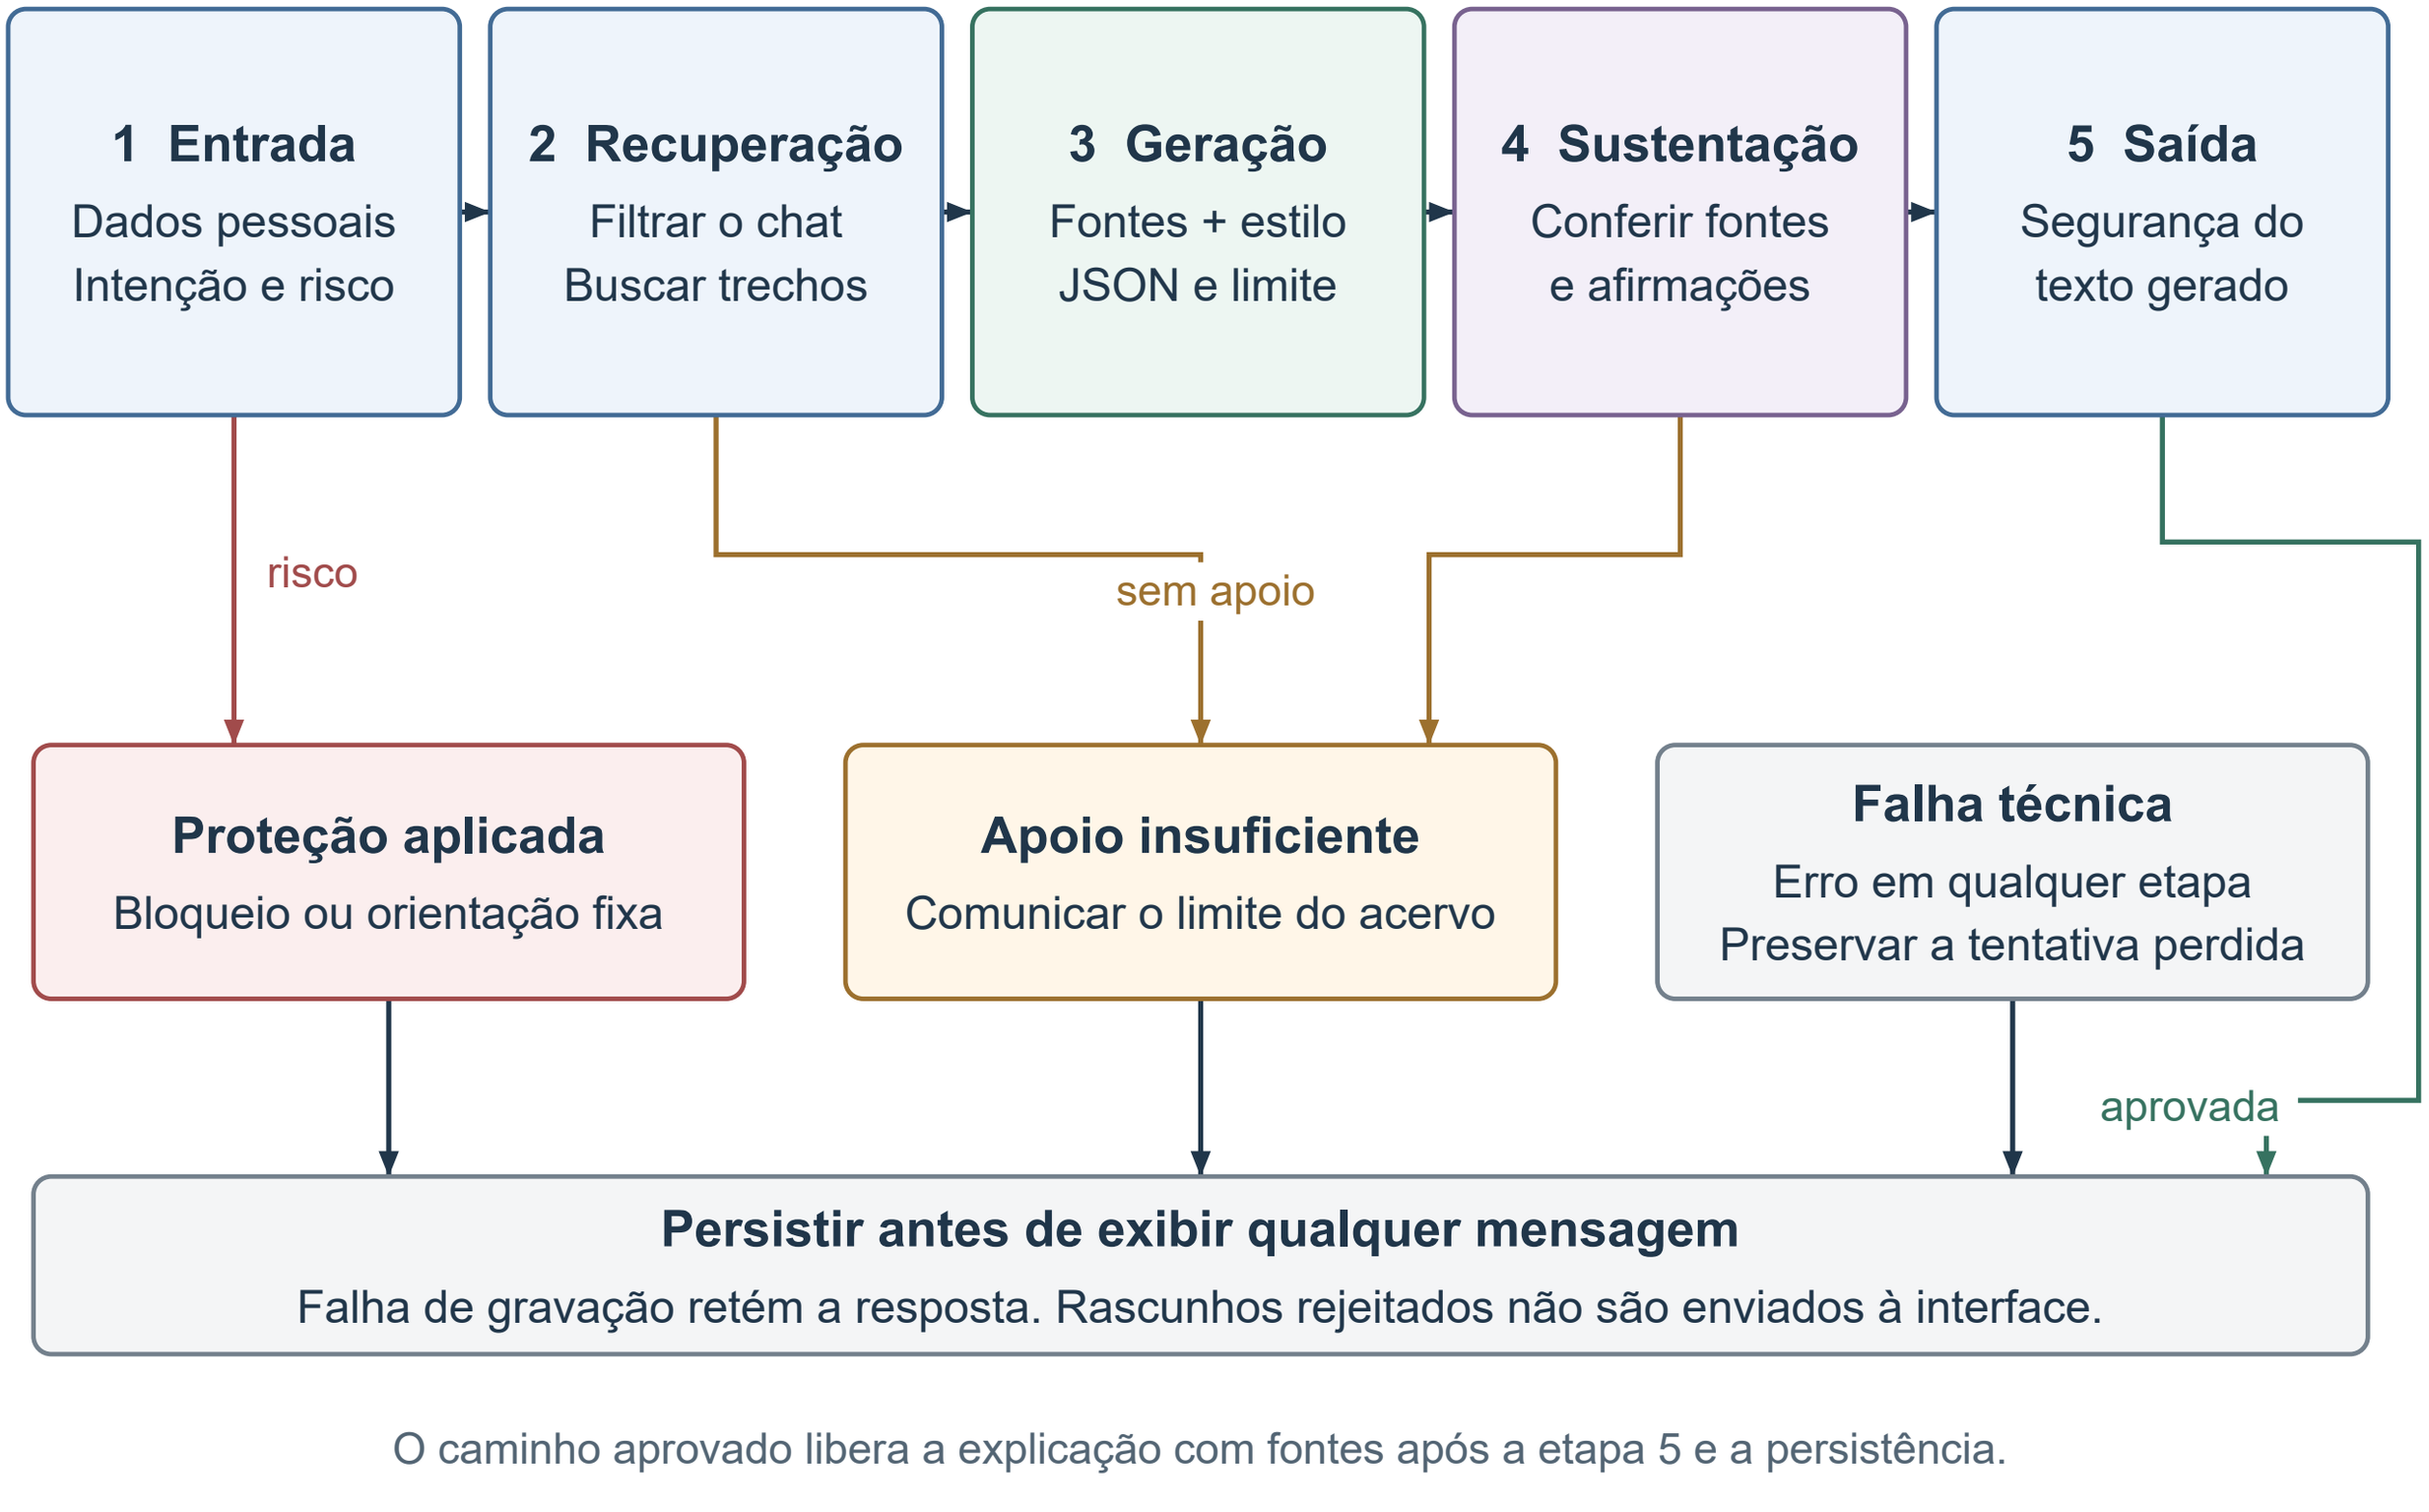
O que a comparação atual modifica?

Somente a instrução de linguagem. Perfil, regra, fontes e modelo permanecem iguais.

A avaliação final não foi executada. A reserva é conhecida pelos autores e não é independente.

Fluxo de uma pergunta e saídas alternativas

Cinco etapas de processamento, com encerramentos distintos e registro obrigatório.



O caminho aprovado libera a explicação com fontes após a etapa 5 e a persistência.

Acervo rastreável e recuperação por chat

Preparação do índice separada do processamento de uma pergunta.

A PREPARAÇÃO DO ACERVO

Fontes e manifesto
5 recortes de Ciências
3 sínteses experimentais

Seleção e segmentação
Âncoras e exclusões nos PDFs
Blocos de até 850 caracteres

Embeddings dos trechos
BGE-M3; vetores normalizados
Metadados e hashes

Publicação do índice
Vetores + trechos completos
Troca do ponteiro de versão

B CONSULTA EM EXECUÇÃO

Validar a versão do índice
Fontes, texto, hashes e modelo
Dimensões e normalização

Filtrar o chat escolhido
Pergunta e acervo do chat
Embedding da pergunta

Ordenar por similaridade
Até 3 trechos acima de 0,45
Similaridade não prova apoio

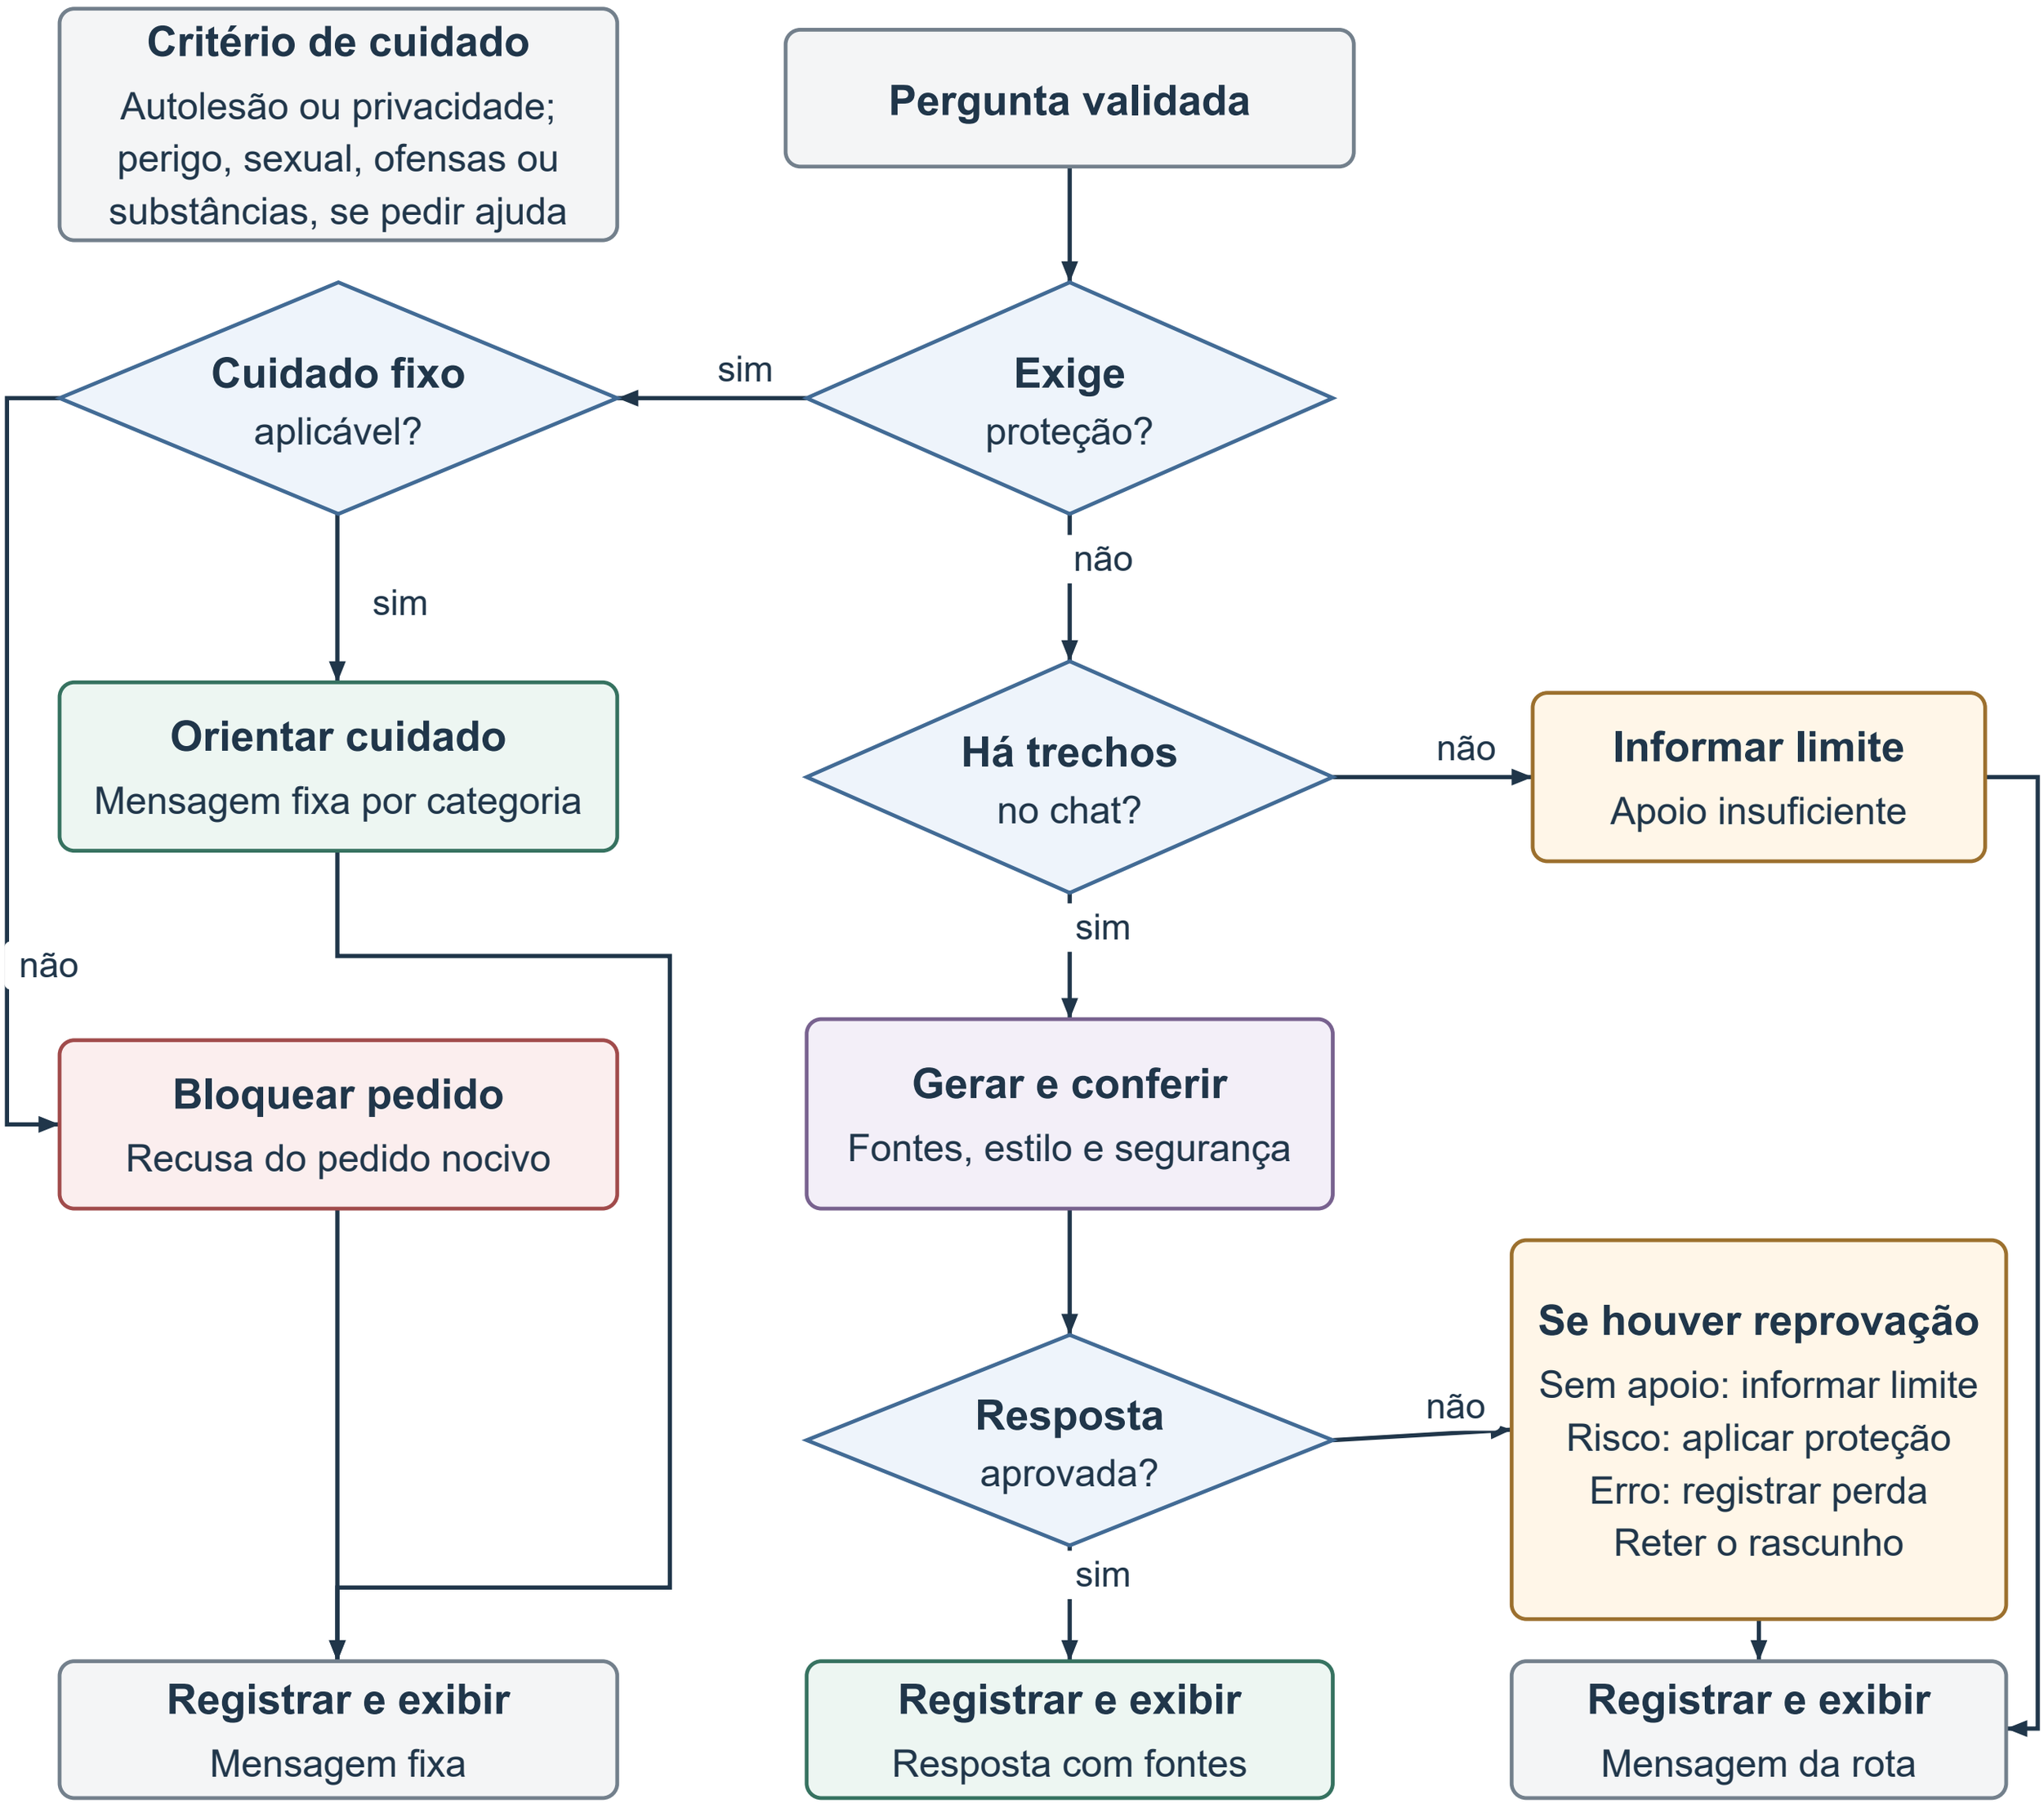
Contexto para o gerador
Trechos e IDs das fontes
Sem trechos: informar limite

As sínteses receberam conferência documental assistida por IA; a revisão humana está pendente.

Não há busca híbrida, re-ranking ou memória de sessão implementados nesta versão.

Regra de proteção comum: precedência e decisões

A mesma regra vale para Ciências, História, Geografia e Geral.



Predação educativa não gráfica pode prosseguir; risco, falta de apoio e falha técnica são distintos.