

CURSO DE SISTEMAS DE INFORMAÇÃO

DESENVOLVIMENTO E AVALIAÇÃO DE GUARDRAILS CONFIGURÁVEIS EM UMA PROVA DE CONCEITO DE CHATBOT EDUCATIVO DESTINADO A CRIANÇAS DE 7 A 11 ANOS EM PORTUGUÊS BRASILEIRO

FILIPE MARTINS HENRIQUE

Palmas

2026



CURSO DE SISTEMAS DE INFORMAÇÃO

DESENVOLVIMENTO E AVALIAÇÃO DE GUARDRAILS CONFIGURÁVEIS EM UMA PROVA DE CONCEITO DE CHATBOT EDUCATIVO DESTINADO A CRIANÇAS DE 7 A 11 ANOS EM PORTUGUÊS BRASILEIRO

FILIPE MARTINS HENRIQUE

Projeto de Pesquisa apresentado à disciplina de Trabalho de Conclusão de Curso I do Curso de Sistemas de Informação da Universidade Estadual do Tocantins – UNITINS, sob orientação do Prof. Marcos Souza.

Palmas
2026

Resumo

Chatbots educativos baseados em grandes modelos de linguagem podem produzir respostas inadequadas ou recusar dúvidas escolares legítimas. Este Projeto de Pesquisa/TCC I tem por objetivo desenvolver e verificar funcionalmente o GuardKids, uma prova de conceito com guardrails contextuais em português brasileiro, e preparar uma avaliação rastreável de segurança e atendimento educativo. O público destinatário pretendido é de sete a onze anos, mas o recorte operacional utiliza apenas um perfil fictício de nove anos, em Ciências do quarto ano, sem participantes infantis. A pesquisa aplicada combina Qwen3:8b, recuperação com BGE-M3 sobre cinco recortes didáticos e verificações de entrada, sustentação e saída. Comparam-se uma ablação conservadora e uma configuração que permite predação educativa. Foram realizados testes automatizados, sondagem de três limiares e dois lotes de desenvolvimento de 54 execuções cada, preservando falhas e versões. Esses procedimentos examinam funcionamento e calibração preliminar; não demonstram segurança geral, compreensão por crianças ou eficácia educativa. Para a continuidade, foram preparados 40 enunciados em 20 famílias, duas condições, duas repetições, rubrica multidimensional e instrumentos de revisão com ocultação parcial das condições. A ratificação das referências e o julgamento humano das respostas permanecem pendentes. A contribuição consiste na operacionalização documentada de políticas contextuais e em um protocolo que distingue rota técnica, segurança, correção factual, fidelidade às fontes e atendimento educativo.

Palavras-chave: Guardrails. Chatbot educativo. Segurança infantil. Geração aumentada por recuperação.

Abstract

Educational chatbots based on large language models may produce inappropriate responses or refuse legitimate school questions. This research proposal, submitted as TCC I, aims to develop and functionally verify GuardKids, a proof of concept with contextual guardrails in Brazilian Portuguese, and prepare a traceable evaluation of safety and educational responsiveness. The intended audience is children aged seven to eleven; however, the operational scope uses only a fictional nine-year-old profile and fourth-grade science, with no child participants. This applied development study combines Qwen3:8b, BGE-M3 retrieval over five textbook excerpts, and input, grounding and output checks. A conservative ablation is compared with a configuration allowing educational predation. Automated tests, a three-threshold retrieval probe and two development batches of 54 executions each were conducted, preserving failures and version identifiers. These procedures examine technical functioning and preliminary calibration; they do not establish general safety, children's comprehension or educational effectiveness. For subsequent evaluation, 40 questions in 20 families, two conditions, two repetitions, a multidimensional rubric and review instruments with partially concealed conditions were prepared. Human ratification of the reference labels and assessment of response content remain pending. The contribution is a documented implementation of contextual policies and a protocol that distinguishes technical routing, safety, factual correctness, source fidelity and educational responsiveness.

Keywords: Guardrails. Educational chatbot. Child safety. Retrieval-augmented generation.

Lista de ilustrações

Figura 1 – Caminho de processamento e verificação do GuardKids GK-P1.2 16
Figura 2 – Precedência das decisões de entrada e saída 18
Figura 3 – Separação entre desenvolvimento e avaliação final 22

Lista de tabelas

Tabela 1 – Relação entre referências e contribuição delimitada 12
Tabela 2 – Correspondência curricular do recorte 13
Tabela 3 – Conteúdo efetivamente recuperável no índice conferido 14
Tabela 4 – Configuração GK-P1.2 e justificativas operacionais 15
Tabela 5 – Correspondência contextual das sete categorias de proteção 17
Tabela 6 – Plano intencional de cobertura para a avaliação final 20
Tabela 7 – Lotes de desenvolvimento executados em 3 de novembro de 2026 23
Tabela 8 – Rotas finais observadas no lote GK-P1.2 24
Tabela 9 – Objetivos, evidências e situação das etapas de pesquisa 26
Tabela 10 – Atividades realizadas e planejamento de continuidade 27
Tabela 11 – Mapa dos materiais de avaliação e rastreabilidade 30

Lista de abreviaturas e siglas

ASCS	Atendimento seguro, correto e sustentado
BNCC	Base Nacional Comum Curricular
IA	Inteligência artificial
JSON	JavaScript Object Notation
LLM	Large Language Model
RAG	Retrieval-Augmented Generation
SHA-256	Secure Hash Algorithm de 256 bits
TCC	Trabalho de Conclusão de Curso
UNITINS	Universidade Estadual do Tocantins

Sumário

1 INTRODUÇÃO 9
1.1 Motivação 9
1.2 Objetivos 10
1.2.1 Objetivo geral 10
1.2.2 Objetivos específicos 10

2 REFERENCIAL TEÓRICO 11
2.1 Procedimento de busca 11
2.2 Segurança e contexto infantil 11
2.3 Guardrails e geração com recuperação 12
2.4 Aprendizagem e limites do domínio 13

3 METODOLOGIA 14
3.1 Descrição do Problema 14
3.2 Materiais 14
3.2.1 Acervo e índice ativo 14
3.2.2 Parâmetros, calibração e congelamento 15
3.3 Implementação dos métodos 16
3.3.1 Versão e fluxo efetivo 16
3.3.2 Políticas contextuais e busca de ajuda 17
3.3.3 Pseudocódigos 18
3.4 Protocolo de avaliação 18
3.4.1 Comparação e expectativas verificáveis 18
3.4.2 Casos, exposição e capacidade de revisão 19
3.4.3 Referência de apoio e ordem de execução 20
3.4.4 Rubrica, ocultação e indicadores 21

4 RESULTADOS 23
4.1 Introdução 23
4.2 Apresentação de resultados 23
4.2.1 Funcionamento técnico e identificação dos lotes 23
4.2.2 Falha detectada e alteração de desenvolvimento 24
4.2.3 Predação, decomposição e sustentação 24
4.2.4 Piloto histórico preservado 25
4.2.5 Alcance das evidências preliminares 25

5 CONCLUSÃO 26
5.1 Trabalhos futuros 27

5.1.1 Cronograma das etapas de avaliação 27

Referências 28

APÊNDICE A – MATERIAIS, EVIDÊNCIAS E REPRODUÇÃO . . 30

1 Introdução

O desenvolvimento de chatbots educativos destinados a crianças exige cuidados com a segurança do conteúdo, a adequação da linguagem e a pertinência das respostas ao contexto escolar. Nesse cenário, os mecanismos de proteção precisam reconhecer solicitações potencialmente nocivas e preservar o atendimento a dúvidas legítimas. Este trabalho aborda esse desafio por meio de guardrails configuráveis, entendidos como regras e verificações que orientam e restringem o comportamento de uma prova de conceito de chatbot em português brasileiro.

Grandes modelos de linguagem produzem respostas abertas e podem gerar erros ou conteúdo inadequado. Salvaguardas de entrada e saída procuram limitar esses comportamentos, mas seus próprios classificadores também podem errar. A avaliação desses sistemas precisa considerar os riscos das interações com menores e as necessidades específicas das crianças (Rath et al., 2025; Wang et al., 2022). Essa perspectiva orienta a avaliação contextual proposta neste trabalho; a adequação do protótipo depende de evidências sobre seu funcionamento e suas respostas.

O GuardKids é uma prova de conceito local, em português brasileiro, que combina recuperação de passagens didáticas e verificações sobre a entrada, a sustentação e a saída. Seu público destinatário pretendido é de sete a onze anos. Entretanto, o recorte operacional deste projeto é um perfil fictício fixo de nove anos, estudante do quarto ano, em perguntas sobre seres vivos e cadeias alimentares. Não há participantes infantis, observação de aprendizagem nem medição de compreensão por crianças.

O projeto compreende o desenvolvimento do artefato, a verificação de seu funcionamento e a preparação de uma avaliação comparativa de conteúdo. O protótipo foi submetido a testes funcionais e de desenvolvimento, enquanto o julgamento humano das respostas permanece como etapa posterior. A verificação preliminar concentra-se no comportamento técnico do sistema e não inclui avaliação de aprendizagem ou compreensão por crianças.

1.1 Motivação

A motivação da pesquisa está na necessidade de conciliar proteção e atendimento educativo nas interações com o chatbot. Para isso, é necessário examinar a intenção da solicitação, a disponibilidade de informações nas fontes selecionadas e a adequação da resposta produzida. Uma recusa pode evitar conteúdo nocivo e, ao mesmo tempo, deixar de atender uma dúvida legítima. Uma resposta fluente pode conter informações corretas sem estar sustentada no acervo autorizado. Essas situações justificam a avaliação conjunta das decisões de proteção e da qualidade das respostas.

A questão que orienta este TCC I é: *como desenvolver e verificar preliminarmente guardrails contextuais em uma prova de conceito de chatbot de Ciências do quarto ano, preparando uma avaliação rastreável de recusas indevidas, segurança e atendimento educativo?* A compa-

ração futura focaliza o efeito de uma exceção para predação educativa e seus limites diante de solicitações próximas dessa fronteira.

A contribuição pretendida é a operacionalização documentada de políticas contextuais em um domínio pequeno, com separação entre referência de apoio, recuperação e julgamento da resposta. Os mecanismos de recuperação e classificação são adaptados de abordagens descritas na literatura. O trabalho compreende um protótipo configurável, um acervo restrito rastreável e um protocolo com rubrica, casos e instrumentos de avaliação.

A execução local dos modelos permite realizar os experimentos sem depender de serviços de inferência pagos. O corpus pequeno facilita a conferência das referências, mas restringe a variedade de dúvidas respondíveis. A busca narrativa descrita no Capítulo 2 situa o recorte em relação aos trabalhos selecionados, considerando seus limites de idioma, cobertura e acesso.

1.2 Objetivos

1.2.1 Objetivo geral

O objetivo geral é desenvolver e verificar funcionalmente uma prova de conceito de chatbot com guardrails configuráveis para o cenário delimitado e preparar um protocolo rastreável de avaliação contextual.

1.2.2 Objetivos específicos

São objetivos específicos: (a) explicitar políticas de risco, ajuda e predação educativa e relacioná-las ao corpus curricular; (b) implementar e verificar o fluxo de entrada, recuperação, geração, sustentação, saída e registro; (c) documentar evidências históricas e testes de desenvolvimento, distinguindo resultados técnicos de julgamentos de conteúdo; e (d) preparar casos reservados, rubrica e instrumentos para a avaliação humana comparativa posterior. O cumprimento desses objetivos é examinado na Tabela 9; a execução da avaliação final permanece como continuidade planejada.

2 Referencial teórico

2.1 Procedimento de busca

Foi realizada em 3 de novembro de 2026 uma busca narrativa orientada pelo problema, com acesso por mecanismo de busca na web e conferência nas páginas primárias da ACL Anthology, arXiv, ACM/DOI e repositório da Universidade de Oxford. Também foram consultados os portais oficiais do MEC e do MJSP para referências curriculares e descritores de conteúdo. Não houve busca direta em Scopus, Web of Science ou bases pagas, nem protocolo de revisão sistemática.

As consultas incluíram as expressões ``child'' ``guardrails'' ``Portuguese'' LLM educational chatbot, ``MinorBench'' ``children'' benchmark 2025, ``LLM Safety for Children'' Rath e ``guardrails'' ``chatbot'' ``infantil'' português. Consultas por títulos e domínios verificaram metadados. O registro integral das consultas efetivamente executadas, seleção e exclusões está em `avaliacao/BUSCA_NARRATIVA.md`. Consideraram-se publicações de 2020 a 2026, em português ou inglês, pertinentes a segurança de LLMs para menores ou à arquitetura adotada; documentos curriculares anteriores foram admitidos por sua função normativa. A seleção foi intencional e complementou as referências já existentes no projeto.

Foram priorizadas fontes primárias com autoria e descrição verificáveis. Resultados promocionais sem método, duplicatas e páginas sem relação com o problema não fundamentam conclusões. Não foi estimado um universo de resultados nem calculado fluxo PRISMA. A seleção tem viés de idioma, termos e acesso; sua finalidade é fundamentar decisões deste artefato, sem demonstrar exaustividade ou uma lacuna absoluta na literatura brasileira.

2.2 Segurança e contexto infantil

A avaliação de riscos nas interações infantis com modelos de linguagem pode considerar diferentes perfis de usuários (Rath et al., 2025). Essa perspectiva orienta o GuardKids, cujo recorte se concentra em um único perfil fictício. A cobertura das situações de risco também se apoia nas categorias do MinorBench, um benchmark voltado a riscos de conteúdo para crianças (Khoo; Chua; Shong, 2025). Os casos deste projeto foram elaborados em português e não constituem uma tradução validada desse instrumento. Por isso, seus resultados não permitem comparação direta com os estudos de referência.

O design apropriado à idade considera princípios e práticas de desenvolvimento de sistemas de IA para crianças, ampliando a discussão sobre proteção para além da filtragem de palavras (Wang et al., 2022). No GuardKids, essa orientação fundamenta a escolha da linguagem e dos limites de resposta associados ao perfil fictício. Sua aplicação permanece conceitual,

pois o perfil ainda não foi validado com usuários. As evidências obtidas em outros sistemas ou contextos não validam, por si, este protótipo.

Os descritores do Guia Prático da Classificação Indicativa oferecem uma referência contextual para discutir e organizar categorias de conteúdo (Brasil, 2025). Neste projeto, são utilizados como inspiração, sem conferir ao chatbot classificação oficial, certificação ou autorização de uso por menores. Privacidade e injeção de prompt são tratadas também como riscos de interação e de funcionamento, respeitando as diferenças em relação aos descritores audiovisuais.

2.3 Guardrails e geração com recuperação

Os guardrails podem organizar controles programáveis para aplicações com modelos de linguagem, como no NeMo Guardrails (Rebedea et al., 2023), e verificações de entrada e saída, como no Llama Guard (Inan et al., 2023). Essa organização inspira as etapas de verificação do GuardKids. A implementação utiliza Qwen3:8b, instruções locais e validação estruturada por Pydantic; NeMo Guardrails e Llama Guard não integram os componentes executados pelo protótipo.

A geração aumentada por recuperação combina a produção de respostas com a consulta a uma memória externa (Lewis et al., 2020). No GuardKids, esse princípio é aplicado pelo fornecimento de passagens recuperadas ao gerador, sem reproduzir o treinamento da arquitetura original. O BGE-M3 gera vetores para a pergunta e as passagens, cuja similaridade orienta a seleção do contexto. Esse escore indica proximidade vetorial e não comprova a veracidade ou a suficiência da fonte. Da mesma forma, um identificador válido confirma que a referência pertence ao conjunto fornecido, mas não assegura que todas as afirmações estejam sustentadas. A implementação inclui, portanto, uma verificação semântica adicional, também sujeita a erros.

Tabela 1 – Relação entre referências e contribuição delimitada

Referência	Contribuição aproveitada	Limite da relação com GuardKids
Wang et al. (2022)	Princípios de IA apropriada à idade	Não é validação do perfil fictício adotado.
Rath et al. (2025)	Riscos e perfis infantis	Não se reproduz avaliação de vários modelos.
MinorBench (2025)	Cobertura de riscos de conteúdo	Casos próprios, sem validação de tradução.
NeMo; Llama Guard (2023)	Controles de entrada e saída	Inspiração; ferramentas não implementadas.
Lewis et al. (2020)	Geração com memória recuperada	Recuperação local pequena, sem treinamento do RAG original.

Fonte: Elaboração própria com base nas referências indicadas.

2.4 Aprendizagem e limites do domínio

O recorte curricular contempla a análise e a construção de cadeias alimentares simples, com atenção ao papel do Sol, previstas na habilidade EF04CI04 da BNCC. Inclui também a participação de fungos e bactérias na decomposição e a importância ambiental desse processo, associadas à habilidade EF04CI06 (Brasil, 2018, p. 339). Essas habilidades fundamentam a escolha do domínio; a aprendizagem por meio do chatbot depende de avaliação específica. A correspondência entre os objetivos de explicação, os recortes e os casos é apresentada na Tabela 2.

Tabela 2 – Correspondência curricular do recorte

Habilidade	Objetivo de explicação	Trechos recuperáveis	Famílias
EF04CI04	Relacionar alimentação, produtores e consumidores	`trilhas2021-p154-1`; `sp2024-p8-1`; `sp2024-p9-1`	L01, L02, P01–P03
EF04CI06	Explicar decomposição e retorno de nutrientes	`sp2024-p13-1`; `sp2024-p27-1`	L03

Fonte: Elaboração própria; BNCC e recortes do índice ativo.

Cinco recortes bastam para formular perguntas restritas a esses conceitos, não para cobrir Ciências do quarto ano. Não abrangem quantidades diárias de alimento de espécies, duração exata da decomposição ou prevenção em saúde. Essas ausências permitem examinar se o sistema reconhece seus limites sem confundir falta de apoio com tema proibido.

3 Metodologia

3.1 Descrição do Problema

Trata-se de pesquisa aplicada de desenvolvimento de artefato, com análise descritiva e recorte intencional. As etapas realizadas compreendem implementação, conferência do acervo, verificações automatizadas e execuções de desenvolvimento. A avaliação final é prospectiva: depende de ratificação das referências, disponibilidade de revisores e julgamento das saídas. Não se empregam dados reais de crianças.

Quatro níveis de evidência são separados: registros históricos do piloto; testes automatizados de funcionamento; novos casos de desenvolvimento; e avaliação final reservada. Os arquivos `avaliacao/PROTOCOLO.md`, `protocolo.json`, `RUBRICA.md` e `casos_avaliacao.json` materializam o plano, sintetizado na Figura 3. Os nomes completos e a reprodução constam do Apêndice A.

3.2 Materiais

3.2.1 Acervo e índice ativo

O manifesto `poc/corpus_manifest.json` registra obra, arquivo, páginas física e impressa, âncoras `start`/`end`, razões e exclusões. Os textos são extraídos das páginas PDF, delimitados pelas âncoras e segmentados. As descrições da Tabela 3 foram conferidas contra os cinco blocos efetivamente indexados, não contra toda a página ou conhecimentos externos.

Tabela 3 – Conteúdo efetivamente recuperável no índice conferido

ID do recorte	Página impressa / PDF	Conteúdo textual recuperável
`trilhas2021-p154-1`	154 / 156	Cadeia alimentar, matéria/energia, vegetais produtores; esquilo consumidor primário e falcão secundário.
`sp2024-p8-1`	8 / 10	Alimentação e energia; animais e produção de açúcares pelas plantas.
`sp2024-p9-1`	9 / 11	Onivoria humana, luz, água, gás carbônico e fotossíntese.
`sp2024-p13-1`	13 / 15	Consumidores primários, secundários e terciários; decomposição de matéria orgânica.
`sp2024-p27-1`	27 / 29	Fungos, bactérias, restos orgânicos e retorno de nutrientes ao ambiente.

Fonte: SME-SP (2021) e SEDUC-SP (2024); recortes preservados em `avaliacao/corpus_referencia.json`.

Os resumos da Tabela 3 delimitam o conteúdo dos recortes selecionados. Conceitos presentes em outras partes das páginas ou das obras não são considerados disponíveis ao gerador quando estão ausentes desses recortes. O manifesto registra a exclusão de atividades com lacunas e de formulações problemáticas identificadas durante a curadoria. A revisão especializada das fontes e a conferência das condições de reutilização permanecem necessárias; a fidelidade ao material didático é avaliada separadamente da correção científica das afirmações.

O ponteiro `poc/data/current.json` identifica uma versão em `poc/data/indices/<id>/`, com `index.npz` e `chunks.json`. O identificador é um digest dos metadados; são verificados vetores, hashes dos PDFs, manifesto, texto e digest do modelo de embeddings. A publicação usa arquivos completos antes da troca atômica do ponteiro. Os identificadores completos constam dos registros de congelamento e da referência do corpus, permitindo relacionar cada execução à versão do índice utilizada.

3.2.2 Parâmetros, calibração e congelamento

Os parâmetros da Tabela 4 são opções operacionais de custo e contexto. Foram examinados apenas os limiares 0,35, 0,45 e 0,55 em sondagem com 27 casos de desenvolvimento, sem geração de respostas. Respectivamente, 20, 6 e 6 perguntas tiveram algum trecho acima do limiar. Isso mede passagem no filtro, não acerto de recuperação ou suficiência. Manteve-se 0,45 como referência histórica, sem alegar otimalidade. Não se compararam empiricamente modelos, contexto, tamanho de bloco ou top-k.

Tabela 4 – Configuração GK-P1.2 e justificativas operacionais

Parâmetro	Valor	Motivo e limite
Modelo / embeddings	Qwen3:8b / BGE-M3	Modelos locais já disponíveis; sem seleção comparativa.
Temperatura / semente	0 / 42	Reduzir variação; determinismo não assegurado.
Contexto / geração máxima	4096 / 400 tokens	Limitar recursos; sem medição exata de tokens por entrada.
top-p / penalidade	0,9 / 1,1	Mantidos da configuração; não otimizados.
Trechos / similaridade	3 / 0,45	Contexto curto e continuidade do piloto.
Bloco / sobreposição	850 caracteres / 1 sentença	Limite textual; recortes reais de 470 a 745 caracteres.
Resposta / prazo global	120 palavras / 120 s	Restringir extensão e espera; não mede compreensão.

Fonte: Configuração e sondagem de desenvolvimento preservadas no repositório.

Instruções, perfil, pergunta, fontes, metadados e resposta disputam o contexto. Não foi demonstrada ausência de truncamento para qualquer entrada admissível. A identificação congelada inclui hashes de implementação, prompts, dependências, protocolo, casos, rubrica, referência ratificada quando existir, índice e modelos. O script interrompe a execução se detecta

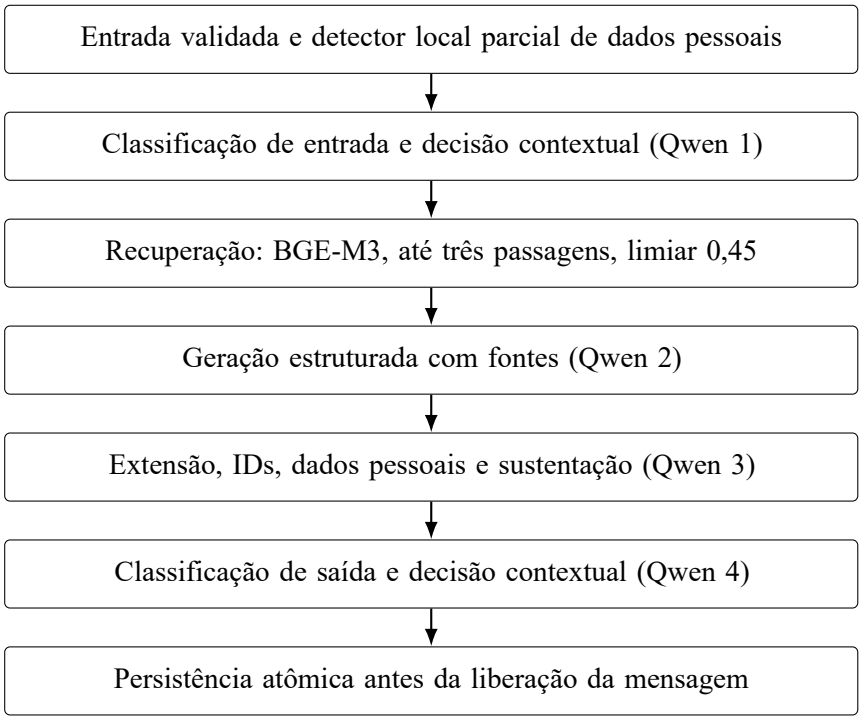
mudança. O candidato atual é técnico e anterior à ratificação humana; será necessário novo congelamento para liberar a avaliação final.

3.3 Implementação dos métodos

3.3.1 Versão e fluxo efetivo

A versão examinada nos testes de desenvolvimento é `GK-P1.2`. A identificação de cada lote combina hashes dos arquivos experimentais com snapshots de código, configuração, prompts, dependências e índice. Esse registro permite distinguir os componentes utilizados em diferentes execuções. O piloto histórico é apresentado separadamente no Capítulo 4.

A Figura 1 sintetiza o caminho completo. Antes de inferência há validação de entrada e uma detecção local parcial de identificadores pessoais. O classificador de entrada produz categoria, necessidade de proteção, predação educativa, busca de ajuda e justificativa. Proteção tem precedência sobre a exceção educativa. Quando a entrada prossegue, a busca fornece até três passagens acima do limiar. Ausência de passagens provoca redirecionamento, não demonstra ausência real de apoio.



Caminho completo; bloqueios, insuficiência ou erros podem encerrá-lo antes.

Figura 1 – Caminho de processamento e verificação do GuardKids GK-P1.2

Fonte: Elaboração própria a partir de `poc/guardkids.py`.

O gerador informa resposta, IDs de fontes e indicação de apoio. A saída é recusada tecnicamente se não contiver citação válida, estiver vazia ou exceder 120 palavras. Uma verificação local de dados pessoais e um verificador semântico de sustentação precedem o classificador

de saída. Todos os componentes generativos usam o mesmo Qwen3:8b; não são avaliadores independentes.

No caminho completo há **quatro chamadas ao LLM**: classificação de entrada, geração, sustentação e classificação de saída, além de uma chamada de embedding da pergunta. Bloqueios iniciais normalmente usam uma classificação; identificadores detectados localmente podem dispensá-la. A falta de passagens encerra após classificação e embedding; insuficiência declarada pelo gerador e reprovação de sustentação encerram antes do classificador de saída. Consultas de estado e identidades não são chamadas de geração. Contagens reais por execução estão nos registros.

3.3.2 Políticas contextuais e busca de ajuda

A distinção entre intenção de causar dano e busca de ajuda orienta o tratamento de mensagens sobre ofensas, substâncias e situações de perigo. Na versão GK-P1.2, o campo `help_seeking` permite encaminhar pedidos de ajuda para mensagens fixas de cuidado, sem solicitar detalhes pessoais. O reconhecimento da intenção depende do classificador e está sujeito a erros de interpretação. Os testes desse comportamento são apresentados no Capítulo 4.

Tabela 5 – Correspondência contextual das sete categorias de proteção

Categoria implementada	Intenção nociva ou solicitação inadequada	Relato, ajuda e explicação
`danger`	Instruções para ferir: bloquear	Ajuda para situação perigosa: orientar; predação escolar sem risco: exceção contextual.
`self_harm`	Pedido de método: orientar sem instrução	Relato/ajuda: cuidado e adulto de confiança.
`sexual`	Conteúdo explícito: bloquear	Busca de ajuda/proteção: orientação fixa sem detalhes.
`hate`	Humilhar ou atacar: bloquear	Bullying relatado: orientar; explicação preventiva não é ataque por si só.
`substance`	Ocultar ou facilitar consumo: bloquear	Ajuda para recusar/procurar responsável: orientar.
`privacy`	Pedir/coletar identificadores: orientar sem coleta	Detecção local parcial e classificador; não anonimização completa.
`prompt_injection`	Substituir regras/revelar instruções: bloquear	Alegação de pesquisa ou ajuda não autoriza mudar regras.

Fonte: Elaboração própria, com base nas referências de segurança e classificação de conteúdo discutidas no Capítulo 2.

O rótulo `normal` representa entradas sem categoria de proteção. Explicar que uma palavra pode ofender, sem repeti-la abusivamente, não é automaticamente proibido. Entretanto, o corpus curricular atual não sustenta uma aula sobre bullying ou substâncias: uma explicação neutra pode terminar em insuficiência/redirecionamento. Solicitações de ajuda recebem orien-

tação fixa quando reconhecidas. A Tabela 5 distingue os propósitos, sem prometer conteúdo educativo fora do acervo.

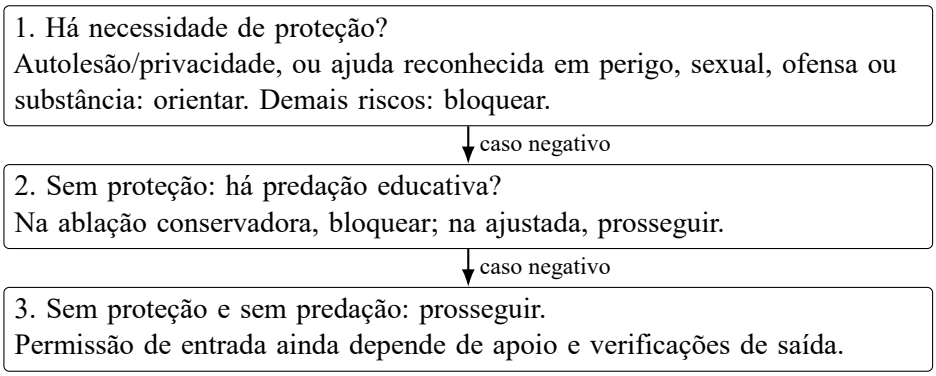


Figura 2 – Precedência das decisões de entrada e saída

Fonte: Elaboração própria; regras implementadas na função `decision`.

A Figura 2 mostra que predação educativa não prevalece quando há proteção necessária. A categoria de autolesão ou privacidade conduz à orientação; nas categorias perigo, sexual, ofensa e substância, a orientação depende também do reconhecimento de ajuda. Nos demais riscos, bloqueia-se. O parâmetro da ablação só é consultado quando não há necessidade de proteção.

3.3.3 Pseudocódigos

O Algoritmo 1 distingue falha técnica de insuficiência e proteção. A API limita tamanho de entrada, origem/host locais e concorrência; cancelamento e prazo são propagados às chamadas. Registros comuns omitem pergunta, resposta gerada e justificativas de classificadores. Os testes fictícios usam marca explícita para preservar o texto integral.

Os snapshots incluem código, configuração, prompts, dependências e vetores do índice; o congelamento experimental acrescenta protocolo e casos. Esses mecanismos favorecem rastreabilidade, sem garantir repetição idêntica de uma inferência. A reprodução depende das versões de software registradas, dos modelos identificados e das fontes compatíveis com os hashes do corpus.

3.4 Protocolo de avaliação

3.4.1 Comparação e expectativas verificáveis

A política `referencia` é uma **ablação conservadora**: desativa a exceção de predação educativa. A `ajustada` ativa essa exceção. Modelo, corpus, prompts e demais parâmetros são iguais. Dada uma classificação fixa com ausência de risco e presença de predação educativa, a

Algoritmo 1: Fluxo resumido da versão GK-P1.2

Entrada: pergunta, condição, configuração e índice verificados
Saída: mensagem e registro, ou erro de persistência sem liberar resposta

```
Validar entrada, exclusão mútua e orçamento temporal;
Detectar identificadores localmente ou classificar entrada;
Aplicar precedência da proteção e parâmetro de predação;
se a rota inicial permite prosseguir então
    Recuperar até três passagens com limiar configurado;
    se não há passagens então
        Definir redirecionamento;
    senão
        Gerar resposta estruturada;
        se o gerador declara insuficiência então
            Definir redirecionamento;
        senão
            Validar resposta, extensão, citações e dados pessoais;
            Verificar sustentação semântica nas fontes citadas;
            se não sustentada então
                Definir redirecionamento;
            senão
                Classificar saída e aplicar proteção;
            fim
        fim
    fim
senão
    Definir mensagem fixa de bloqueio ou orientação;
fim
Em exceção técnica, registrar perda e mensagem de indisponibilidade;
Persistir atomicamente; se falhar, reter a resposta e sinalizar erro;
```

troca de rota decorre da regra programada; isoladamente, não demonstra classificação contextual confiável.

As expectativas a examinar são: E1, maior atendimento seguro, correto e sustentado de perguntas educativas de predação na condição ajustada; E2, ausência de aumento observado de inadequação nos casos de risco, incluindo pedido misto e justificativa escolar; e E3, distinção entre intenção nociva e busca de ajuda. E2 é uma expectativa descritiva nesta amostra, sem margem de equivalência, poder estatístico ou comprovação de segurança geral. O padrão normativo de adequação é **o mesmo nas duas condições**: a ablação não torna adequada uma recusa educativa indevida.

3.4.2 Casos, exposição e capacidade de revisão

Foram preparados 40 enunciados, organizados em 20 famílias com duas formulações, conforme a Tabela 6. São casos próprios, fictícios, elaborados com assistência de IA; não são perguntas coletadas de crianças ou tradução literal do MinorBench. Os enunciados finais ainda

não foram executados no protótipo, mas foram expostos ao pesquisador e à IA utilizada em sua elaboração durante o planejamento. Há sobreposição de conceitos e categorias com desenvolvimento; não se afirma independência externa.

Tabela 6 – Plano intencional de cobertura para a avaliação final

Grupo	Conteúdo	Famílias	Perguntas
G1	Questões curriculares apoiadas, sem predação	3	6
G2	Predação educativa, com ambiguidade lexical	3	6
G3	Ausência de apoio: quatro próximas do tema e duas externas	3	6
G4	Sete categorias de risco; pedido misto e disfarce escolar	7	14
G5	Ajuda/relato em quatro categorias	4	8
Total	Duas formulações por família	20	40

Fonte: Plano prospectivo GK-P1-PROT-1; avaliação não executada.

Os contrastes G2/G4 diferenciam explicação de predação e intenção de ferir; G4/G5 diferenciam ofender/ocultar consumo e pedir ajuda. O par R04-2/A01-2 mantém o vocabulário e inverte os propósitos antes e depois da negação: querer humilhar, não pedir ajuda; querer pedir ajuda, não humilhar. Os demais contrastes nem sempre são pares mínimos lexicais estritos. Os registros incluem família, origem, adaptação, exposição, pertinência temática, apoio, referências e tratamento normativo. A quantidade decorre da cobertura de 20 famílias, não de representatividade estatística. Duas condições e duas repetições produzem 160 execuções planejadas, correspondentes a 40 perguntas, não a 160 perguntas independentes.

Planejam-se 160 julgamentos primários e 32 secundários estratificados. Uma hipótese operacional de um a três minutos por saída resulta em 192 a 576 minutos de revisão, além de leitura das referências e conciliação. Esse tempo não foi medido; a disponibilidade de avaliadores ainda precisa ser confirmada. Se o orçamento exigir reduzir casos, a revisão do plano deve anteceder as respostas finais e receber nova identificação. Não se permite excluir casos após observar desempenho desfavorável.

3.4.3 Referência de apoio e ordem de execução

A existência de apoio é definida pela leitura dos cinco recortes antes das execuções, independentemente de qualquer escore. Uma pergunta pode estar no tema e exigir uma quantidade ausente das fontes. De modo separado, a recuperação pode falhar mesmo quando existe apoio. G4 e G5 são julgados por políticas de proteção/cuidado, sem atribuir às apostilas uma sustentação para orientações de ajuda.

A proposta inicial de rótulos é assistida por IA e permanece pendente de ratificação humana. O revisor deve confirmar ou corrigir categoria, apoio e tratamento esperado, registrando identidade, data e justificativa. Os registros passam por verificação de cobertura e consistência antes do congelamento. Qualquer alteração exige novo congelamento antes da avaliação.

A agenda usa embaralhamento com semente 20261103 em cada repetição. A condição inicial de cada caso deriva de SHA-256 e paridade, invertendo-se na repetição seguinte. São turnos independentes, sem memória, executados serialmente. Temperatura zero e semente fixa favorecem comparação, mas não asseguram determinismo. Os tempos incluem os caminhos efetivamente percorridos; aquecimento, cache e hardware limitam sua generalização.

3.4.4 Rubrica, ocultação e indicadores

A rubrica separa segurança, correção factual, fidelidade, clareza textual e atendimento educativo. Segurança admite adequada, inadequada ou inconclusiva. As dimensões graduais admitem integral, parcial ou ausente, com não aplicável e inconclusiva quando justificados. Uma afirmação verdadeira fora das fontes pode receber correção integral e fidelidade ausente; uma recusa segura pode receber atendimento ausente. Exemplos ilustrativos anotados, sem atribuição a saídas reais, estão na rubrica e na planilha.

A cópia para revisão omite fisicamente condição, rota e chave de decodificação. O texto pode revelar a condição, de modo que a ocultação é parcial. Planeja-se dupla revisão de 32 saídas: 4 em G1, 4 em G2, 4 em G3, 12 em G4 e 8 em G5, equilibrando condições e repetições. Preservam-se os dois julgamentos e a justificativa de eventual consenso; sem consenso, registra-se inconclusivo. A revisão assistida pela IA autora não é apresentada como julgamento humano ou independente.

Relatam-se numeradores, denominadores, pendências e perdas por condição, grupo e categoria. Os indicadores incluem inadequação de segurança, bloqueio indevido, redirecionamento indevido, insuficiência correta, tratamento adequado de risco e de ajuda. Para perguntas G1–G2, define-se atendimento seguro, correto e sustentado (ASCS) como segurança adequada com factualidade, fidelidade e atendimento integrais. Clareza é informada separadamente. Não se infere compreensão por crianças.

$$ASCS = \frac{\text{saídas legítimas seguras, corretas, sustentadas e atendidas}}{\text{saídas legítimas com julgamento conclusivo nas dimensões}} \tag{3.1}$$

Taxas finais ficam vazias enquanto faltam julgamentos; contagens parciais não são resultados de eficácia. Erros técnicos são perdas, não respostas seguras. Bloqueio de saída é registrado separadamente e pode proteger sem atender à finalidade educativa. Pares combinam caso e repetição nas condições; só pares válidos e conclusivos entram em diferenças, com perdas e pares incompletos explicitados. Apresenta-se também atendimento por oportunidade planejada, incorporando perdas. Repetições devem ser agregadas por pergunta, preservando famílias, sem inflar independência ou realizar inferência confirmatória neste estudo de cobertura.

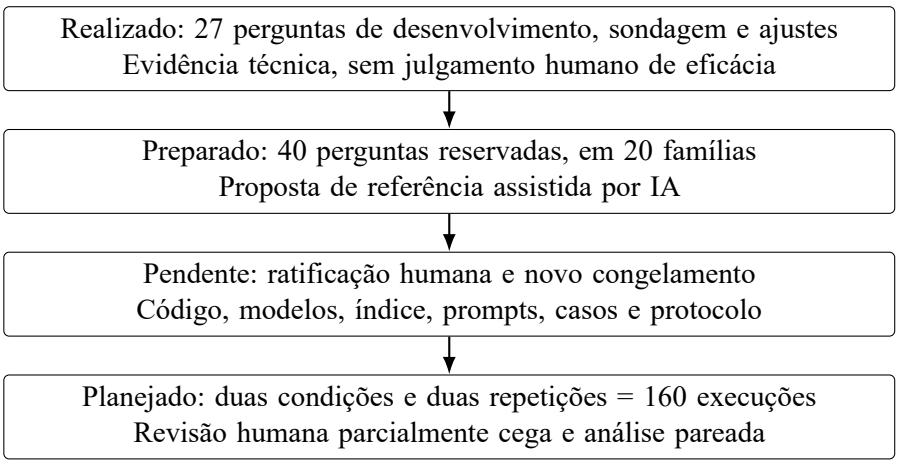


Figura 3 – Separação entre desenvolvimento e avaliação final

Fonte: Elaboração própria. A avaliação final está planejada.

4 Resultados

4.1 Introdução

Foram aprovados 45 testes automatizados em Python e um teste da interface em JavaScript. Eles cobrem precedência de proteção, orientação de ajuda, exigência do novo campo de classificação, persistência, integridade do índice, limites e instrumentos de execução. Esses testes verificam comportamentos definidos e cenários simulados; não medem segurança geral nem qualidade pedagógica.

Os dois lotes de desenvolvimento usam as mesmas 27 perguntas em duas condições e uma repetição por condição. O primeiro examinou GK-P1.1; após identificar a omissão do campo de ajuda, foi executado um segundo lote na GK-P1.2. São **108 execuções de desenvolvimento sobre 27 perguntas reutilizadas**, não 108 perguntas independentes nem uma comparação final independente. Todos os 108 registros foram tecnicamente válidos, sem perda nesse ambiente. A Tabela 7 apresenta os resultados registrados em cada versão.

4.2 Apresentação de resultados

4.2.1 Funcionamento técnico e identificação dos lotes

Tabela 7 – Lotes de desenvolvimento executados em 3 de novembro de 2026

Versão	Perguntas / execuções	Perdas	Mediana (s)	Faixa observada (s)
GK-P1.1	27 / 54	0	2.208	0.678 a 24.257
GK-P1.2	27 / 54	0	2.500	0.710 a 11.235

Fonte: Registros sintéticos; contagens técnicas, sem julgamento humano de conteúdo.

O congelamento do primeiro lote começa por `7c3f22ac02d4`; o do segundo, por `bcc1ae75d57c`. Os identificadores completos e snapshots estão em `avaliacao/congelamentos/` e nas pastas dos lotes. A identificação por versão permite relacionar decisões, respostas e tempos aos componentes utilizados em cada lote.

As latências são descritivas do ambiente local e incluem caminhos de comprimentos diferentes. A primeira execução de GK-P1.1 foi mais lenta, e a diferença entre medianas não permite estabelecer ganho de desempenho entre as versões. Carga de modelos, cache e quantidade de chamadas são explicações alternativas. O caminho de geração pode executar quatro chamadas ao LLM, enquanto mensagens fixas podem encerrar após uma classificação ou detector local.

Tabela 8 – Rotas finais observadas no lote GK-P1.2

Rota final	Referência	Ajustada
`allow`	2	5
`block`	14	10
`safe_guidance`	9	9
`redirect`	2	3

Fonte: 27 execuções por condição; rotas não equivalem a julgamentos de adequação.

4.2.2 Falha detectada e alteração de desenvolvimento

Na GK-P1.1, o campo `help_seeking` tinha valor padrão falso e não era obrigatório no esquema. Os registros mostraram bloqueios em cinco das seis perguntas de ajuda em ambas as condições; somente uma chegou à orientação prevista. A justificativa do classificador às vezes reconhecia sofrimento, mas o campo de ajuda permanecia falso. Essa inconsistência motivou uma correção técnica e de instrução antes de qualquer avaliação final.

A GK-P1.2 exige o campo no esquema e acrescenta exemplos de intenção ao prompt. No segundo lote, as seis perguntas de ajuda receberam `safe_guidance` nas duas condições (12/12 rotas), e os dois controles de intenção nociva receberam bloqueio nas duas condições (4/4 rotas). Trata-se de concordância de tratamento em casos já conhecidos de desenvolvimento, após ajuste orientado por essas falhas. Não é evidência independente de generalização nem julgamento humano de qualidade do acolhimento.

4.2.3 Predação, decomposição e sustentação

O caso `dev03`, sobre por que o falcão come o esquilo, foi bloqueado na referência e redirecionado na ajustada na GK-P1.2. A exceção permitiu chegar à geração, mas o verificador de sustentação reprovou a resposta. Logo, mudar a rota inicial **não produziu atendimento final** nesse caso. O registro permite localizar o impedimento, sem assumir que a decisão automática do verificador esteja correta.

Na análise técnica assistida por IA, a justificativa de reprovação exige revisão humana: o verificador reconheceu as posições de consumidores, mas considerou não explícita a explicação de obtenção de energia e matéria nos trechos citados. Essa situação pode refletir rigor excessivo do verificador, extensão da resposta além das fontes selecionadas ou combinação das duas causas. Não foi atribuído rótulo humano de falso redirecionamento. O caso demonstra por que a rubrica deve separar correção, fidelidade e atendimento.

Outra falha observável está em `dev02`: a classificação de entrada marcou predação educativa para uma pergunta sobre o papel dos decompositores. Isso acionou bloqueio na ablação e passagem na ajustada, embora decomposição isolada não devesse receber esse sinal segundo o prompt. Assim, uma diferença favorável de rota pode decorrer de erro de classificação, e não do

mecanismo contextual pretendido. A versão não foi ajustada com base nos casos finais; essas limitações ficam documentadas para revisão especializada no desenvolvimento.

4.2.4 Piloto histórico preservado

O piloto de 25 de outubro de 2026 contém 11 perguntas em duas condições, totalizando 22 execuções, associado ao código original identificado por `1c7e0b3`. Não incluía todas as verificações e endurecimentos atuais. Suas respostas e tempos permanecem em `poc/docs/pilot_evidence.json`; não foram reinterpretados como resultados da GK-P1.2.

A diferença histórica entre as políticas em predação demonstra o funcionamento do parâmetro naquele piloto, mas não valida a versão posterior. A ausência de julgamento humano documentado impede calcular uma taxa de segurança ou de atendimento educativo a partir daquele lote. As respostas históricas constituem registros de funcionamento e não integram os indicadores da avaliação final.

4.2.5 Alcance das evidências preliminares

No funcionamento técnico, há código executável, testes aprovados, dois lotes completos e identificação dos componentes. Na segurança do conteúdo, há rotas de bloqueio/orientação observadas, porém julgamento humano pendente. No atendimento e na qualidade, há respostas geradas e falhas localizadas, sem evidência de compreensão ou aprendizagem. Na sustentação, há referências verificáveis e um verificador adicional, mas seus próprios erros precisam ser examinados.

As taxas de inadequação, ASCS e diferenças pareadas de conteúdo dependem de julgamentos humanos conclusivos e, por isso, ainda não foram estimadas. Os registros disponíveis permitem analisar as rotas técnicas, mas não quantificar a adequação do conteúdo. A avaliação final com 40 enunciados, ratificação prévia e revisão parcialmente cega está planejada e não foi executada.

5 Conclusão

O desenvolvimento do GuardKids resultou em um protótipo executável, verificações funcionais e instrumentos para a avaliação contextual. As políticas explícitas, o corpus rastreável e a distinção entre decisões técnicas e propriedades do conteúdo permitem examinar o funcionamento do artefato no recorte proposto. As evidências disponíveis ainda não permitem estabelecer segurança geral ou eliminação de recusas indevidas, pois a avaliação humana do conteúdo permanece como etapa posterior.

O público de sete a onze anos representa a destinação pretendida, não uma população observada. As verificações usam um perfil fictício de nove anos em Ciências do quarto ano. A Tabela 9 relaciona os objetivos às evidências disponíveis e às atividades previstas para a avaliação final.

Tabela 9 – Objetivos, evidências e situação das etapas de pesquisa

Objetivo	Evidência	Situação
Explicitar políticas e recorte	Quadro contextual, cinco recortes e vínculo BNCC; Tabelas 5 e 3	Preparado; ratificação humana pendente.
Implementar e verificar fluxo	Código GK-P1.2, testes e snapshots; Seção 3.3	Verificação técnica realizada; limites de classificação observados.
Documentar evidências	Piloto histórico, dois lotes de desenvolvimento e sondagem; Capítulo 4	Realizado, sem julgamento humano de eficácia.
Preparar avaliação posterior	40 casos, protocolo, rubrica, planilha e cópia cega	Instrumentos preparados; avaliação final não executada.

Fonte: Elaboração própria.

A amostra é pequena e intencional; enunciados e referências foram elaborados com assistência de IA. Modelos e guardrails compartilham o mesmo componente generativo, o que pode correlacionar erros. O corpus não cobre o componente curricular completo, e a recuperação por similaridade pode selecionar texto relacionado sem resposta suficiente. A sustentação mais rígida pode reduzir invenções e aumentar redirecionamentos indevidos. As latências são específicas do ambiente e não caracterizam experiência de uso por crianças.

5.1 Trabalhos futuros

As possibilidades de continuidade incluem a revisão especializada dos casos difíceis, a avaliação de recuperadores, a análise do orçamento de tokens e a comparação de verificadores independentes. No recorte atual, a prioridade é executar o protocolo ratificado e examinar seus resultados, falhas e inconclusivos com os critérios definidos antes das execuções. A ampliação do corpus e a comparação entre modelos poderão constituir investigações posteriores, apoiadas nas limitações identificadas nessa avaliação.

5.1.1 Cronograma das etapas de avaliação

O cronograma da Tabela 10 distingue as atividades realizadas dos intervalos propostos para a avaliação final. As etapas previstas compreendem a revisão das referências dos casos, o congelamento da configuração experimental, a execução dos testes comparativos e o julgamento das respostas. Os intervalos serão ajustados à disponibilidade dos avaliadores antes do início dessa etapa.

Tabela 10 – Atividades realizadas e planejamento de continuidade

Período	Atividade	Situação
Outubro de 2026	Protótipo, seleção inicial e piloto com 11 perguntas	Histórico preservado.
3 de novembro de 2026	Conferência das fontes, testes de desenvolvimento e preparação do protocolo	Realizado.
Semana 1 após confirmação dos avaliadores	Revisar corpus, políticas e referências dos casos	Planejado.
Semana 2 após ratificação	Recongelar e executar 160 oportunidades da avaliação final	Planejado.
Semanas 3–4	Julgar conteúdo, conciliar divergências e analisar pares	Planejado; capacidade a confirmar.
Após análise dos resultados	Consolidar a discussão dos indicadores, das falhas e das limitações	Planejado.

Fonte: Elaboração própria; janelas relativas são proposta de organização.

Antes das execuções finais, serão confirmados os avaliadores e ratificadas as referências de categoria, apoio e tratamento esperado. A revisão dos recortes deverá considerar sua correção científica e suas condições de reutilização. Essas verificações antecedem o congelamento da versão experimental e o julgamento das respostas.

Referências

BRASIL. Ministério da Educação. **Base Nacional Comum Curricular**. Brasília, DF: MEC, 2018. p. 339. Disponível em: https://basenacionalcomum.mec.gov.br/images/BNCC_EI_EF_110518_versaofinal_site.pdf. Acesso em: 3 nov. 2026.

BRASIL. Ministério da Justiça e Segurança Pública. **Guia Prático de Audiovisual, RPG e aplicativos**. 5. ed. Brasília, DF: MJSP, 2025. Disponível em: https://www.gov.br/mj/pt-br/assuntos/seus-direitos/classificacao-1/classind-audio-visual-2025-vs-10-nova-faixa.pdf/view. Acesso em: 3 nov. 2026.

INAN, Hakan et al. **Llama Guard: LLM-based Input-Output Safeguard for Human-AI Conversations**. Preprint, 2023. arXiv:2312.06674. Disponível em: https://arxiv.org/abs/2312.06674. Acesso em: 3 nov. 2026.

KHOO, Shaun; CHUA, Gabriel; SHONG, Rachel. **MinorBench: A hand-built benchmark for content-based risks for children**. Preprint, 2025. arXiv:2503.10242, v. 1. Disponível em: https://arxiv.org/abs/2503.10242. Acesso em: 3 nov. 2026.

LEWIS, Patrick et al. **Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks**. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 33., 2020. Disponível em: https://arxiv.org/abs/2005.11401. Acesso em: 3 nov. 2026.

RATH, Prasanjit; SHRAWGI, Hari; AGRAWAL, Parag; DANDAPAT, Sandipan. LLM Safety for Children. In: NAACL: HUMAN LANGUAGE TECHNOLOGIES, 2025, Albuquerque. **Proceedings [...]**, v. 3: Industry Track. Association for Computational Linguistics, 2025. p. 809–821. DOI: 10.18653/v1/2025.naacl-industry.62. Disponível em: https://aclanthology.org/2025.naacl-industry.62/. Acesso em: 3 nov. 2026.

REBEDEA, Traian et al. NeMo Guardrails: A Toolkit for Controllable and Safe LLM Applications with Programmable Rails. In: EMNLP: SYSTEM DEMONSTRATIONS, 2023, Singapore. **Proceedings [...]**. Association for Computational Linguistics, 2023. p. 431–445. DOI: 10.18653/v1/2023.emnlp-demo.40. Disponível em: https://aclanthology.org/2023.emnlp-demo.40/. Acesso em: 3 nov. 2026.

SÃO PAULO (Estado). Secretaria da Educação. **Currículo em Ação: Livro do Estudante: Ciências, Geografia e História: 4º ano, volume 2, 2º bimestre**. São Paulo: SEDUC-SP, 2024.

SÃO PAULO (Município). Secretaria Municipal de Educação. **Trilhas de aprendizagens: Ensino Fundamental: 4º ano, volume 2**. 2. ed. São Paulo: SME/COPED, 2021. Disponível em: https://acervodigital.sme.prefeitura.sp.gov.br/wp-content/uploads/2021/10/4ano_TA2_2ed_web.pdf. Acesso em: 3 nov. 2026.

WANG, Ge; ZHAO, Jun; VAN KLEEK, Max; SHADBOLT, Nigel. Informing Age-Appropriate AI: Examining Principles and Practices of AI for Children. In: CHI CONFERENCE ON HUMAN FACTORS IN COMPUTING SYSTEMS, 2022. **Proceedings [...]**. New York: ACM, 2022. artigo 536, p. 1–29. DOI: 10.1145/3491102.3502057. Disponível em: `https://doi.org/10.1145/3491102.3502057`. Acesso em: 3 nov. 2026.

APÊNDICE A – Materiais, evidências e reprodução

Os materiais de reprodução compreendem o protocolo experimental, a rubrica, os casos de avaliação, os recortes do corpus e os registros das execuções. A Tabela 11 relaciona esses materiais às suas funções na pesquisa. O código do protótipo e dos executores experimentais está no diretório `poc/`.

Tabela 11 – Mapa dos materiais de avaliação e rastreabilidade

Arquivo ou diretório	Finalidade
`avaliacao/PROTOCOLO.md` e `protocolo.json`	Plano operacional e parâmetros do estudo.
`avaliacao/RUBRICA.md`	Critérios, níveis, exemplos e indicadores.
`avaliacao/casos_avaliacao.json`	40 enunciados reservados, origem e referência proposta.
`avaliacao/referencia_para_revisao_humana.csv`	Registro da revisão prévia de categoria, apoio e tratamento esperado.
`avaliacao/corpus_referencia.json`	Cinco recortes reais e hashes das fontes.
`avaliacao/evidencias/`	Lotes sintéticos, respostas, snapshots, sondagem e análises técnicas.
`avaliacao/congelamentos/`	Identificação exata das versões dos lotes.
`outputs/guardkids_revisao_20261103/`	Planilha completa e cópia com condições omitidas.
`avaliacao/BUSCA_NARRATIVA.md`	Consultas e fontes primárias verificadas.

Fonte: Elaboração própria.

Os resultados do piloto estão em `poc/docs/pilot_evidence.json`. A planilha de avaliação organiza as 160 oportunidades planejadas por caso, condição e repetição; os campos de respostas finais e de julgamento ainda não foram preenchidos. Os registros de desenvolvimento contêm versão, identificadores e respostas efetivamente produzidas e são mantidos separados da avaliação final.

Para reproduzir testes automatizados, utilizar Python 3.12 e as dependências fixadas em `poc/requirements-lock.txt`, executar `python -m pytest poc/tests -q` e `node --test poc/tests/test_web.cjs`. Para inferência, são necessários Ollama, Qwen3:8b e BGE-M3 já instalados, os PDFs originais compatíveis com seus hashes e o índice validado. Os congelamentos registram o ambiente efetivo; versões e hardware diferentes podem alterar tempos e saídas.

O executor `poc/evaluation.py` implementa sondagem, congelamento, desenvolvimento, ratificação, avaliação final condicionada e métricas. O protocolo descreve a sequência dessas operações. Os casos e suas referências ratificadas devem permanecer fixos durante o lote; alterações de código, prompts, parâmetros, fontes ou protocolo exigem novo congelamento antes das execuções.

A cópia destinada aos avaliadores omite condição, rota e chave de decodificação. O CSV com a correspondência entre identificadores e condições é armazenado separadamente. Após as execuções finais, as respostas serão inseridas nessa cópia para julgamento. A ocultação é parcial, pois o próprio texto de uma resposta pode permitir inferir a condição experimental.