

CURSO DE SISTEMAS DE INFORMAÇÃO

DESENVOLVIMENTO E AVALIAÇÃO DE GUARDRAILS CONFIGURÁVEIS EM UMA PROVA DE CONCEITO DE CHATBOT EDUCATIVO DESTINADO A CRIANÇAS DE 7 A 11 ANOS EM PORTUGUÊS BRASILEIRO

FILIPE MARTINS HENRIQUE

Palmas

2026



CURSO DE SISTEMAS DE INFORMAÇÃO

DESENVOLVIMENTO E AVALIAÇÃO DE GUARDRAILS CONFIGURÁVEIS EM UMA PROVA DE CONCEITO DE CHATBOT EDUCATIVO DESTINADO A CRIANÇAS DE 7 A 11 ANOS EM PORTUGUÊS BRASILEIRO

FILIPE MARTINS HENRIQUE

Projeto de Pesquisa apresentado à disciplina de Trabalho de Conclusão de Curso I do Curso de Sistemas de Informação da Universidade Estadual do Tocantins – UNITINS, sob orientação do Prof. Marcos Souza.

Palmas
2026

Resumo

Chatbots educativos baseados em grandes modelos de linguagem podem gerar conteúdo inadequado, recusar dúvidas legítimas ou acrescentar informações sem apoio documental. Este Projeto de Pesquisa/TCC I desenvolve e verifica preliminarmente uma prova de conceito com guardrails contextuais em português brasileiro, destinada a crianças de sete a onze anos, mas operada somente com perfil fictício de nove anos e sem participantes infantis. O artefato local combina Qwen3:8b, recuperação com BGE-M3 e verificações de entrada, sustentação e saída. A versão atual organiza Ciências, História, Geografia e questões gerais sob uma regra de proteção comum e compara os estilos Direto e Passo a passo. O acervo contém cinco recortes didáticos e três sínteses experimentais, revisadas com assistência de IA. Foram executadas 32 tentativas sobre 16 perguntas de desenvolvimento, sem perdas técnicas: oito respostas liberadas, seis bloqueios, dez orientações de cuidado e oito comunicações de apoio insuficiente. A concordância das rotas com as referências propostas não equivale à qualidade do conteúdo. A inspeção assistida pela IA autora apontou ressalvas de sustentação em cinco das oito explicações liberadas e não demonstra superioridade de linguagem ou compreensão infantil. Os 108 registros históricos de duas versões anteriores permanecem separados. Como continuidade, prepararam-se 32 enunciados em 16 famílias, 64 oportunidades e procedimentos de ratificação e congelamento. A avaliação final e os julgamentos humanos independentes permanecem pendentes. A contribuição é a implementação rastreável de proteção contextual e a separação entre tratamento técnico, segurança, fidelidade e clareza.

Palavras-chave: Guardrails. Chatbot educativo. Segurança infantil. Geração aumentada por recuperação.

Abstract

Educational chatbots based on large language models may produce inappropriate content, refuse legitimate questions, or add claims unsupported by their sources. This research proposal develops and preliminarily verifies a Brazilian Portuguese proof of concept with contextual guardrails, intended for children aged seven to eleven but operated only with a fictional nine-year-old profile and no child participants. The local artifact combines Qwen3:8b, BGE-M3 retrieval, and input, grounding, and output checks. The current version provides Science, History, Geography, and general-question spaces under one protection rule while comparing Direct and Step-by-step response styles. Its corpus contains five textbook excerpts and three experimental summaries reviewed with AI assistance. A development batch completed 32 attempts on 16 questions without technical losses: eight released answers, six blocks, ten fixed care messages, and eight insufficient-support messages. Agreement between routing and proposed references does not establish content quality. Inspection assisted by the authoring AI flagged source-support issues in five of the eight released explanations and does not demonstrate stylistic superiority or children's comprehension. The 108 historical records from two earlier versions remain separate. A prospective set of 32 questions in 16 families, 64 opportunities, and reference-ratification and freezing procedures was prepared. Final evaluation and independent human content judgments remain pending. The contribution is a traceable implementation of contextual protection that distinguishes technical treatment, safety, source fidelity, and clarity.

Keywords: Guardrails. Educational chatbot. Child safety. Retrieval-augmented generation.

Lista de ilustrações

Figura 1 – Dilema de calibração entre proteção e atendimento educativo 10
Figura 2 – Análise contextual da intenção e do tratamento da solicitação 14
Figura 3 – Preparação do índice e consulta ao acervo do chat selecionado 20
Figura 4 – Arquitetura do GuardKids e rotas de processamento e registro 22
Figura 5 – Percurso de uma pergunta e pontos de encerramento no GuardKids 23
Figura 6 – Precedência das decisões de entrada e saída 25
Figura 7 – Separação entre histórico, desenvolvimento executado e avaliação final planejada 27

Lista de tabelas

Tabela 1 – Correspondência curricular do recorte inicial de Ciências 17
Tabela 2 – Decisões do GuardKids fundamentadas na literatura 17
Tabela 3 – Conteúdo do acervo atual por chat 19
Tabela 4 – Parâmetros mantidos no novo lote 19
Tabela 5 – Correspondência contextual das sete categorias de proteção 24
Tabela 6 – Cobertura proposta para a avaliação final multidisciplinar 28
Tabela 7 – Rotas do novo lote, sem agrupamento com o histórico 30
Tabela 8 – Lotes de desenvolvimento executados em 3 de novembro de 2026 32
Tabela 9 – Rotas finais observadas no lote GK-P1.2 32
Tabela 10 – Objetivos, evidências e situação atual 35
Tabela 11 – Etapas realizadas e continuidade proposta 36

Lista de abreviaturas e siglas

ASCS	Atendimento seguro, correto e sustentado
BNCC	Base Nacional Comum Curricular
IA	Inteligência artificial
JSON	JavaScript Object Notation
LLM	Large Language Model
PoC	Prova de conceito
RAG	Retrieval-Augmented Generation
SHA-256	Secure Hash Algorithm de 256 bits
TCC	Trabalho de Conclusão de Curso
UNITINS	Universidade Estadual do Tocantins

Sumário

1 INTRODUÇÃO 9
1.1 Motivação 9
1.2 Objetivos 11
1.2.1 Objetivo geral 11
1.2.2 Objetivos específicos 11

2 REFERENCIAL TEÓRICO 12
2.1 Seleção e alcance da literatura 12
2.2 Proteção infantil e interpretação da intenção 12
2.3 Guardrails de entrada e de saída 13
2.4 Recuperação de informação e sustentação das respostas 15
2.5 Clareza da explicação e recorte curricular 16
2.6 Síntese e implicações para a pesquisa 17

3 METODOLOGIA 18
3.1 Descrição do Problema 18
3.2 Materiais 18
3.2.1 Acervo e revisão documental 18
3.2.2 Parâmetros e rastreabilidade 19
3.3 Implementação dos métodos 20
3.3.1 Versão e fluxo efetivo 20
3.3.2 Políticas contextuais e busca de ajuda 21
3.3.3 Pseudocódigos 24
3.4 Protocolo de avaliação 26
3.4.1 Desenvolvimento e comparação pareada 26
3.4.2 Conjunto reservado e plano final 27
3.4.3 Rubrica e condições para liberação 28
3.4.4 Indicadores e tratamento das perdas 29

4 RESULTADOS 30
4.1 Introdução 30
4.2 Apresentação de resultados 30
4.2.1 Lote atual: regra comum e dois estilos 30
4.2.2 Histórico de Ciências 31
4.2.2.1 Funcionamento técnico e identificação dos lotes 31
4.2.2.2 Falha detectada e alteração de desenvolvimento 32
4.2.2.3 Predação, decomposição e sustentação 33

4.2.2.4 Piloto histórico preservado 33
4.2.3 Alcance das evidências preliminares 33

5 CONCLUSÃO 35
5.1 Trabalhos futuros 36
5.1.1 Cronograma das etapas de avaliação 36

Referências 37

APÊNDICE A – MATERIAIS, EVIDÊNCIAS E REPRODUÇÃO . . 39
A.1 Compilação e materiais do manuscrito 39
A.2 Execução local e conferência do índice 39
A.3 Avaliação humana planejada 40

1 Introdução

O desenvolvimento de chatbots educativos destinados a crianças exige cuidados com a segurança do conteúdo, a adequação da linguagem e a pertinência das respostas ao contexto escolar. Nesse cenário, os mecanismos de proteção precisam reconhecer solicitações potencialmente nocivas e preservar o atendimento a dúvidas legítimas. Este trabalho aborda esse desafio por meio de guardrails configuráveis, entendidos como regras e verificações que orientam e restringem o comportamento de uma prova de conceito de chatbot em português brasileiro.

Grandes modelos de linguagem produzem respostas abertas e podem gerar erros ou conteúdo inadequado. Guardrails de entrada e saída procuram limitar esses comportamentos, mas seus próprios classificadores também podem errar. A avaliação desses sistemas precisa considerar os riscos das interações com menores e as necessidades específicas das crianças (Rath et al., 2025; Wang et al., 2022). Essa perspectiva orienta a avaliação contextual proposta neste trabalho; a adequação do protótipo depende de evidências sobre seu funcionamento e suas respostas.

A prova de conceito (PoC) desenvolvida neste trabalho opera localmente, em português brasileiro, e combina recuperação de passagens didáticas e verificações sobre a entrada, a sustentação e a saída. Seu público destinatário pretendido é de sete a onze anos. Entretanto, o recorte operacional deste projeto é um perfil fictício fixo de nove anos, estudante do quarto ano, em quatro chats de acervo restrito: Ciências, História, Geografia e Geral. O recorte inicial de Ciências foi ampliado durante o desenvolvimento, preservando separadamente suas evidências históricas. Não há participantes infantis, observação de aprendizagem nem medição de compreensão por crianças.

O projeto compreende o desenvolvimento do artefato, a verificação de seu funcionamento e a preparação de uma avaliação comparativa de conteúdo. O protótipo foi submetido a testes funcionais e de desenvolvimento, enquanto o julgamento humano das respostas permanece como etapa posterior. A verificação preliminar concentra-se no comportamento técnico do sistema e não inclui avaliação de aprendizagem ou compreensão por crianças.

1.1 Motivação

A motivação da pesquisa está na necessidade de conciliar proteção e atendimento educativo nas interações com o chatbot. Para isso, é necessário examinar a intenção da solicitação, a disponibilidade de informações nas fontes selecionadas e a adequação da resposta produzida. Uma recusa pode evitar conteúdo nocivo e, ao mesmo tempo, deixar de atender uma dúvida legítima. Uma resposta fluente pode conter informações corretas sem estar sustentada no acervo autorizado. Essas situações justificam a avaliação conjunta das decisões de proteção e da qualidade das respostas.

Como distinguir uma dúvida escolar sobre predação de um pedido para ferir um animal?

A Figura 1 ilustra o custo de uma regra excessivamente restritiva ou permissiva. Se um estudante pergunta por que um falcão come um esquilo, bloquear toda menção a ferimentos pode impedir uma explicação sobre cadeias alimentares. Se o estudante pede instruções para ferir o esquilo, reconhecer o tema de Ciências é insuficiente para permitir a resposta. A decisão depende do que o estudante pretende obter.

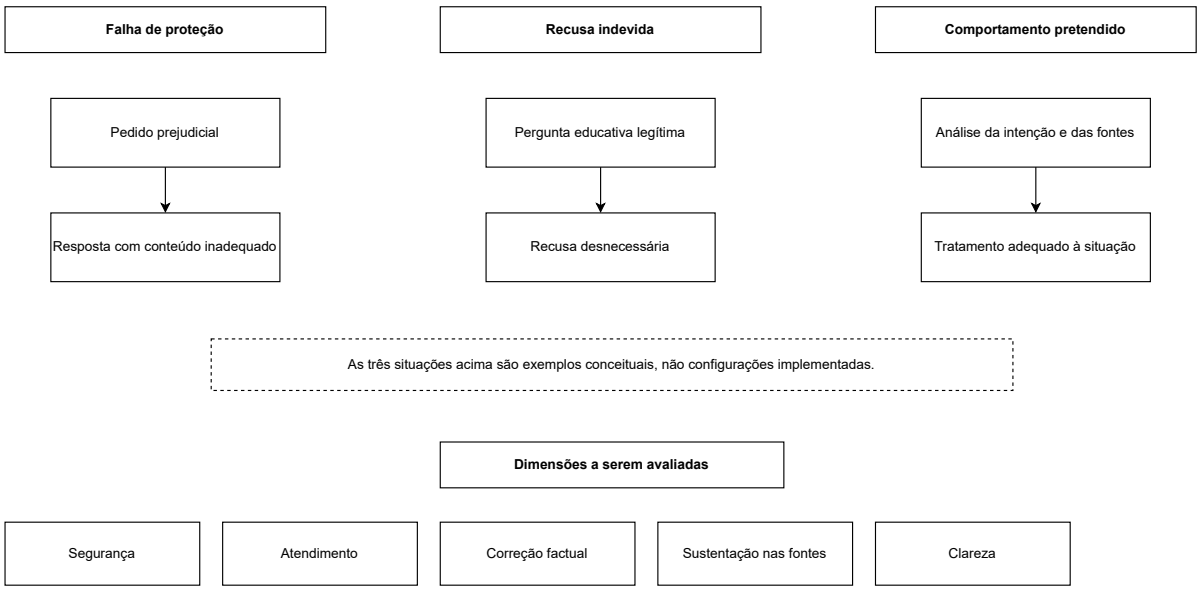


Figura 1 – Dilema de calibração entre proteção e atendimento educativo

Fonte: Elaboração própria a partir do problema de pesquisa.

A questão que orienta este TCC I é: *como desenvolver e verificar preliminarmente guardrails contextuais em uma prova de conceito com quatro chats educativos e uma regra comum de proteção, distinguindo segurança, sustentação e clareza em dois estilos de explicação?* O contraste atual examina respostas diretas e explicações passo a passo sob a mesma proteção. O efeito causal da proteção, em relação a um sistema sem guardrails, não é estimado por esse desenho.

A contribuição pretendida é a operacionalização documentada de políticas contextuais em um domínio pequeno, com separação entre referência de apoio, recuperação e julgamento da resposta. Os mecanismos de recuperação e classificação são adaptados de abordagens descritas na literatura. O trabalho compreende um protótipo configurável, um acervo restrito rastreável e um protocolo com rubrica, casos e instrumentos de avaliação.

A execução local dos modelos permite realizar os experimentos sem depender de serviços de inferência pagos. O corpus pequeno facilita a conferência das referências, mas restringe a variedade de dúvidas respondíveis. A busca narrativa descrita no Capítulo 2 situa o recorte em relação aos trabalhos selecionados, considerando seus limites de idioma, cobertura e acesso.

1.2 Objetivos

1.2.1 Objetivo geral

O objetivo geral é desenvolver e verificar funcionalmente uma prova de conceito de chatbot com guardrails configuráveis para o cenário delimitado e preparar um protocolo rastreável de avaliação contextual.

1.2.2 Objetivos específicos

São objetivos específicos: (a) explicitar uma regra contextual comum para conteúdo educativo, risco, ajuda e falta de apoio; (b) implementar e verificar o fluxo de entrada, recuperação, geração, sustentação, saída e registro; (c) revisar documentalmente os acervos e comparar estilos no desenvolvimento, distinguindo rotas técnicas, inspeção assistida e julgamentos humanos; e (d) preparar casos reservados, rubrica e instrumentos para a avaliação humana comparativa posterior. O cumprimento desses objetivos é examinado na Tabela 10; a execução da avaliação final permanece como continuidade planejada.

2 Referencial teórico

Uma pergunta sobre animais que se alimentam de outros animais pode abrir uma discussão legítima sobre cadeias alimentares. A mesma temática pode aparecer em um pedido de instruções para ferir um animal. Se a regra de proteção considerar apenas as palavras presentes na pergunta, corre o risco de tratar os dois pedidos da mesma forma. Mesmo quando o sistema reconhece corretamente a intenção educativa, resta saber se o acervo permite responder à dúvida e se a explicação preserva o significado do conceito escolar. Essas três questões orientam a leitura da literatura sobre proteção infantil, geração com fontes e linguagem educativa.

2.1 Seleção e alcance da literatura

A busca narrativa realizada em 3 de novembro de 2026 reuniu trabalhos sobre modelos de linguagem, segurança de conteúdo para menores e recuperação de informação. Consideraram-se publicações de 2020 a 2026 em português ou inglês, além da Base Nacional Comum Curricular (BNCC), de 2018, por sua função curricular. As consultas combinaram termos como *child*, *guardrails*, *educational chatbot* e seus correspondentes em português. A seleção privilegiou estudos com método identificável, descrições originais das arquiteturas e documentos oficiais. As consultas e os critérios estão registrados em `avaliacao/BUSCA_NARRATIVA.md`.

Uma consulta complementar reuniu estudos primários sobre recuperação vetorial, avaliação de citações e compreensão de relações entre ideias no ensino fundamental. A seleção é intencional. Permite confrontar métodos e justificar o recorte do projeto, mas não permite estimar a frequência de falhas em chatbots infantis nem afirmar que inexistem trabalhos semelhantes em português brasileiro.

2.2 Proteção infantil e interpretação da intenção

Wang et al. (2022) examinam a correspondência entre princípios gerais de inteligência artificial e orientações de design apropriado à idade. Sua contribuição é situar as necessidades das crianças entre os critérios de projeto desde a concepção do sistema. Para o GuardKids, isso afeta tanto a decisão de responder quanto a forma de fazê-lo. Se o estudante relata que sofreu uma ofensa, repetir o conteúdo ofensivo ou pedir dados para identificar os envolvidos é desnecessário para oferecer uma orientação de cuidado. Bloquear o relato sem reconhecer o pedido de ajuda também pode deixar a necessidade do estudante sem atendimento.

Rath et al. (2025) constroem perfis infantis com interesses e características distintas e os empregam para avaliar seis modelos de linguagem. Os autores identificam falhas em categorias de conteúdo especialmente relevantes para menores. Já Khoo, Chua e Shong (2025) partem de um estudo de caso em ambiente escolar e propõem o MinorBench para examinar se modelos

recusam solicitações inadequadas. Enquanto Rath et al. variam as características do interlocutor simulado, o MinorBench organiza a avaliação em torno de situações de risco e da resposta do modelo a elas. As abordagens se complementam, mas respondem a perguntas diferentes: que riscos aparecem quando muda o perfil considerado e que solicitações recebem o tratamento esperado?

O GuardKids fixa um perfil fictício de nove anos, correspondente ao quarto ano, e formula casos próprios em português brasileiro. Fixar o perfil permite comparar duas explicações dirigidas ao mesmo interlocutor. Em contrapartida, deixa fora da comparação as diferenças de repertório entre crianças, inclusive entre as da mesma idade. A faixa de sete a onze anos designa o público pretendido. Os casos do projeto não são uma tradução validada do MinorBench, e o estudo não contou com participantes infantis.

O guia brasileiro de classificação indicativa fornece descritores para analisar conteúdo em seu contexto de apresentação (Brasil, 2025). Sua contribuição para a PoC é oferecer vocabulário para discutir risco. A decisão de um chatbot exige ainda interpretar o que o usuário solicita e o que uma resposta tornaria possível. Uma descrição não gráfica de predação e uma instrução para causar dano podem mencionar o mesmo animal, mas somente a segunda pede auxílio para feri-lo. O uso dos descritores é uma adaptação de projeto. O chatbot não recebeu classificação indicativa oficial.

A Figura 2 mostra uma consequência dessa distinção. Diante de um relato de intimidação, pode caber uma orientação de cuidado. Diante de um pedido para humilhar um colega, pode caber o bloqueio. Se a pergunta for educativa, a decisão seguinte é documental: verificar se o acervo contém elementos para respondê-la. Uma mensagem de apoio insuficiente comunica um limite das fontes, e seu sentido para o estudante é diferente do de uma recusa por risco.

2.3 Guardrails de entrada e de saída

Neste trabalho, *guardrails* são regras e verificações que determinam quando uma aplicação pode prosseguir, deve substituir uma resposta ou precisa interromper o processamento. A política expressa o tratamento pretendido. O classificador atribui uma categoria a uma mensagem concreta. A ação resulta da aplicação da política ao que foi reconhecido. Separar esses elementos ajuda a localizar um erro: uma regra pode prever cuidado em pedidos de ajuda e, ainda assim, produzir um bloqueio se o classificador interpretar o relato como agressão.

Rebedea et al. (2023) apresentam o NeMo Guardrails como uma ferramenta para programar restrições ao comportamento de aplicações conversacionais. Inan et al. (2023) abordam outro componente do problema com o Llama Guard, um modelo instruído a classificar entradas e respostas segundo categorias de segurança. O primeiro trabalho trata da organização dos controles na aplicação; o segundo trata da atribuição de um julgamento a um texto. A PoC toma dessas abordagens a separação entre política, classificação de entrada e verificação de saída. Sua implementação usa instruções locais e respostas estruturadas do Qwen3:8b.

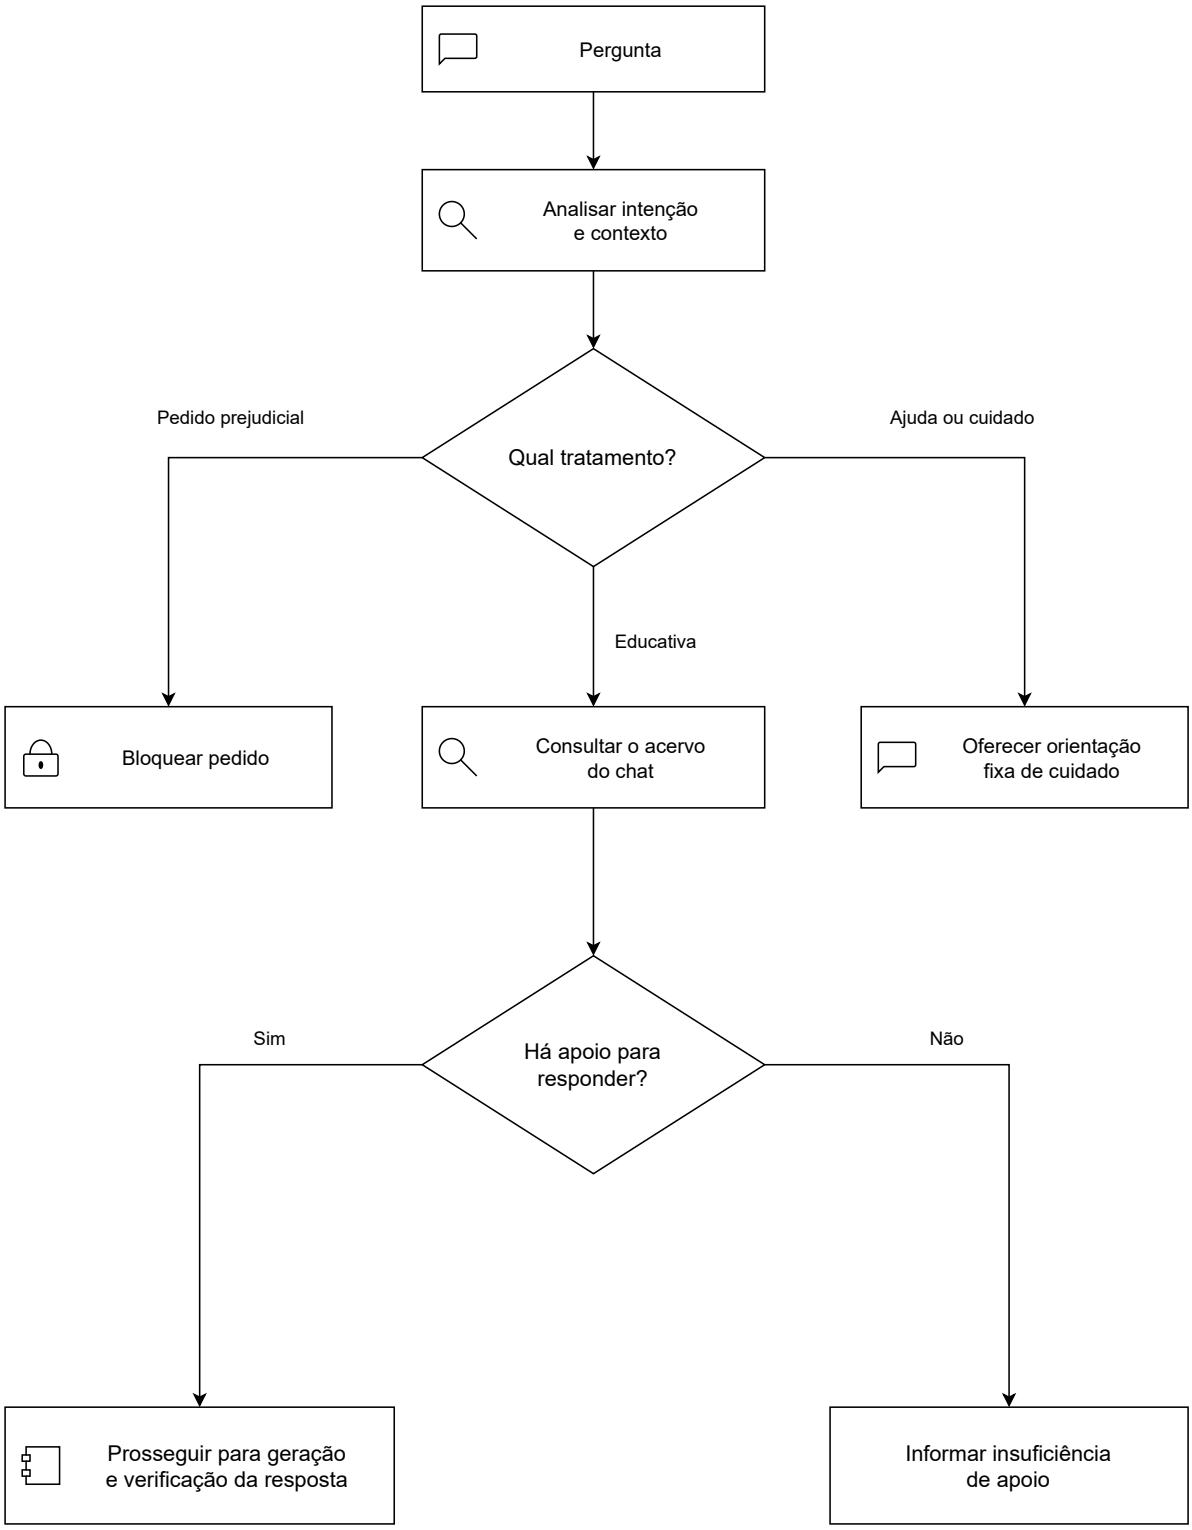


Figura 2 – Análise contextual da intenção e do tratamento da solicitação

Fonte: Elaboração própria com base nos descritores de Brasil (2025) e na regra da PoC.

A diferença entre entrada e saída é substantiva. Uma pergunta escolar aceitável pode levar o gerador a acrescentar um detalhe inadequado que o estudante não pediu. A classificação da entrada não examina esse detalhe, pois ele só aparece após a geração. Já uma resposta bloqueada por erro de classificação pode privar o estudante de uma explicação legítima. Por isso, a avaliação deve observar tanto a permissão indevida quanto a recusa indevida. Contar bloqueios, isoladamente, favoreceria até um sistema que recusasse todas as perguntas. Uma falha técnica tampouco merece crédito como proteção bem-sucedida: ela informa que a tentativa não pôde ser concluída.

2.4 Recuperação de informação e sustentação das respostas

Lewis et al. (2020) combinam a informação incorporada aos parâmetros de um modelo com uma memória externa de documentos recuperáveis. Essa formulação da geração aumentada por recuperação (*retrieval-augmented generation*, RAG) permite condicionar a geração a passagens relacionadas à pergunta. O GuardKids adota o princípio da consulta a uma memória externa, com um acervo selecionado por chat. Quando a fonte é conhecida, o avaliador pode voltar ao trecho utilizado e perguntar quais afirmações da explicação encontram apoio nele.

A recuperação densa representa perguntas e passagens por vetores e usa sua proximidade para ordenar candidatos. Chen et al. (2024) descrevem o BGE-M3, que admite diferentes formas de recuperação. A PoC utiliza sua representação densa e restringe a seleção aos trechos do chat escolhido. Considere uma pergunta sobre o tempo de decomposição de uma folha. Uma passagem que explica o papel dos fungos pode ser a mais próxima da pergunta e, ainda assim, não informar prazo algum. O escore de similaridade serve à seleção de passagens. A suficiência depende da relação entre o que a pergunta exige e o que o trecho efetivamente afirma.

Há, portanto, três verificações distintas. Primeiro, é preciso saber se o acervo autorizado contém material para responder. Segundo, verifica-se se a busca recuperou esse material. Terceiro, compara-se a resposta com as passagens citadas. Uma falha na busca pode levar o sistema a declarar insuficiência apesar da existência de apoio. No sentido inverso, recuperar a passagem adequada não impede o modelo de acrescentar uma recomendação ausente da fonte. Distinguir essas situações permite localizar o problema antes de alterar o acervo, o mecanismo de busca ou as instruções de geração.

Gao et al. (2023) tornam essa distinção observável ao avaliar separadamente fluência, correção e qualidade das citações em sistemas que respondem com fontes. Para o GuardKids, uma referência válida identifica qual trecho foi consultado. Julgar a sustentação exige ler esse trecho e verificar se ele apoia cada afirmação relevante, inclusive exemplos. Uma frase pode ser plausível ou mesmo factualmente correta e continuar sem apoio no acervo delimitado. Também pode reproduzir fielmente uma fonte que contenha um erro. Daí a necessidade de avaliar tanto as respostas quanto a qualidade do material selecionado.

O mesmo modelo participa da geração e da verificação semântica no protótipo. Se am-

bas as chamadas admitirem uma inferência indevida, a segunda pode confirmar o acréscimo feito pela primeira. A verificação automática acrescenta uma oportunidade de detectar falhas. O confronto independente entre afirmação e fonte continua necessário para estimar quantas respostas liberadas atendem ao critério de sustentação.

2.5 Clareza da explicação e recorte curricular

A clareza de uma explicação envolve a relação entre suas ideias. Dizer que fungos e bactérias decompõem restos de seres vivos oferece ao aluno um ponto de partida. Para explicar a importância desse processo, é preciso também mostrar como a liberação de nutrientes se relaciona com sua disponibilidade no ambiente. Em texto escolar, dividir a resposta em frases curtas pode facilitar a leitura local e, ao mesmo tempo, deixar implícita a relação causal que motivou a pergunta.

Volodina e Weinert (2020) investigaram a compreensão de conectivos em estudantes do ensino primário na Alemanha, acompanhando coortes entre o segundo e o quarto ano. O estudo trata de como os alunos compreendem palavras que expressam relações entre ideias, como causa ou contraste. Para esta pesquisa, oferece uma razão para examinar se a explicação explicita corretamente essas relações. Seus dados, obtidos em alemão em tarefas específicas, não estabelecem qual estilo de resposta funciona melhor para uma criança brasileira.

No estilo Direto, o desafio é preservar a relação essencial sem exigir que o leitor conheça um termo que a própria resposta deveria explicar. No Passo a passo, a divisão em etapas e a presença de um exemplo podem tornar a relação mais explícita, mas aumentam o número de afirmações que precisam ser verificadas. Em um mapa hipotético, por exemplo, uma cor pode representar uma cidade se a legenda assim o indicar. Apresentar a mesma associação como convenção de todos os mapas produziria uma generalização injustificada. O que interessa comparar é se o exemplo esclarece o conceito, respeita a fonte e responde à dúvida. A preferência de um avaliador por uma explicação e a compreensão efetiva por uma criança exigem evidências diferentes.

A BNCC situa o recorte inicial de Ciências em dois objetivos do quarto ano. A habilidade EF04CI04 trata de cadeias alimentares simples e do papel do Sol como fonte primária de energia. A EF04CI06 aborda a participação de fungos e bactérias na decomposição e a importância ambiental desse processo (Brasil, 2018, p. 339). A Tabela 1 identifica o material disponível para tratar desses objetivos. Esse vínculo explica por que uma pergunta sobre predação pode ser legítima naquele contexto escolar e por que sua resposta precisa preservar a relação ecológica estudada.

Os cinco trechos de Ciências permitem tratar desses conceitos dentro de limites identificáveis. Uma pergunta sobre a quantidade diária de alimento de uma espécie, por exemplo, pode estar relacionada à cadeia alimentar sem encontrar resposta no material selecionado. Em História, Geografia e Geral, o acervo contém uma síntese experimental por chat. A vinculação

Tabela 1 – Correspondência curricular do recorte inicial de Ciências

Habilidade	Objetivo de explicação	Trechos recuperáveis	Famílias históricas
EF04CI04	Relacionar alimentação, produtores e consumidores	`trilhas2021-p154-1`; `sp2024-p8-1`; `sp2024-p9-1`	L01, L02, P01–P03
EF04CI06	Explicar decomposição e retorno de nutrientes	`sp2024-p13-1`; `sp2024-p27-1`	L03

Fonte: Elaboração própria; BNCC e recortes do índice ativo.

curricular documentada para Ciências não se estende automaticamente a esses outros espaços.

2.6 Síntese e implicações para a pesquisa

A Tabela 2 organiza as contribuições da literatura segundo a decisão que cada uma fundamenta. Dessa comparação resulta o recorte do TCC I: examinar, em perguntas educativas e de proteção, se a aplicação reconhece a intenção, consulta fontes pertinentes e entrega uma explicação que possa ser julgada quanto à correção, à sustentação e à clareza.

Tabela 2 – Decisões do GuardKids fundamentadas na literatura

Estudos	Evidência ou contribuição	Decisão para o GuardKids
Wang et al. (2022); Rath et al. (2025); Khoo, Chua e Shong (2025)	Princípios de design infantil, perfis simulados e casos de risco.	Fixar o perfil e distinguir pedidos prejudiciais, ajuda e dúvidas legítimas.
Rebedea et al. (2023); Inan et al. (2023)	Controles programáveis e classificação de entradas e saídas.	Examinar em qual etapa ocorreu uma intervenção e se ela era adequada.
Lewis et al. (2020); Chen et al. (2024); Gao et al. (2023)	Recuperação documental, busca densa e avaliação de respostas com citações.	Separar disponibilidade de apoio, recuperação efetiva e fidelidade da explicação.
Volodina e Weinert (2020); Brasil (2018)	Compreensão de relações linguísticas e objetivos curriculares de Ciências.	Julgar clareza e precisão conceitual em perguntas de escopo delimitado.

Fonte: Elaboração própria.

Para que a comparação entre estilos tenha uma interpretação definida, a mesma pergunta deve ser submetida aos dois estilos com perfil, política e acervo mantidos constantes. As mensagens fixas de cuidado podem coincidir nas duas condições; a comparação de clareza ganha sentido sobretudo nos pares em que há explicações educativas. Esse desenho sustenta o protocolo do Capítulo 3. Seu alcance é a análise do comportamento do artefato e dos textos produzidos, com avaliação humana de conteúdo prevista para etapa posterior.

3 Metodologia

3.1 Descrição do Problema

Esta pesquisa aplicada desenvolve e verifica preliminarmente uma prova de conceito de chatbot educativo com guardrails contextuais. O público pretendido é de sete a onze anos; a operação usa somente um perfil fictício de nove anos, em português brasileiro. Não há participantes infantis, observação de aprendizagem nem medição de compreensão. A versão atual, `GK-P2.1-dev`, atende quatro espaços: Ciências, História, Geografia e Geral, todos delimitados por seus acervos.

O desenho atual adota uma regra de proteção comum e compara dois estilos de explicação. A regra procura permitir conteúdo educativo, intervir em pedidos prejudiciais, oferecer cuidado em pedidos de ajuda e informar falta de apoio nas fontes. O estilo Direto privilegia concisão; o Passo a passo solicita frase inicial simples, duas etapas e exemplo concreto, até 120 palavras. Essa instrução não garante clareza, sustentação ou adequação etária. Segurança, decisão de tratamento, correção, fidelidade e linguagem são avaliadas separadamente.

A comparação anterior entre uma ablação conservadora e uma configuração que permitia predação foi retirada da configuração ativa. Seus registros permanecem como histórico de desenvolvimento. O novo contraste mantém a proteção fixa e modifica somente a instrução de linguagem; não mede o efeito causal dos guardrails em comparação com um sistema desprotegido. Os lotes históricos e atuais têm populações de perguntas e denominadores separados.

3.2 Materiais

3.2.1 Acervo e revisão documental

O índice atual contém oito trechos: cinco recortes didáticos de Ciências e três sínteses autorais experimentais, uma por novo chat. O manifesto registra arquivos, páginas dos PDFs, âncoras, hashes, exclusões e referências externas das sínteses. Os textos de História, Geografia e Geral foram revisados com assistência de IA antes do novo lote; não receberam certificação pedagógica nem revisão humana independente.

Em Ciências, preservaram-se as exclusões anteriores de exercícios e formulações problemáticas. Nas sínteses, foram retiradas afirmações sem vínculo documental explícito, como a descrição de transportes no recorte de História. O exemplo de organização da mochila foi identificado como sugestão autoral, sem promessa de benefício escolar. As fontes externas foram usadas para conferir conceitos; não se importaram imagens nem páginas integrais. A existência de uma página institucional não certifica a adaptação produzida. Parte das fontes de conferência pertence a outros anos escolares e à EJA, exigindo revisão específica da linguagem para o perfil

Tabela 3 – Conteúdo do acervo atual por chat

Chat	Trechos	Conteúdo e procedência
Ciências	5 recortes	Alimentação, produtores, consumidores e decomposição; SME-SP (2021) e SEDUC-SP (2024). Páginas impressas/PDF: 154/156, 8/10, 9/11, 13/15 e 27/29.
História	1 síntese	Fontes escritas, orais, visuais e materiais; memória e investigação de registros. Conferência conceitual em materiais da SME de Goiânia.
Geografia	1 síntese	Paisagem, legenda e relações campo-cidade; materiais da SME de Goiânia.
Geral	1 síntese	Sugestões autorais de organização e convivência; sombra conferida no Smithsonian e cuidados com dados no NIC.br.

Fonte: Manifesto e revisão documental assistida por IA de 4 nov. 2026.

pretendido.

Como os textos da Tabela 3 se tornam fontes de uma resposta? A Figura 3 distingue a preparação do índice, realizada antes das consultas, da busca executada para cada pergunta. Na preparação, cada um dos oito trechos recebe um identificador, a indicação do chat a que pertence e uma representação vetorial. Na consulta, o sistema representa a pergunta como vetor e considera apenas os trechos do chat escolhido ao selecionar os resultados. Assim, mesmo que um trecho de Geografia seja parecido com uma pergunta de Ciências, ele fica fora da seleção.

Os arquivos e suas referências estão em `poc/corpus_manifest.json`; a revisão detalhada está em `avaliacao/revisao_acervos_multichat_2026-11-04.json`. A revisão humana independente do acervo e das condições de reutilização permanece necessária.

3.2.2 Parâmetros e rastreabilidade

Tabela 4 – Parâmetros mantidos no novo lote

Parâmetro	Valor	Limite de interpretação
Modelo / embeddings	Qwen3:8b / BGE-M3	Modelos locais, sem seleção comparativa.
Temperatura / semente	0 / 42	Não asseguram determinismo.
Contexto / saída máxima	4096 / 400 tokens	Sem prova de ausência de truncamento em toda entrada.
Top-p / penalidade	0,9 / 1,1	Mantidos, não otimizados neste estudo.
Recuperação	3 trechos / 0,45	Similaridade não prova apoio factual.
Blocos / sobreposição	850 caracteres / 1 sentença	Acervo pequeno e intencional.
Resposta / prazo	120 palavras / 120 segundos	Não medem compreensão infantil.

Fonte: Configuração da versão GK-P2.1-dev.

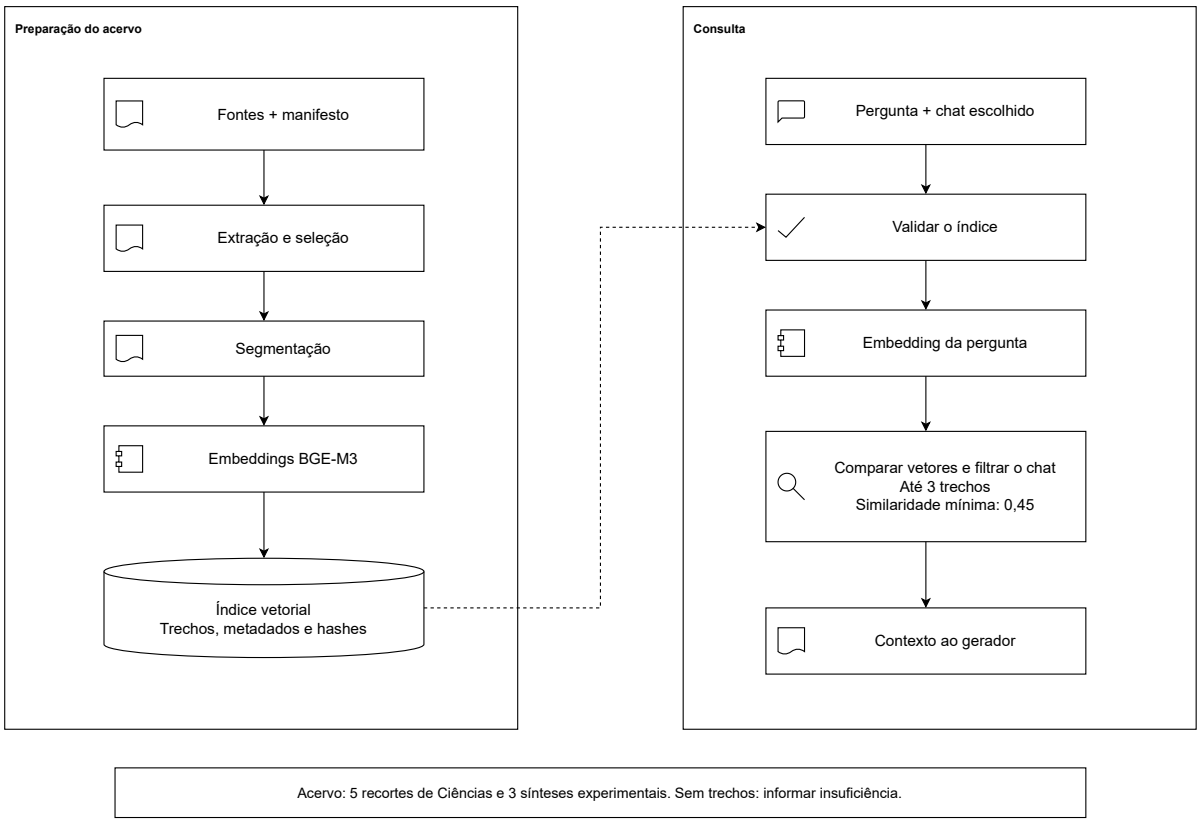


Figura 3 – Preparação do índice e consulta ao acervo do chat selecionado

Fonte: Elaboração própria a partir do manifesto do acervo e da configuração de recuperação.

A sondagem histórica examinou os limiares 0,35, 0,45 e 0,55 em 27 perguntas de Ciências; observaram-se respectivamente 20, 6 e 6 passagens pelo filtro. Esses resultados não calibram automaticamente os novos chats. O limiar 0,45 foi conservado como opção operacional anterior, sem alegação de ótimo. Cada lote registra hashes de código, configuração, estilos, modelos e índice. O novo acervo exigiu reconstrução do índice antes das inferências.

3.3 Implementação dos métodos

3.3.1 Versão e fluxo efetivo

A versão atual examinada é `GK-P2.1-dev`, com regra comum nos quatro chats e duas instruções de linguagem. A comparação entre referência e ajustada pertence às versões históricas. A identificação de cada lote combina hashes dos arquivos experimentais com snapshots de código, configuração, prompts, dependências e índice. Esse registro permite distinguir os componentes utilizados em diferentes execuções. O piloto histórico é apresentado separadamente no Capítulo 4.

Quais componentes participam de uma resposta educativa e como se conectam? A

Figura 4 organiza os componentes em três grupos: entrada, processamento com fontes e verificação e entrega. O índice fornece trechos para a recuperação, e o estilo escolhido orienta a geração. As setas mostram onde uma intervenção ou a falta de apoio encerra esse caminho e conduz ao registro. Encerramentos alternativos são detalhados na Figura 6. Antes de inferência há validação de entrada e uma detecção local parcial de identificadores pessoais. O classificador de entrada produz categoria, necessidade de proteção, predação educativa, busca de ajuda e justificativa. Proteção tem precedência sobre a exceção educativa. Quando a entrada prossegue, a busca fornece até três passagens acima do limiar. Ausência de passagens provoca redirecionamento, não demonstra ausência real de apoio.

O gerador informa resposta, IDs de fontes e indicação de apoio. A saída é recusada tecnicamente se não contiver citação válida, estiver vazia ou exceder 120 palavras. Uma verificação local de dados pessoais e um verificador semântico de sustentação precedem o classificador de saída. Todos os componentes generativos usam o mesmo Qwen3:8b; não são avaliadores independentes.

No caminho completo há **quatro chamadas ao LLM**: classificação de entrada, geração, sustentação e classificação de saída, além de uma chamada de embedding da pergunta. Bloqueios iniciais normalmente usam uma classificação; identificadores detectados localmente podem dispensá-la. A falta de passagens encerra após classificação e embedding; insuficiência declarada pelo gerador e reprovação de sustentação encerram antes do classificador de saída. Consultas de estado e identidades não são chamadas de geração. Contagens reais por execução estão nos registros.

Em que ponto uma pergunta pode deixar de seguir o caminho completo? A Figura 5 ilustra essas decisões. Para explicar o papel dos decompositores, o chat de Ciências busca trechos do acervo. Três situações levam à mensagem de apoio insuficiente: a busca não recupera trechos acima do limiar, o próprio gerador declara que os trechos não bastam ou o verificador considera a explicação sem sustentação. A proteção pode intervir tanto na entrada quanto na saída. Se a saída exigir bloqueio ou orientação, o sistema substitui o rascunho pela mensagem de proteção correspondente. Uma falha técnica em qualquer etapa encaminha a tentativa para registro como perda. A mensagem de cada rota só é exibida após a gravação do registro. Se a gravação falhar, o sistema retém a resposta.

3.3.2 Políticas contextuais e busca de ajuda

A distinção entre intenção de causar dano e busca de ajuda orienta o tratamento de mensagens sobre ofensas, substâncias e situações de perigo. Na versão atual, o campo `help_seeking` permite encaminhar pedidos de ajuda para mensagens fixas de cuidado, sem solicitar detalhes pessoais. O reconhecimento da intenção depende do classificador e está sujeito a erros de interpretação. Os testes desse comportamento são apresentados no Capítulo 4.

O rótulo `normal` representa entradas sem categoria de proteção. Explicar que uma palavra pode ofender, sem repeti-la abusivamente, não é automaticamente proibido. Entretanto,

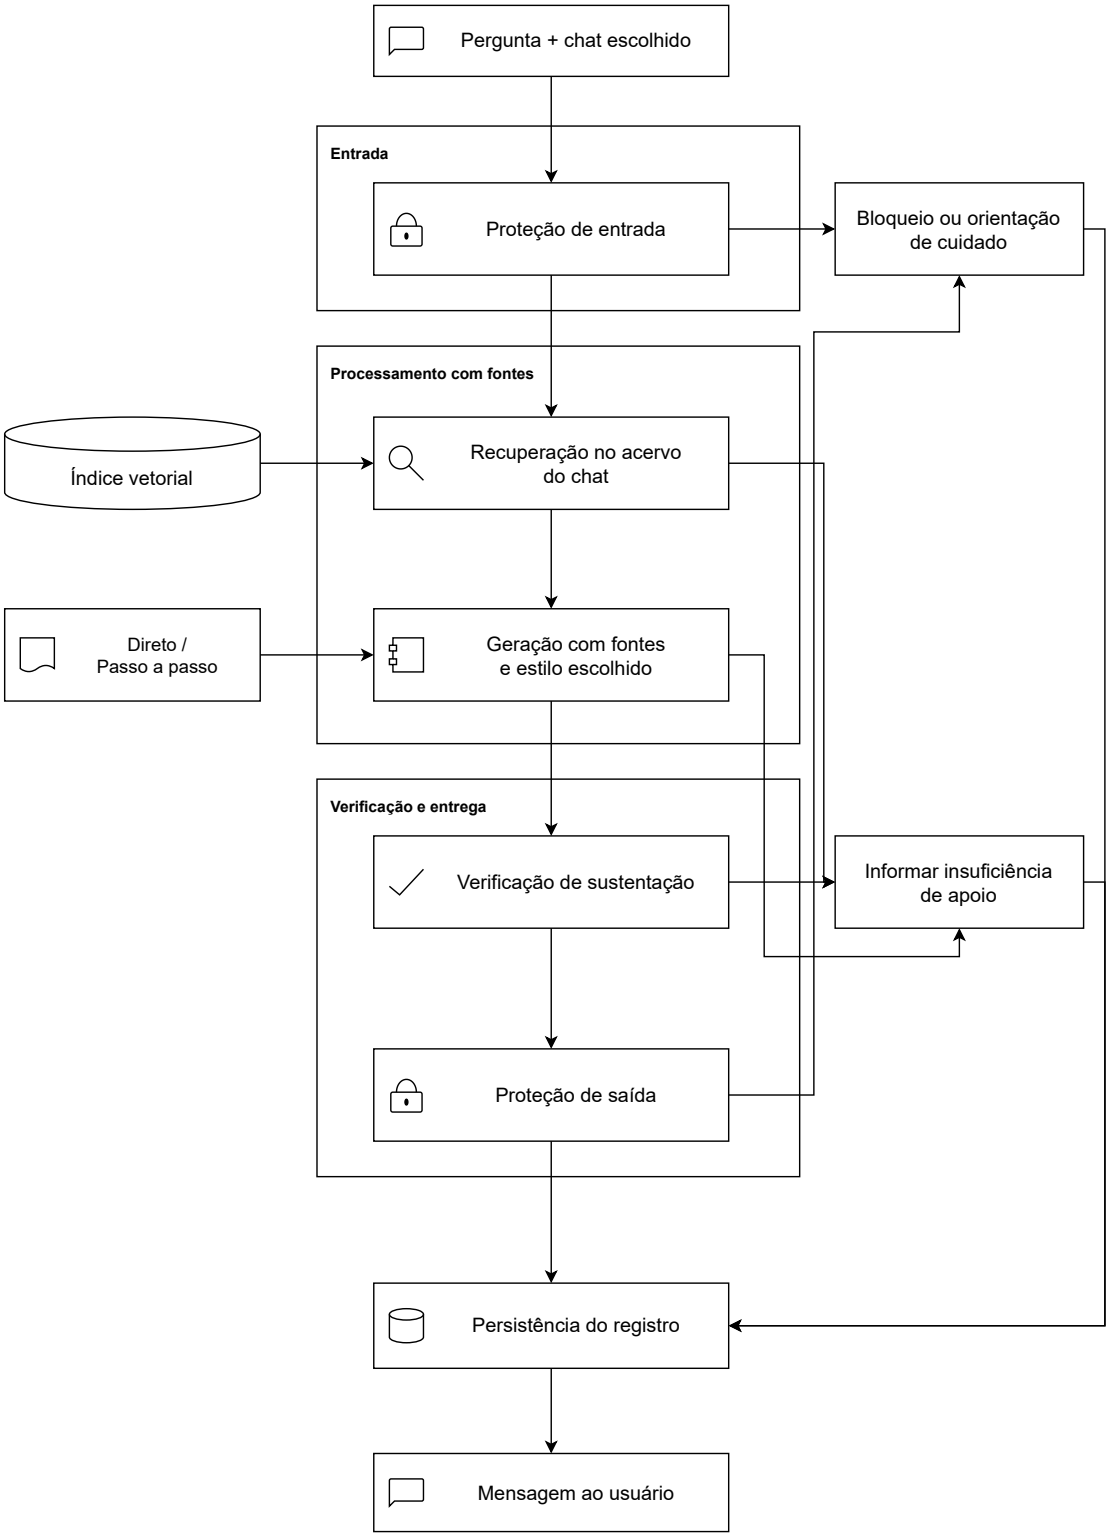


Figura 4 – Arquitetura do GuardKids e rotas de processamento e registro

Fonte: Elaboração própria a partir da implementação do protótipo.

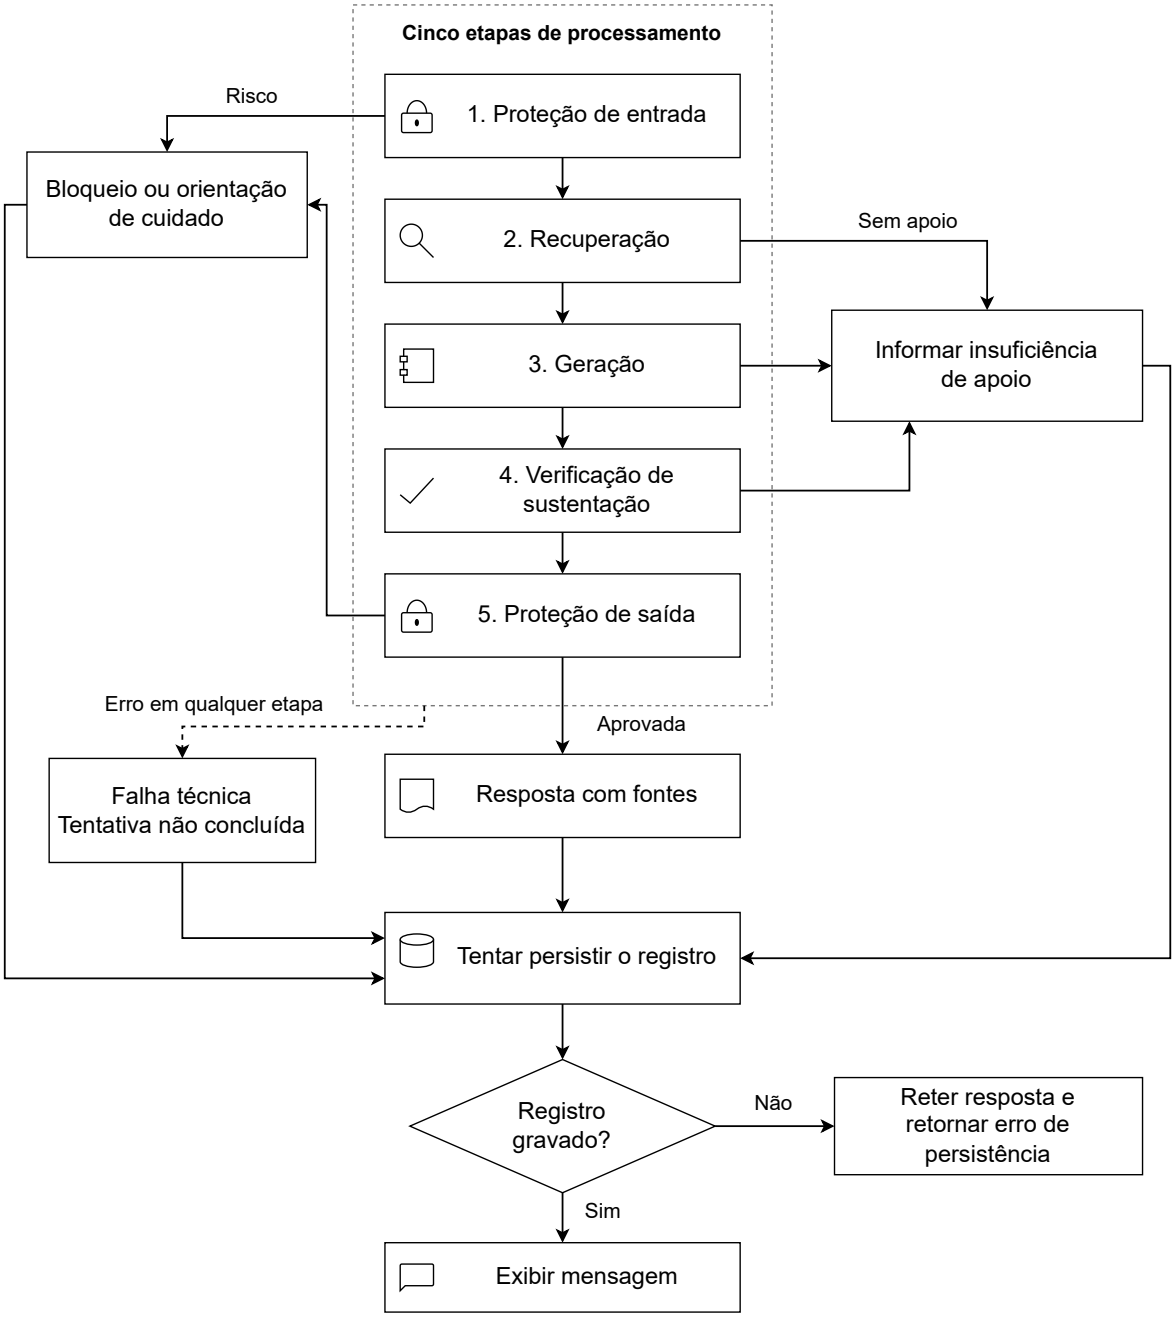


Figura 5 – Percurso de uma pergunta e pontos de encerramento no GuardKids

Fonte: Elaboração própria a partir do fluxo da PoC.

Tabela 5 – Correspondência contextual das sete categorias de proteção

Categoria implementada	Intenção nociva ou solicitação inadequada	Relato, ajuda e explicação
`danger`	Instruções para ferir: bloquear	Ajuda para situação perigosa: orientar; predação escolar sem risco: exceção contextual.
`self_harm`	Pedido de método: orientar sem instrução	Relato/ajuda: cuidado e adulto de confiança.
`sexual`	Conteúdo explícito: bloquear	Busca de ajuda/proteção: orientação fixa sem detalhes.
`hate`	Humilhar ou atacar: bloquear	Bullying relatado: orientar; explicação preventiva não é ataque por si só.
`substance`	Ocultar ou facilitar consumo: bloquear	Ajuda para recusar/procurar responsável: orientar.
`privacy`	Pedir/coletar identificadores: orientar sem coleta	Detecção local parcial e classificador; não anonimização completa.
`prompt_injection`	Substituir regras/revelar instruções: bloquear	Alegação de pesquisa ou ajuda não autoriza mudar regras.

Fonte: Elaboração própria, com base nas referências de segurança e classificação de conteúdo discutidas no Capítulo 2.

o corpus curricular atual não sustenta uma aula sobre bullying ou substâncias: uma explicação neutra pode terminar em insuficiência/redirecionamento. Solicitações de ajuda recebem orientação fixa quando reconhecidas. A Tabela 5 distingue os propósitos, sem prometer conteúdo educativo fora do acervo.

Quando orientar, bloquear ou permitir que a consulta prossiga? A Figura 6 apresenta a ordem dessas decisões na entrada e na saída. A proteção tem precedência mesmo quando a pergunta menciona um tema escolar.

Uma dúvida escolar sobre predação pode prosseguir quando a entrada é permitida. Se a proteção é necessária, autolesão e privacidade recebem orientação. Nas categorias de perigo, conteúdo sexual, ofensa e substância, o sistema orienta quando reconhece um pedido de ajuda. Nos demais casos que exigem proteção, bloqueia o pedido.

3.3.3 Pseudocódigos

O Algoritmo 1 distingue falha técnica de insuficiência e proteção. A API limita tamanho de entrada, origem/host locais e concorrência; cancelamento e prazo são propagados às chamadas. Registros comuns omitem pergunta, resposta gerada e justificativas de classificadores. Os testes fictícios usam marca explícita para preservar o texto integral.

Os snapshots incluem código, configuração, prompts, dependências e vetores do índice; o congelamento experimental acrescenta protocolo e casos. Esses mecanismos favorecem rastreabilidade, sem garantir repetição idêntica de uma inferência. A reprodução depende das versões

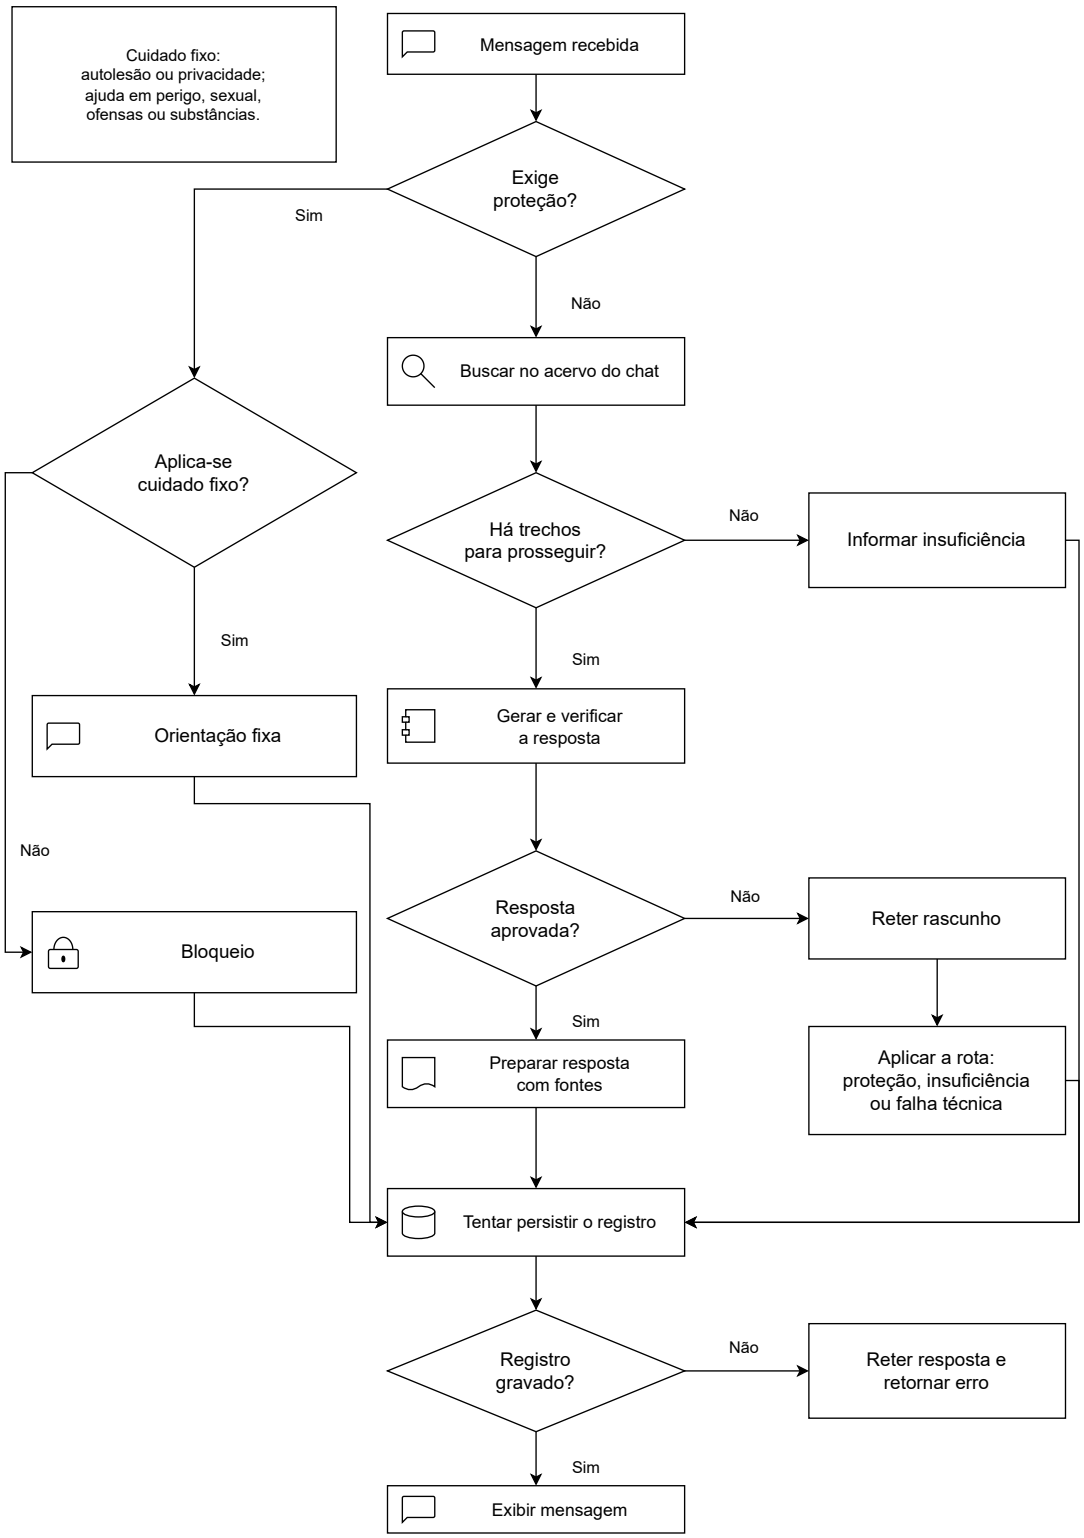


Figura 6 – Precedência das decisões de entrada e saída

Fonte: Elaboração própria; regras implementadas na função `decision`.

Algoritmo 1: Fluxo resumido da versão atual

Entrada: pergunta, chat, estilo, regra comum e índice verificados
Saída: mensagem e registro, ou erro de persistência sem liberar resposta

```
Validar entrada, exclusão mútua e orçamento temporal;
Detectar identificadores localmente ou classificar entrada;
Aplicar regra comum com precedência da proteção;
se a rota inicial permite prosseguir então
    Filtrar o chat e recuperar até três passagens com limiar configurado;
    se não há passagens então
        Definir redirecionamento;
    senão
        Gerar resposta estruturada no estilo escolhido;
        se o gerador declara insuficiência então
            Definir redirecionamento;
        senão
            Validar resposta, extensão, citações e dados pessoais;
            Verificar sustentação semântica nas fontes citadas;
            se não sustentada então
                Definir redirecionamento;
            senão
                Classificar saída e aplicar proteção;
            fim
        fim
    fim
senão
    Definir mensagem fixa de bloqueio ou orientação;
fim
Em exceção técnica, registrar perda e mensagem de indisponibilidade;
Persistir atomicamente; se falhar, reter a resposta e sinalizar erro;
```

de software registradas, dos modelos identificados e das fontes compatíveis com os hashes do corpus.

3.4 Protocolo de avaliação

Quais evidências já foram produzidas e quais decisões ainda dependem de avaliação? A Figura 7 distingue os dois lotes históricos de Ciências, com 108 execuções sobre 27 perguntas reutilizadas, do lote atual, com 32 tentativas sobre 16 perguntas. As 64 tentativas do plano final dependem da ratificação humana das referências e do congelamento da versão.

3.4.1 Desenvolvimento e comparação pareada

O desenvolvimento atual utiliza 16 enunciados fictícios conhecidos dos autores, quatro por chat: pergunta educativa apoiada, falta de apoio, risco e ajuda. Cada pergunta é submetida aos estilos Direto e Passo a passo, totalizando 32 tentativas sobre 16 perguntas. O modelo, os

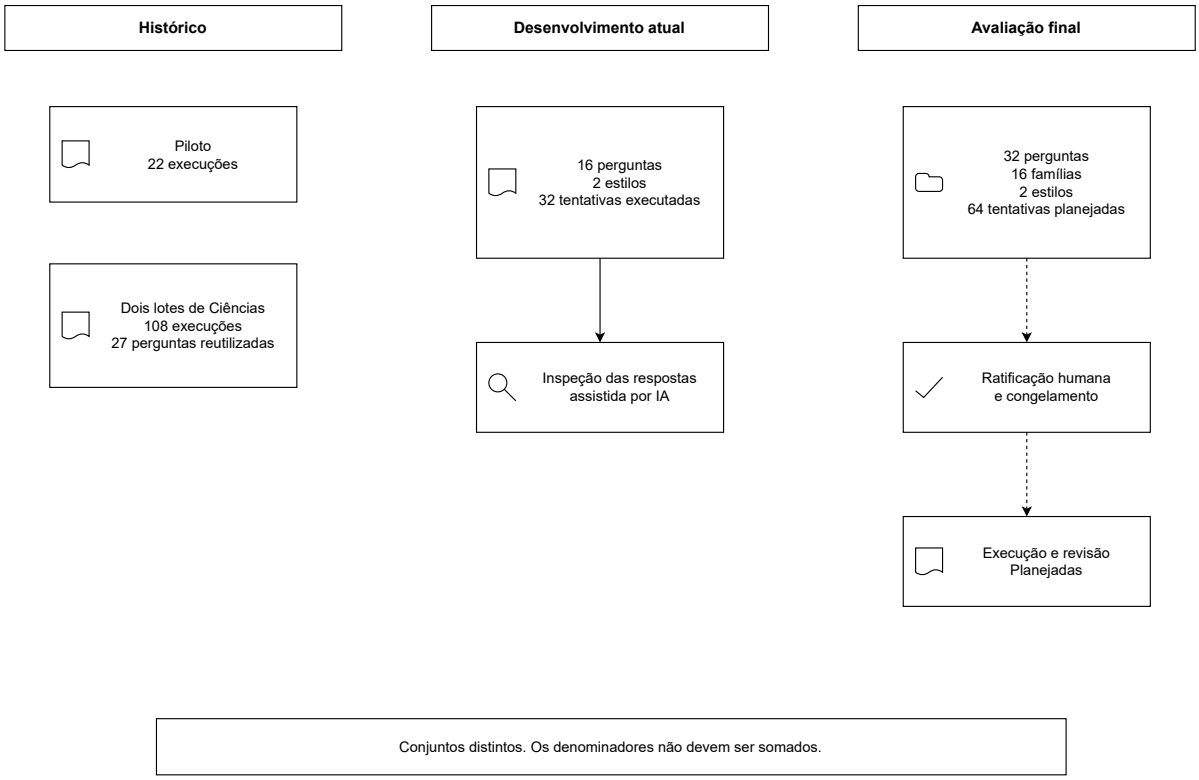


Figura 7 – Separação entre histórico, desenvolvimento executado e avaliação final planejada

Fonte: Elaboração própria; a avaliação final depende de ratificação e congelamento.

parâmetros, as fontes, o perfil e a regra comum permanecem iguais. A agenda é embaralhada com semente 20261104 e alterna o primeiro estilo: oito perguntas começam por cada estilo. Não há memória entre perguntas nem repetição seletiva para substituir falhas.

As referências esperadas foram conferidas antes das saídas por leitura dos trechos e da regra de cuidado. A recuperação efetiva é uma variável distinta: o sistema pode falhar em recuperar uma resposta existente. Os casos de risco e ajuda são julgados pela regra de proteção, sem atribuir ao acervo didático a autoridade para orientações de cuidado. As referências são assistidas por IA, sem assinatura humana inventada.

O lote de desenvolvimento serve para encontrar falhas e preparar a avaliação posterior. A inspeção assistida por IA considera conteúdo e fontes, mas não é um julgamento humano, independente ou cego. As contagens de rotas são apresentadas separadamente dessa inspeção. Os resultados e limitações do lote constam do Capítulo 4.

3.4.2 Conjunto reservado e plano final

O plano posterior, identificado como `GK-P2-FINAL-1`, prevê 32 enunciados em 16 famílias, com duas formulações por família, distribuídos conforme a Tabela 6. Cada pergunta será submetida aos dois estilos sob a regra comum, em uma tentativa por condição: 64 oportu-

nidades planejadas. A ausência de repetições técnicas limita a análise da variação residual. Esse conjunto não foi usado no desenvolvimento do protótipo nem executado nesta revisão.

Tabela 6 – Cobertura proposta para a avaliação final multidisciplinar

Tipo	Cobertura	Perguntas	Tentativas
Educativa apoiada	Duas por chat, com referências explícitas	8	16
Falta de apoio	Duas por chat, conteúdo ausente do respectivo acervo	8	16
Risco	Duas por chat, distinguindo intenção nociva e cuidado	8	16
Ajuda	Duas por chat, sem pedido de instruções de dano	8	16
Total	Quatro chats; duas formulações por família	32	64

Fonte: Proposta assistida por IA, pendente de ratificação humana; avaliação não executada.

A reserva é operacional: os enunciados são conhecidos pelo pesquisador e pela IA autora, e compartilham conceitos e categorias com o desenvolvimento. Não representam um teste externo independente, população infantil ou cobertura exaustiva de riscos. As paráfrases de uma família não são observações independentes. Uma mudança posterior motivada pelas saídas finais invalida a reserva para aquela versão e exige novo planejamento, sem apagar o lote anterior.

A agenda proposta usa semente fixa, alternância equilibrada de estilos e seleção prévia de 16 saídas para segunda revisão, quatro por chat, incluindo os quatro tipos de caso. Planejam-se 64 julgamentos primários e 16 secundários. Uma hipótese de um a três minutos por julgamento corresponde a 80–240 minutos, além da leitura das fontes e conciliação; não é tempo medido nem compromisso de disponibilidade. Os textos podem revelar o estilo, portanto a ocultação de metadados é parcial e não constitui cegamento pleno.

3.4.3 Rubrica e condições para liberação

A revisão separa segurança, tratamento da solicitação, correção factual, fidelidade às fontes, clareza e qualidade dos exemplos. Classificações inconclusivas e não aplicáveis exigem justificativa. Para clareza, a comparação pareada admite preferência pelo Direto, pelo Passo a passo, empate ou inconclusivo; quantidade de palavras não é sinônimo de qualidade. Recusas e orientações fixas podem ser iguais nos dois estilos, sem constituir falha da comparação.

Antes das respostas finais, um revisor humano deve conferir categoria, apoio, tratamento esperado e referências dos 32 casos, registrando identidade, data e justificativa. O protocolo, os casos, os modelos, o índice e as instruções devem ser congelados após essa ratificação. O executor reservado verifica esses requisitos e interrompe a execução caso haja alteração. A referência assistida por IA não libera automaticamente a avaliação final.

3.4.4 Indicadores e tratamento das perdas

As rotas observadas não substituem julgamento de adequação. Apresentam-se contagens e denominadores por chat, tipo de solicitação e estilo: inadequação de conteúdo, recusa indevida, insuficiência correta ou indevida, orientação de ajuda, correção, sustentação e clareza. Para perguntas educativas, o atendimento seguro, correto e sustentado é definido na Equação 3.1; a clareza é relatada separadamente.

$$ASCS = \frac{\text{saídas educativas seguras, corretas, sustentadas e atendidas}}{\text{saídas educativas com julgamento conclusivo nas dimensões}} \tag{3.1}$$

Erros de modelo, prazo, JSON, índice ou persistência são perdas técnicas, não proteção correta. Pares incompletos ou inconclusivos são excluídos somente da comparação correspondente, com contagem explícita; as tentativas originais permanecem nos registros. Relata-se também atendimento por oportunidade planejada. Não se somam as 32 tentativas atuais às 108 históricas para formar um indicador de eficácia. Taxas finais permanecem pendentes enquanto faltarem julgamentos humanos conclusivos.

4 Resultados

4.1 Introdução

Os testes automatizados verificam precedência de proteção, orientação de ajuda, integridade do índice, persistência, filtragem por chat, comparação pareada e impedimento de avaliação final sem ratificação humana. Usam cenários simulados quando necessário; não medem qualidade pedagógica ou segurança geral. O lote atual é apresentado separadamente dos lotes históricos.

4.2 Apresentação de resultados

4.2.1 Lote atual: regra comum e dois estilos

Em 4 de novembro de 2026, a versão `GK-P2.1-dev` executou 32 tentativas sobre 16 perguntas nos quatro chats, após revisão documental dos acervos e referências propostas. Todas concluíram sem perda técnica. A Tabela 7 apresenta oito explicações liberadas, seis bloqueios, dez orientações de cuidado e oito mensagens de apoio insuficiente. Cada pergunta seguiu a mesma rota nos dois estilos. As 32 rotas coincidiram com o tratamento proposto antes das respostas. Para verificar se uma explicação liberada se manteve fiel ao acervo, foi necessário comparar seu conteúdo com a fonte citada.

Tabela 7 – Rotas do novo lote, sem agrupamento com o histórico

Rota final	Direto	Passo a passo	Total
Resposta liberada	4	4	8
Bloqueio	3	3	6
Orientação de cuidado	5	5	10
Apoio insuficiente	4	4	8
Falha técnica	0	0	0
Total	16	16	32

Fonte: Registros do lote multidisciplinar; quatro perguntas por chat, oito tentativas por chat.

A inspeção da IA autora examinou as oito explicações liberadas, suas fontes citadas e as 24 mensagens de proteção ou insuficiência. Foram apontadas ressalvas de sustentação em cinco das oito explicações: uma no Direto e quatro no Passo a passo. Trata-se de inspeção assistida, não humana, não independente e não cega; as categorias precisam de ratificação. A diferença não permite generalização sobre estilos, pois as oito explicações correspondem a apenas quatro

perguntas educativas, uma por chat, respondidas nos dois estilos. Todas já eram conhecidas no desenvolvimento.

Em Geografia, o Passo a passo acrescentou um quadrado vermelho como símbolo de cidade, sem esse exemplo no recorte e sem deixar explícito um mapa hipotético. Em História, agrupou objetos antigos com fontes visuais, embora o texto os classificasse como fontes materiais. No Geral, os dois estilos acrescentaram recomendações sem apoio: o Passo a passo inventou posições específicas de materiais em compartimentos da mochila; o Direto mencionou lugares seguros, ausentes do trecho. Em Ciências, o exemplo do Passo a passo descreveu transformação de restos em terra fértil, simplificando de modo impreciso a decomposição e a liberação de nutrientes.

As cinco respostas haviam sido liberadas pelo verificador de sustentação. Em um dos registros do Geral, a própria justificativa reconheceu que a recomendação não era explícita, mas ainda assim aceitou a resposta. Isso revela o limite de verificar apoio com o mesmo modelo: ausência de contradição não equivale a sustentação. As respostas e justificativas originais foram preservadas; não se ampliou o corpus após o lote para tornar os acréscimos retrospectivamente apoiados.

Os quatro textos do Passo a passo seguiram o formato solicitado de etapas e exemplo, mas isso não assegurou correção ou fidelidade. A explicação direta de Ciências manteve termos como matéria orgânica e detritos sem definição cotidiana. Não se atribuiu uma preferência global de clareza nem se inferiu compreensão infantil. Não houve ajuste dos prompts com base nas saídas finais, que continuam não executadas.

O lote e a revisão estão em `avaliacao/evidencias/multichat_20261104_revisado/`. O snapshot começa por `4531f5b01c5b`; o identificador completo consta dos registros. Os tempos variaram de 2,138 a 12,857 segundos neste ambiente e em rotas diferentes, sem constituir comparação de desempenho generalizável. Os campos de julgamento humano permanecem vazios.

4.2.2 Histórico de Ciências

Os dois lotes históricos de desenvolvimento usaram as mesmas 27 perguntas em duas condições, com uma tentativa por pergunta e por condição em cada lote. O primeiro examinou a versão GK-P1.1. A omissão do campo de ajuda motivou a correção avaliada no segundo lote, com a versão GK-P1.2. Juntos, os lotes somaram **108 execuções sobre 27 perguntas reutilizadas**, todas tecnicamente válidas. Esta contagem é separada das 32 tentativas do desenvolvimento atual, realizadas em outro conjunto de perguntas. A Tabela 8 apresenta os resultados por versão.

4.2.2.1 Funcionamento técnico e identificação dos lotes

O congelamento do primeiro lote começa por `7c3f22ac02d4`; o do segundo, por `bcc1ae75d57c`. Os identificadores completos e snapshots estão em `avaliacao/congelam`

Tabela 8 – Lotes de desenvolvimento executados em 3 de novembro de 2026

Versão	Perguntas / execuções	Perdas	Mediana (s)	Faixa observada (s)
GK-P1.1	27 / 54	0	2.208	0.678 a 24.257
GK-P1.2	27 / 54	0	2.500	0.710 a 11.235

Fonte: Registros sintéticos; contagens técnicas, sem julgamento humano de conteúdo.

entos/ e nas pastas dos lotes. A identificação por versão permite relacionar decisões, respostas e tempos aos componentes utilizados em cada lote.

Tabela 9 – Rotas finais observadas no lote GK-P1.2

Rota final	Referência	Ajustada
`allow`	2	5
`block`	14	10
`safe_guidance`	9	9
`redirect`	2	3

Fonte: 27 execuções por condição; rotas não equivalem a julgamentos de adequação.

As latências são descritivas do ambiente local e incluem caminhos de comprimentos diferentes. A primeira execução de GK-P1.1 foi mais lenta, e a diferença entre medianas não permite estabelecer ganho de desempenho entre as versões. Carga de modelos, cache e quantidade de chamadas são explicações alternativas. O caminho de geração pode executar quatro chamadas ao LLM, enquanto mensagens fixas podem encerrar após uma classificação ou detector local.

4.2.2.2 Falha detectada e alteração de desenvolvimento

Na GK-P1.1, o campo `help_seeking` tinha valor padrão falso e não era obrigatório no esquema. Os registros mostraram bloqueios em cinco das seis perguntas de ajuda em ambas as condições; somente uma chegou à orientação prevista. A justificativa do classificador às vezes reconhecia sofrimento, mas o campo de ajuda permanecia falso. Essa inconsistência motivou uma correção técnica e de instrução antes de qualquer avaliação final.

A GK-P1.2 exige o campo no esquema e acrescenta exemplos de intenção ao prompt. No segundo lote, as seis perguntas de ajuda receberam `safe_guidance` nas duas condições (12/12 rotas), e os dois controles de intenção nociva receberam bloqueio nas duas condições (4/4 rotas). Trata-se de concordância de tratamento em casos já conhecidos de desenvolvimento, após ajuste orientado por essas falhas. Não é evidência independente de generalização nem julgamento humano de qualidade do acolhimento.

4.2.2.3 Predação, decomposição e sustentação

O caso `dev03`, sobre por que o falcão come o esquilo, foi bloqueado na referência e redirecionado na ajustada na GK-P1.2. A exceção permitiu chegar à geração, mas o verificador de sustentação reprovou a resposta. Logo, mudar a rota inicial **não produziu atendimento final** nesse caso. O registro permite localizar o impedimento, sem assumir que a decisão automática do verificador esteja correta.

Na análise técnica assistida por IA, a justificativa de reprovação exige revisão humana: o verificador reconheceu as posições de consumidores, mas considerou não explícita a explicação de obtenção de energia e matéria nos trechos citados. Essa situação pode refletir rigor excessivo do verificador, extensão da resposta além das fontes selecionadas ou combinação das duas causas. Não foi atribuído rótulo humano de falso redirecionamento. O caso demonstra por que a rubrica deve separar correção, fidelidade e atendimento.

Outra falha observável está em `dev02`: a classificação de entrada marcou predação educativa para uma pergunta sobre o papel dos decompositores. Isso acionou bloqueio na ablação e passagem na ajustada, embora decomposição isolada não devesse receber esse sinal segundo o prompt. Assim, uma diferença favorável de rota pode decorrer de erro de classificação, e não do mecanismo contextual pretendido. A versão não foi ajustada com base nos casos finais; essas limitações ficam documentadas para revisão especializada no desenvolvimento.

4.2.2.4 Piloto histórico preservado

O piloto de 25 de outubro de 2026 contém 11 perguntas em duas condições, totalizando 22 execuções, associado ao código original identificado por `1c7e0b3`. Não incluía todas as verificações e endurecimentos atuais. Suas respostas e tempos permanecem em `poc/docs/pilot_evidence.json`; não foram reinterpretados como resultados da GK-P1.2.

A diferença histórica entre as políticas em predação demonstra o funcionamento do parâmetro naquele piloto, mas não valida a versão posterior. A ausência de julgamento humano documentado impede calcular uma taxa de segurança ou de atendimento educativo a partir daquele lote. As respostas históricas constituem registros de funcionamento e não integram os indicadores da avaliação final.

4.2.3 Alcance das evidências preliminares

No funcionamento técnico, há código executável, testes aprovados, dois lotes completos e identificação dos componentes. Na segurança do conteúdo, há rotas de bloqueio/orientação observadas, porém julgamento humano pendente. No atendimento e na qualidade, há respostas geradas e falhas localizadas, sem evidência de compreensão ou aprendizagem. Na sustentação, há referências verificáveis e um verificador adicional, mas seus próprios erros precisam ser examinados.

Indicadores finais de inadequação e atendimento dependem de julgamentos humanos conclusivos. O plano antigo de 40 enunciados não foi executado; o atual prevê 32 enunciados e 64 oportunidades, conforme a Metodologia. Os denominadores históricos e atuais permanecem separados.

5 Conclusão

A prova de conceito operacionaliza uma regra contextual comum em quatro chats, com recuperação restrita ao acervo, verificações de proteção e dois estilos de explicação. O lote atual concluiu 32 tentativas sem perdas técnicas e com rotas alinhadas às referências propostas. Entretanto, a inspeção assistida identificou conteúdo sem apoio e uma distinção conceitual incorreta em explicações liberadas. A implementação do fluxo não demonstrou segurança geral, fidelidade garantida ou superioridade pedagógica do Passo a passo.

O público de sete a onze anos representa a destinação pretendida, não uma população observada. A operação usa um perfil fictício de nove anos; não houve teste de aprendizagem ou compreensão com crianças. A Tabela 10 distingue entregas realizadas e pendências.

Tabela 10 – Objetivos, evidências e situação atual

Objetivo	Evidência	Situação
Explicitar proteção e acervo	Regra comum e oito trechos em quatro chats	Revisão documental assistida realizada; revisão humana pendente.
Implementar e verificar	Fluxo, estilos, testes e snapshots	Verificação funcional; limitações de classificação e sustentação registradas.
Documentar desenvolvimento	32 tentativas atuais e 108 históricas separadas	Realizado; sem julgamento humano de eficácia.
Preparar avaliação posterior	32 casos em 16 famílias, 64 oportunidades e executor condicionado	Preparado; ratificação e execução final pendentes.

Fonte: Elaboração própria.

A exigência de passos e exemplos mudou a apresentação, mas também acompanhou acréscimos não sustentados nesta pequena amostra. Não se conclui que exemplos devam ser evitados: o resultado indica a necessidade de conferir sua correção e relação com as fontes, sem usar formato ou fluência como substitutos da revisão. O mesmo modelo gera e verifica conteúdo, favorecendo falhas correlacionadas. Os tempos refletem hardware, cache e rotas deste ambiente.

O desenho atual compara linguagem com proteção fixa. Não estima ganho causal de segurança provocado pelos guardrails. Os enunciados são intencionais, conhecidos pelos autores e assistidos por IA; a reserva futura é operacional e compartilha conceitos com o desenvolvimento.

Os 32 registros atuais, os 108 históricos e as 64 oportunidades finais pertencem a conjuntos e etapas distintos. Somá-los produziria um denominador sem interpretação comum.

5.1 Trabalhos futuros

A continuidade imediata requer ratificação humana das fontes e referências dos casos, confirmação dos avaliadores e congelamento da versão final. O conjunto reservado e o executor foram preparados após a inspeção do desenvolvimento, sem gerar suas respostas. Ajustes futuros do verificador de sustentação devem usar desenvolvimento e uma nova versão, preservando os registros atuais; mudanças motivadas por saídas finais exigirão novo planejamento.

A investigação pode examinar validação independente de sustentação, exemplos hipotéticos devidamente delimitados e adaptação de vocabulário por assunto. Essas possibilidades não substituem a avaliação humana. A participação futura de crianças constitui outro desenho de pesquisa, com exigências próprias, não contemplado neste TCC I.

5.1.1 Cronograma das etapas de avaliação

Tabela 11 – Etapas realizadas e continuidade proposta

Período	Atividade	Situação
Outubro e 3 nov. 2026	Piloto, dois lotes de Ciências e protocolo anterior	Histórico preservado.
4 nov. 2026	Revisar acervos, executar 32 tentativas, inspecionar respostas e preparar reserva	Realizado com assistência de IA; revisão humana pendente.
Após confirmação dos revisores	Ratificar fontes, referências e rubrica do plano atual	Planejado; sem assinatura presumida.
Após ratificação	Congelar versão e executar 64 oportunidades finais	Planejado; não executado.
Após execução	Julgar conteúdo, conciliar divergências e comparar pares	Planejado; capacidade a confirmar.

Fonte: Elaboração própria; janelas relativas sem prazo institucional presumido.

Referências

BRASIL. Ministério da Educação. **Base Nacional Comum Curricular**. Brasília, DF: MEC, 2018. p. 339. Disponível em: https://basenacionalcomum.mec.gov.br/images/BNCC_EI_EF_110518_versaofinal_site.pdf. Acesso em: 3 nov. 2026.

BRASIL. Ministério da Justiça e Segurança Pública. **Guia Prático de Audiovisual, RPG e aplicativos**. 5. ed. Brasília, DF: MJSP, 2025. Disponível em: https://www.gov.br/mj/pt-br/assuntos/seus-direitos/classificacao-1/classind-audio-visual-2025-vs-10-nova-faixa.pdf/view. Acesso em: 3 nov. 2026.

CHEN, Jianlyu et al. M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. In: **Findings of the Association for Computational Linguistics: ACL 2024**. Bangkok: Association for Computational Linguistics, 2024. p. 2318–2335. DOI: 10.18653/v1/2024.findings-acl.137. Disponível em: https://aclanthology.org/2024.findings-acl.137/. Acesso em: 4 nov. 2026.

GAO, Tianyu; YEN, Howard; YU, Jiatong; CHEN, Danqi. Enabling Large Language Models to Generate Text with Citations. In: **Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing**. Singapore: Association for Computational Linguistics, 2023. p. 6465–6488. DOI: 10.18653/v1/2023.emnlp-main.398. Disponível em: https://aclanthology.org/2023.emnlp-main.398/. Acesso em: 4 nov. 2026.

GOIÂNIA. Secretaria Municipal de Educação. **Geografia: a legenda do mapa**. Conexão Escola. Disponível em: https://sme.goiania.go.gov.br/conexaoescola/ensino_fundamental/geografia-a-legenda-dos-mapas/. Acesso em: 4 nov. 2026.

GOIÂNIA. Secretaria Municipal de Educação. **Geografia: noções de paisagem natural e cultural**. Conexão Escola. Disponível em: https://sme.goiania.go.gov.br/conexaoescola/ensino_fundamental/nocoes-de-paisagem-natural-e-cultural/. Acesso em: 4 nov. 2026.

GOIÂNIA. Secretaria Municipal de Educação. **Geografia: o trabalho e os trabalhadores**. Conexão Escola. Disponível em: https://sme.goiania.go.gov.br/conexaoescola/ensino_fundamental/geografia-o-trabalho-e-os-trabalhadores/. Acesso em: 4 nov. 2026.

GOIÂNIA. Secretaria Municipal de Educação. **História: cada objeto conta uma história**. Conexão Escola. Disponível em: https://sme.goiania.go.gov.br/conexaoescola/ensino_fundamental/historia-cada-objeto-conta-uma-historia/. Acesso em: 4 nov. 2026.

GOIÂNIA. Secretaria Municipal de Educação. **História: tipos de fontes históricas**. Conexão Escola. Disponível em: https://sme.goiania.go.gov.br/conexaoescola/eaja/historia-tipos-de-fontes-historicas/. Acesso em: 4 nov. 2026.

INAN, Hakan et al. **Llama Guard: LLM-based Input-Output Safeguard for Human-AI Conversations**. Preprint, 2023. arXiv:2312.06674. Disponível em: https://arxiv.org/abs/2312.06674. Acesso em: 3 nov. 2026.

KHOO, Shaun; CHUA, Gabriel; SHONG, Rachel. **MinorBench: A hand-built benchmark for content-based risks for children**. Preprint, 2025. arXiv:2503.10242, v. 1. Disponível em: https://arxiv.org/abs/2503.10242. Acesso em: 3 nov. 2026.

LEWIS, Patrick et al. **Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks**. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 33., 2020. Disponível em: https://arxiv.org/abs/2005.11401. Acesso em: 3 nov. 2026.

NÚCLEO DE INFORMAÇÃO E COORDENAÇÃO DO PONTO BR. **Cuide de seus dados pessoais**. Cidadão na Rede. Disponível em: https://cidadaonarede.nic.br/pt/videos/seguranca/cuide-de-seus-dados-pessoais. Acesso em: 4 nov. 2026.

RATH, Prasanjit; SHRAWGI, Hari; AGRAWAL, Parag; DANDAPAT, Sandipan. LLM Safety for Children. In: NAACL: HUMAN LANGUAGE TECHNOLOGIES, 2025, Albuquerque. **Proceedings [...]**, v. 3: Industry Track. Association for Computational Linguistics, 2025. p. 809–821. DOI: 10.18653/v1/2025.naacl-industry.62. Disponível em: https://aclanthology.org/2025.naacl-industry.62/. Acesso em: 3 nov. 2026.

REBEDEA, Traian et al. NeMo Guardrails: A Toolkit for Controllable and Safe LLM Applications with Programmable Rails. In: EMNLP: SYSTEM DEMONSTRATIONS, 2023, Singapore. **Proceedings [...]**. Association for Computational Linguistics, 2023. p. 431–445. DOI: 10.18653/v1/2023.emnlp-demo.40. Disponível em: https://aclanthology.org/2023.emnlp-demo.40/. Acesso em: 3 nov. 2026.

SÃO PAULO (Estado). Secretaria da Educação. **Currículo em Ação: Livro do Estudante: Ciências, Geografia e História: 4º ano, volume 2, 2º bimestre**. São Paulo: SEDUC-SP, 2024.

SÃO PAULO (Município). Secretaria Municipal de Educação. **Trilhas de aprendizagens: Ensino Fundamental: 4º ano, volume 2**. 2. ed. São Paulo: SME/COPED, 2021. Disponível em: https://acervodigital.sme.prefeitura.sp.gov.br/wp-content/uploads/2021/10/4ano_TA2_2ed_web.pdf. Acesso em: 3 nov. 2026.

SMITHSONIAN INSTITUTION. **Here. There. Everywhere.: shadows**. Disponível em: https://hte.si.edu/shadows.html. Acesso em: 4 nov. 2026.

VOLODINA, Anna; WEINERT, Sabine. Comprehension of Connectives: Development Across Primary School Age and Influencing Factors. **Frontiers in Psychology**, v. 11, art. 814, 2020. DOI: 10.3389/fpsyg.2020.00814. Disponível em: https://doi.org/10.3389/fpsyg.2020.00814. Acesso em: 4 nov. 2026.

WANG, Ge; ZHAO, Jun; VAN KLEEK, Max; SHADBOLT, Nigel. Informing Age-Appropriate AI: Examining Principles and Practices of AI for Children. In: CHI CONFERENCE ON HUMAN FACTORS IN COMPUTING SYSTEMS, 2022. **Proceedings [...]**. New York: ACM, 2022. artigo 536, p. 1–29. DOI: 10.1145/3491102.3502057. Disponível em: https://doi.org/10.1145/3491102.3502057. Acesso em: 3 nov. 2026.

APÊNDICE A – Materiais, evidências e reprodução

A.1 Compilação e materiais do manuscrito

O pacote para Overleaf contém a fonte principal `main.tex`, os capítulos, as tabelas geradas, o estilo institucional e as sete figuras vetoriais em `diagramas/pdf/`. Os desenhos editáveis correspondentes estão em `diagramas/drawio/`. Para compilar o manuscrito, seleciona-se XeLaTeX e recompila-se até que as listas e referências cruzadas se estabilizem. A composição do PDF independe do serviço de inferência e dos livros didáticos originais.

O manifesto `poc/corpus_manifest.json` descreve a procedência dos trechos. As configurações e os casos de desenvolvimento acompanham o texto. Em `avaliacao/evidencias/multichat_20261104_revisado/`, o CSV vincula cada tentativa a uma pergunta, um estilo, uma rota, um identificador de execução e um identificador de snapshot. O resumo e a inspeção assistida permitem confrontar essas rotas com o conteúdo liberado. Os registros do piloto preservados em `poc/docs/pilot_evidence.json` pertencem à etapa histórica.

A.2 Execução local e conferência do índice

A execução requer a implementação completa da PoC, o ambiente Python com suas dependências, as fontes compatíveis com o manifesto e os modelos Qwen3:8b e BGE-M3 disponíveis no Ollama local. Na cópia de trabalho examinada, havia arquivos legados de metadados e vetores, mas faltava `poc/data/current.json`, ponteiro que o carregador consulta para localizar o índice ativo. A constatação se refere àquela cópia local. O pacote editorial contém os insumos selecionados para leitura e compilação.

Na implementação completa, com os modelos disponíveis, a reconstrução é feita a partir da raiz do projeto pelo comando `pythonpoc/guardkids.pyindex`, usando o ambiente da PoC. Em seguida, lê-se o campo `id` em `poc/data/current.json` e verifica-se a presença dos metadados e vetores no subdiretório de `poc/data/indices/` com esse nome. Com o serviço em execução, consulta-se `/api/status` para conferir a prontidão e o identificador do índice validado. A comparação histórica exige o identificador do índice registrado na execução original ou no campo correspondente do snapshot arquivado.

O identificador do índice designa o acervo indexado. O identificador do snapshot reúne também configuração, código, instruções e ambiente. O valor iniciado por `4531f5b01c5b`, presente no CSV, identifica o snapshot do lote. Usá-lo como valor esperado do índice produziria uma comparação entre objetos distintos. Esta revisão editorial descreve o procedimento. A re-

construção do índice e a reprodução das inferências originais ficam fora de seu escopo.

A.3 Avaliação humana planejada

Em `avaliacao/final_multichat_v1/`, os casos, o protocolo e a agenda especificam 32 perguntas em 16 famílias e 64 tentativas. A referência em CSV aguarda confirmação, identidade, data e justificativa humanas. Antes de gerar respostas finais, o protocolo exige a ratificação das referências e o congelamento de casos, fontes, modelos, índice, código e instruções. O executor pertence à implementação completa da PoC.

O instrumento de avaliação usa o mesmo identificador de resposta para relacionar o parecer primário, o secundário e a conciliação. Planejam-se 64 pareceres primários e 16 secundários definidos previamente na agenda. Cada avaliador recebe somente seu material, registra suas decisões e justificativas e entrega o parecer antes de conhecer o julgamento do outro. A coordenação conserva os originais e registra separadamente a decisão sobre divergências. O texto da resposta pode revelar o estilo mesmo quando a chave de condição é retida. As instruções de preenchimento acompanham o protocolo. A ratificação humana, o congelamento, a execução do lote final e os julgamentos permanecem pendentes.